

Fundamentals of Actuarial Mathematics

Short-Term

John Rodríguez

20 de agosto de 2026

Índice general

	5
1 - Short-Term Insurance and Reinsurance Coverages	7
1.1 - Coverage Modifications and Reinsurance	7
2 - Severity, Frequency, and Aggregate Models	33
2.1 - Basics	33
2.2 - Severity Models	49
2.3 - Severity Models with Coverage Modifications	69
2.4 - Frequency Models	89
2.5 - Aggregate Models	122
2.6 - Risk Measures	158
3 - Parametric Estimation	179
Section 3.1 - Maximum Likelihood Estimators	179
Ejercicios	206
Cierre y puente final	213
4 - Introduction to Credibility	217
Section 4.1 - Classical Credibility	217
5 - Pricing and Reserving for Short-Term Insurance Coverages	235
Section 5.1 - Loss Reserving: Expected Loss Ratio, Chain-Ladder y Bornhuetter-Ferguson	235
Section 5.2 - Data Preparation for Ratemaking	256
Section 5.3 - Ratemaking: Loss Cost and Loss Ratio Methods	273
Cierre y Puente de Paradigm Shift (Tránsito a Part 6)	283

Ejercicios	284
6 - Option Pricing Fundamentals	289
Section 6.1 - Introduction to Options	289

1 - Short-Term Insurance and Reinsurance Coverages

1.1 - Coverage Modifications and Reinsurance

El mismo siniestro cambia de tamaño según el contrato y el balance desde el que se mire

1.1.1 El siniestro original no es la pérdida final de la aseguradora

Cuando ocurre un siniestro en el seguro de daños comerciales, la primera cifra que se registra es el daño físico directo sufrido por el asegurado, conocido técnicamente como pérdida original o pérdida *ground-up*. Consideremos el Siniestro A, caso canónico del universo ficticio de Meridiano Seguros. Un asegurado de su cartera de seguros de propiedad comercial para pequeñas y medianas empresas sufre un siniestro de gran magnitud en sus instalaciones, cuya pérdida *ground-up* se evalúa en exactamente 80,000 USD. Ante este escenario, la primera pregunta parece directa: ¿cuánto perdió Meridiano Seguros?

Para un lector no familiarizado con la práctica actuarial, la respuesta obvia sería 80,000 USD. Sin embargo, la pérdida que experimenta el asegurado y el desembolso que realiza la aseguradora rara vez coinciden. La pregunta completa que gobernará esta sección es más precisa: **¿quién termina pagando cada porción de esos 80,000 USD entre el asegurado, la aseguradora y, cuando existe reaseguro, el reasegurador?**

Entre el siniestro original y el pago final intervienen las condiciones del contrato de seguro directo, diseñadas para repartir el costo del evento entre el asegurado y la compañía. Para el contrato base de Meridiano Seguros, estas condiciones están compuestas por tres elementos secuenciales: un deducible (*deductible*) de 2,500 USD, un límite de pago por encima del deducible (*payment limit above deductible*) de 75,000 USD y una proporción de coaseguro (*coinsurance*) bajo la cual la aseguradora asume el 90 %.

Desafío al lector. Antes de continuar, calcule cuánto debería pagar Meridiano Seguros por el Siniestro A si el orden contractual es: deducible, límite y, finalmente, coaseguro. La respuesta no es 80,000 USD.

La existencia de estas cláusulas exige desterrar el lenguaje ambiguo. Irene, en su función de *chief actuary* de Meridiano Seguros, advierte que expresiones vagas como “la pérdida es de 80,000 USD” conducen a errores de interpretación. En la práctica actuarial es necesario clasificar cada importe según la perspectiva económica a la que pertenezca. El daño original, el importe después del deducible, el monto sujeto a coaseguro y el pago bruto de la aseguradora son cantidades distintas. Ninguna es intercambiable con las demás.

1.1.2 El deducible, el límite de cobertura y el coaseguro esculpen el pago bruto

La transformación de una pérdida *ground-up* X en el pago bruto de la aseguradora Y se rige por un orden de aplicación de las condiciones contractuales que es estrictamente secuencial y no conmutativo. Esto significa que no debemos aplicar las cláusulas como si fueran operaciones independientes cuyo orden careciera de importancia.

La secuencia contractual correcta es:

1. **Absorción del deducible.** El deducible traslada la primera porción de la pérdida directamente al asegurado. Para el Siniestro A:

$$80,000 \text{ USD} - 2,500 \text{ USD} = 77,500 \text{ USD}.$$

2. **Tope del límite de pago.** El contrato establece un máximo de 75,000 USD pagaderos por encima del deducible. Como el importe después del deducible es 77,500 USD:

$$\min(77,500 \text{ USD}, 75,000 \text{ USD}) = 75,000 \text{ USD}.$$

3. **Aplicación del coaseguro.** Meridiano asume el 90 % del importe cubierto y limitado:

$$0.90(75,000 \text{ USD}) = 67,500 \text{ USD}.$$

Por tanto, el pago bruto realizado por la aseguradora es:

$$Y = 67,500 \text{ USD}.$$

Solo después de comprender el mecanismo contractual resulta útil escribir la regla general:

$$Y = c \min((X - d)_+, \ell),$$

donde:

$$(X - d)_+ = \max(X - d, 0),$$

d es el deducible nominal, ℓ es el límite de pago por encima del deducible y c es la proporción del importe cubierto que paga la aseguradora.

Las cuatro cantidades del Siniestro A pueden verse simultáneamente:

Cantidad económica	Importe
Pérdida <i>ground-up</i> X	80,000 USD
Importe después del deducible	77,500 USD

Cantidad económica	Importe
Importe después del límite	75,000 USD
Pago bruto de la aseguradora Y	67,500 USD

¿Cuál de estas cuatro cifras es “la pérdida”? La pregunta está mal formulada si no se especifica la variable económica. 80,000 USD es la pérdida *ground-up*; 67,500 USD es el pago bruto de la aseguradora.

Para verificar la conservación del costo económico del evento, podemos reconstruir los 80,000 USD originales:

- El asegurado absorbe los primeros 2,500 USD por el deducible.
- El límite de 75,000 USD por encima del deducible implica que el contrato alcanza su máximo cubierto cuando la pérdida *ground-up* llega a:

$$d + \ell = 2,500 + 75,000 = 77,500 \text{ USD.}$$

Como el Siniestro A asciende a 80,000 USD, el importe no cubierto por encima de ese umbral es:

$$80,000 - (2,500 + 75,000) = 2,500 \text{ USD.}$$

- El asegurado soporta además el 10 % del importe cubierto y limitado:

$$0.10(75,000 \text{ USD}) = 7,500 \text{ USD.}$$

- Meridiano Seguros paga el 90 % restante:

67,500 USD.

La reconciliación completa es:

$$2,500 + 2,500 + 7,500 + 67,500 = 80,000 \text{ USD.}$$

Las cláusulas contractuales no hacen desaparecer el costo de un siniestro. Determinan quién soporta cada porción.

1.1.3 El factor de eliminación de pérdidas (LER) mide dólares de siniestro, no cantidad de reclamaciones

Para analizar el impacto de las modificaciones de cobertura en una cartera completa, los actuarios deben pasar del análisis de un único siniestro a cantidades agregadas observadas. Supongamos que Meridiano Seguros quiere cuantificar qué proporción de sus pérdidas *ground-up* observadas deja de convertirse en obligación de pago por el efecto exclusivo del deducible. El cálculo empírico utiliza el Accident Year 2024 completamente desarrollado del caso canónico. Durante ese año, la cartera registró:

- 12,000 pólizas-año de exposición (*policy-years*);
- 720 reclamaciones *ground-up*;
- 12.960 millones USD de pérdidas *ground-up* acumuladas.

De las 720 pérdidas, 96 fueron menores o iguales al deducible de 2,500 USD y registraron un costo promedio de 1,250 USD. El deducible elimina completamente esos importes de la obligación considerada:

$$96(1,250 \text{ USD}) = 120,000 \text{ USD.}$$

Las otras 624 pérdidas superaron el deducible, por lo que este elimina los primeros 2,500 USD de cada una:

$$624(2,500 \text{ USD}) = 1,560,000 \text{ USD}.$$

El monto total eliminado exclusivamente por el deducible es entonces:

$$120,000 + 1,560,000 = 1,680,000 \text{ USD} = 1.680\text{M USD}.$$

El importe agregado remanente después del deducible, pero antes de límites y coaseguro, es:

$$12.960\text{M USD} - 1.680\text{M USD} = 11.280\text{M USD}.$$

Desafío al lector. Si la cartera tenía 12.960M USD de pérdidas *ground-up* y conserva 11.280M USD después del deducible, ¿qué fracción de los dólares *ground-up* fue eliminada?

El factor de eliminación de pérdidas o *loss elimination ratio* (LER) es:

$$\text{LER} = \frac{\text{Monto de pérdida ground-up eliminado}}{\text{Monto total de pérdidas ground-up}}.$$

Equivalentemente:

$$\text{LER} = 1 - \frac{\text{Monto después del deducible}}{\text{Monto ground-up}}.$$

Para la cartera 2024:

$$\text{LER} = \frac{1.680\text{M USD}}{12.960\text{M USD}} = 12.96296 \dots \% \approx \boxed{12.96 \%}.$$

El significado económico es específico: **bajo esta cartera observada y este deducible, aproximadamente el 12.96 % de los dólares de pérdida *ground-up* queda eliminado**

de la obligación de pago considerada por efecto exclusivo del deducible, antes de aplicar límite y coaseguro.

Este resultado no significa que haya desaparecido aproximadamente el 12.96 % de las reclamaciones. Las 96 reclamaciones que no superaron el deducible representan:

$$\frac{96}{720} = 13.33 \, \%.$$

El 13.33 % es una proporción de reclamaciones. El 12.96 % es una proporción de dólares de pérdida. La proximidad numérica de ambos valores en esta cartera no los convierte en la misma cantidad.

Las demás modificaciones contractuales generan reducciones adicionales que deben etiquetarse por separado.

Después de deducible y límite, antes de coaseguro, el importe agregado es 10.400M USD:

$$1 - \frac{10.400\text{M USD}}{12.960\text{M USD}} = 19.753 \dots \% \approx 19.75 \, \%.$$

Después de deducible, límite y coaseguro, el pago bruto agregado de Meridiano es 9.360M USD:

$$1 - \frac{9.360\text{M USD}}{12.960\text{M USD}} = 27.777 \dots \% \approx 27.78 \, \%.$$

La palabra “eliminación” por sí sola es insuficiente: siempre debe especificarse qué modificaciones contractuales están incluidas. En esta sección, LER se reserva para el efecto del deducible.

Existe además una sensibilidad inmediata. Si el deducible aumentara, manteniendo todo lo demás constante, la proporción de dólares *ground-up* eliminados por el deducible debería aumentar. Todavía no necesitamos modelar una distribución completa para entender la dirección económica del cambio: un deducible mayor desplaza una porción mayor de cada pérdida hacia el asegurado.

1.1.4 Los deducibles nominales fijos distorsionan la transmisión de la inflación

La inflación de severidad aumenta el costo de reparación o reemplazo y, por tanto, modifica directamente la pérdida *ground-up* X . Sin embargo, un aumento porcentual de X no tiene por qué convertirse en el mismo aumento porcentual del pago bruto Y cuando existen umbrales contractuales expresados en dólares nominales.

Consideremos el Siniestro B, cuya pérdida *ground-up* inicial es:

$$X = 40,000 \text{ USD.}$$

Bajo el contrato base de Meridiano Seguros, el deducible es 2,500 USD, el límite por encima del deducible es 75,000 USD y el coaseguro de la aseguradora es del 90 %. En este caso el límite no es vinculante, porque:

$$40,000 - 2,500 = 37,500 < 75,000.$$

El pago inicial es:

$$Y = 0.90(40,000 - 2,500) = \boxed{33,750 \text{ USD}}.$$

Desafío al lector. Si la pérdida *ground-up* aumenta exactamente un 6 %, ¿debería aumentar también el pago de Meridiano exactamente un 6 %?

La inflación de severidad lleva la pérdida a:

$$X' = 40,000(1.06) = \boxed{42,400 \text{ USD}}.$$

El deducible y el límite del contrato permanecen nominalmente fijos. El límite continúa sin ser vinculante:

$$42,400 - 2,500 = 39,900 < 75,000.$$

El nuevo pago bruto es:

$$Y' = 0.90(42,400 - 2,500) = \boxed{35,910 \text{ USD}}.$$

La pérdida *ground-up* creció exactamente:

$$\frac{42,400}{40,000} - 1 = \boxed{6.00 \%}.$$

El pago de la aseguradora creció:

$$\frac{35,910}{33,750} - 1 = \boxed{6.40 \%}.$$

Por tanto, una inflación *ground-up* del 6.00 % se convierte, en este siniestro, en un crecimiento del pago bruto del 6.40 %.

La causa es el deducible nominal fijo. La pérdida aumenta, pero se continúa restando la misma cantidad de 2,500 USD. El deducible representa así una fracción menor del siniestro inflado, de modo que el importe restante sobre el cual actúa el coaseguro aumenta proporcionalmente más que la pérdida original.

Una pequeña sensibilidad confirma el mecanismo. Supongamos que, en lugar de permanecer fijo, el deducible también se indexara un 6 %:

$$d' = 2,500(1.06) = 2,650 \text{ USD}.$$

Con la pérdida inflada de 42,400 USD y manteniendo el mismo coaseguro, el pago sería:

$$Y^{(\text{indexado})} = 0.90(42,400 - 2,650) = 0.90(39,750) = \boxed{35,775 \text{ USD}}.$$

Su crecimiento respecto del pago inicial sería:

$$\frac{35,775}{33,750} - 1 = \boxed{6.00\%}.$$

El contraste demuestra que la diferencia entre 6.00% y 6.40% no procede de la inflación por sí sola. Procede de la interacción entre la inflación de X y un deducible contractual que permanece fijo en términos nominales.

El límite puede producir el efecto opuesto. El pago bruto máximo bajo el contrato base es:

$$0.90(75,000) = \boxed{67,500 \text{ USD}}.$$

Una vez alcanzado ese máximo, una pérdida *ground-up* puede seguir aumentando sin que el pago bruto supere 67,500 USD. Los deducibles fijos pueden amplificar el crecimiento porcentual del pago en ciertos intervalos; los límites pueden frenarlo o detenerlo en otros.

La regla que debemos conservar es sencilla: **la inflación actúa sobre X ; los umbrales contractuales determinan cómo ese cambio se transmite a Y .**

1.1.5 El reaseguro no reduce la deuda con el asegurado: redistribuye el costo de los pagos

Una vez determinado el pago bruto Y que Meridiano Seguros debe realizar al asegurado, aparece una segunda relación contractual: el reaseguro (*reinsurance*).

El reaseguro permite que Meridiano Seguros, como compañía cedente, transfiera económicamente una parte del costo de sus pagos a una reaseguradora. No sustituye el contrato original entre Meridiano y su asegurado.

En el Siniestro A:

$$Y = 67,500 \text{ USD}.$$

La pregunta es ahora distinta: **Meridiano debe pagar 67,500 USD al asegurado; ¿significa eso que los 67,500 USD permanecerán íntegramente como costo retenido por Meridiano?**

No necesariamente.

Mateo enfatiza una distinción fundamental: el reaseguro no extingue ni reduce la obligación directa de Meridiano frente al asegurado. Si el contrato de seguro directo exige un pago bruto de 67,500 USD, Meridiano continúa debiendo esos 67,500 USD al cliente con independencia de la estructura de reaseguro analizada.

El tratado de reaseguro determina cómo se distribuye económicamente ese pago bruto entre la cedente y la reaseguradora. Definimos:

- Y^{ced} : recuperación de reaseguro o importe cedido;
- Y^{net} : importe neto retenido por Meridiano.

La identidad fundamental es:

$$Y = Y^{ced} + Y^{net}.$$

El contrato directo transforma:

$$X \longrightarrow Y.$$

El tratado de reaseguro transforma después la financiación económica de Y :

$$Y \longrightarrow Y^{ced} + Y^{net}.$$

Los dos niveles contractuales no deben confundirse.

1.1.6 Quota Share y Exceso de Pérdida reestructuran el perfil de riesgo retenido de formas opuestas

Meridiano Seguros analiza dos tratados de reaseguro **alternativos y excluyentes**, no simultáneos. Ambos se aplican sobre el pago bruto Y , no directamente sobre la pérdida *ground-up* X .

Tratado 1: Reaseguro Quota Share (Proporcional)

En el tratado Quota Share canónico, la proporción cedida es:

$$q = 0.30.$$

La reaseguradora participa en una proporción fija del 30 % de cada pago bruto:

$$Y^{ced} = qY = 0.30Y.$$

La retención neta de Meridiano es:

$$Y^{net} = Y - Y^{ced} = 0.70Y.$$

Para el Siniestro A:

$$Y = 67,500 \text{ USD}.$$

La recuperación de reaseguro es:

$$Y^{ced} = 0.30(67,500) = \boxed{20,250 \text{ USD}}.$$

La retención neta es:

$$Y^{net} = 67,500 - 20,250 = \boxed{47,250 \text{ USD}}.$$

La reconciliación es exacta:

$$67,500 = 20,250 + 47,250.$$

El mismo mecanismo proporcional opera sobre el pago bruto agregado observado de la cartera 2024:

$$Y_{agg} = 9.360\text{M USD}.$$

El importe cedido agregado es:

$$Y_{agg}^{ced} = 0.30(9.360\text{M}) = \boxed{2.808\text{M USD}}.$$

La retención neta agregada es:

$$Y_{agg}^{net} = 9.360\text{M} - 2.808\text{M} = \boxed{6.552\text{M USD}}.$$

Y nuevamente:

$$9.360\text{M} = 2.808\text{M} + 6.552\text{M}.$$

La característica estructural del Quota Share es la proporcionalidad: la misma fracción del pago se cede en todos los niveles a los que se aplica el tratado.

Tratado 2: Reaseguro de Exceso de Pérdida (No Proporcional)

El tratado de exceso de pérdida o *excess-of-loss* (XoL) funciona de forma distinta. Meridiano retiene los primeros 25,000 USD del pago bruto y la reaseguradora cubre después una capa

de hasta 40,000 USD.

El tratado se expresa como:

$$40,000 \text{ xs } 25,000.$$

La recuperación es:

$$Y^{ced} = \min((Y - 25,000)_+, 40,000).$$

Para el Siniestro A:

$$Y = 67,500 \text{ USD.}$$

El importe por encima del *attachment* es:

$$67,500 - 25,000 = 42,500 \text{ USD.}$$

Como la capa solo puede ceder 40,000 USD:

$$Y^{ced} = \boxed{40,000 \text{ USD}}.$$

La retención neta es:

$$Y^{net} = 67,500 - 40,000 = \boxed{27,500 \text{ USD}}.$$

La capa se agota cuando el pago bruto alcanza:

$$25,000 + 40,000 = \boxed{65,000 \text{ USD}}.$$

El Siniestro A tiene un pago bruto de 67,500 USD, por lo que los 2,500 USD situados entre 65,000 y 67,500 quedan nuevamente retenidos por Meridiano.

Así:

$$27,500 = 25,000 + 2,500.$$

Esto desmonta una intuición frecuente: una retención XoL de 25,000 USD no significa que la aseguradora nunca pueda terminar reteniendo más de 25,000 USD. Con una capa finita, los importes posteriores al agotamiento vuelven a la cedente.

El Siniestro B permite ver otro comportamiento del mismo tratado.

Antes de inflación:

$$Y = 33,750 \text{ USD.}$$

La recuperación XoL es:

$$Y^{ced} = 33,750 - 25,000 = \boxed{8,750 \text{ USD}}.$$

La retención neta es:

$$Y^{net} = 33,750 - 8,750 = \boxed{25,000 \text{ USD}}.$$

La reconciliación es:

$$33,750 = 8,750 + 25,000.$$

Después de la inflación del 6%:

$$Y' = 35,910 \text{ USD.}$$

La recuperación pasa a ser:

$$Y^{ced} = 35,910 - 25,000 = \boxed{10,910 \text{ USD}}.$$

La retención neta continúa siendo:

$$Y^{net} = 35,910 - 10,910 = \boxed{25,000 \text{ USD}}.$$

Y:

$$35,910 = 10,910 + 25,000.$$

En este tramo concreto de la capa XoL, el aumento de 2,160 USD del pago bruto se refleja íntegramente en el aumento de la recuperación de reaseguro:

$$10,910 - 8,750 = 2,160 \text{ USD},$$

mientras que la retención neta permanece en 25,000 USD. Esta conclusión depende de que ambos pagos permanezcan dentro de la capa; no debe generalizarse a pagos por debajo del *attachment* ni por encima de su punto de agotamiento.

Desafío al lector. Antes de observar la tabla siguiente, determine para pagos brutos de 20,000, 40,000 y 67,500 USD cuánto cedería un Quota Share del 30 % y cuánto cedería el XoL de 40,000 xs 25,000. ¿Qué tratado cede más en cada nivel?

				Neto de
Pago bruto directo Y	Cedido bajo QS (30 %)	Neto de Meridiano - QS	Cedido bajo XoL 40k xs 25k	Meridiano - XoL
20,000 USD	6,000 USD	14,000 USD	0 USD	20,000 USD
40,000 USD	12,000 USD	28,000 USD	15,000 USD	25,000 USD
67,500 USD	20,250 USD	47,250 USD	40,000 USD	27,500 USD

Las cifras de 20,000 y 40,000 USD son escenarios locales estrictamente pedagógicos y no nuevos registros históricos del Accident Year 2024.

La comparación muestra dos estructuras distintas:

- **Quota Share:** cede una proporción fija desde el primer dólar relevante del pago. Los pagos pequeños y grandes se comparten con la misma proporción.
- **XoL:** no cede nada por debajo del *attachment*, absorbe los dólares comprendidos dentro de la capa y, después del agotamiento, deja nuevamente los importes adicionales con la cedente.

Por tanto, los dos tratados no son versiones casi equivalentes de una misma reducción. Modifican la retención de formas estructuralmente distintas. Determinar cuál conviene económicamente exigiría además considerar el costo y el objetivo del programa de reaseguro, cuestiones que no se cuantifican en esta sección.

El contraste principal del Siniestro A puede resumirse de la siguiente manera:

Perspectiva	Variable	Claim A - Quota Share	Claim A - XoL
Pérdida económica <i>ground-up</i>	X	80,000 USD	80,000 USD
Pago bruto al asegurado	Y	67,500 USD	67,500 USD
Recuperación de reaseguro	Y^{ced}	20,250 USD	40,000 USD
Pago neto retenido	Y^{net}	47,250 USD	27,500 USD

La elección del tratado cambia la división entre Y^{ced} y Y^{net} ; no cambia ni el evento *ground-up* X ni el pago bruto Y debido al asegurado.

1.1.7 La tarificación y la constitución de reservas exigen definir si la base es bruta o neta

La transferencia de parte del costo al reasegurador afecta las cantidades que posteriormente importarán para tarificación (*pricing*) y constitución de reservas (*reserving*), pero esos dos

temas requieren marcos que se desarrollarán más adelante.

En tarificación, Lucía debe distinguir entre:

1. siniestralidad esperada bruta (*gross expected losses*);
2. siniestralidad esperada cedida (*ceded expected losses*);
3. siniestralidad esperada neta retenida (*net retained expected losses*);
4. costo económico del reaseguro.

Una reducción de Y^{net} no significa automáticamente que la prima del asegurado deba disminuir en la misma cantidad. El reaseguro tiene un costo económico propio, pero esta sección no dispone de una prima de reaseguro canónica y, por tanto, no la inventará ni la descompondrá.

Para reserving, Mateo enfatiza una disciplina semejante. La existencia de reaseguro no borra la obligación bruta derivada del contrato directo. Posteriormente será necesario distinguir entre la obligación bruta por siniestros, las recuperaciones de reaseguro esperadas y la posición neta resultante.

Por tanto, antes de interpretar una cifra de pricing o reserving habrá que responder una pregunta básica:

¿La cantidad que estamos analizando está expresada sobre una base bruta o neta de reaseguro?

Esta sección no desarrolla todavía métodos de tarificación ni técnicas de reserving. Solo establece la distinción de base que esos métodos necesitarán.

Cierre y Puente Final

Al inicio de esta sección, el Siniestro A parecía ofrecer una única cifra: 80,000 USD. Ahora podemos distinguir una cadena completa de cantidades.

Para el Siniestro A:

$$X = 80,000 \text{ USD},$$

y:

$$Y = 67,500 \text{ USD}.$$

Bajo el Quota Share del 30 %:

$$Y^{ced} = 20,250 \text{ USD},$$

$$Y^{net} = 47,250 \text{ USD}.$$

Bajo el XoL de 40,000 xs 25,000:

$$Y^{ced} = 40,000 \text{ USD},$$

$$Y^{net} = 27,500 \text{ USD}.$$

Todas estas cifras son correctas porque responden preguntas distintas.

El Siniestro B añadió otra disciplina. Una pérdida *ground-up* de:

$$40,000 \text{ USD}$$

produce un pago bruto de:

$$33,750 \text{ USD}.$$

Después de una inflación del 6 %:

$$X' = 42,400 \text{ USD},$$

mientras que:

$$Y' = 35,910 \text{ USD},$$

un crecimiento del:

$$6.40 \%.$$

Bajo el XoL analizado, y específicamente mientras ambos pagos permanecen dentro de su capa, la recuperación aumenta de:

$$8,750 \text{ USD}$$

a:

$$10,910 \text{ USD},$$

mientras que la retención neta de Meridiano permanece en:

$$25,000 \text{ USD}.$$

La conclusión operativa es fundamental: antes de modelar un riesgo o interrogar una base de datos, debemos definir sin ambigüedad qué variable económica estamos midiendo.

Una modificación de cobertura transforma:

$$X \longrightarrow Y.$$

El reaseguro divide después:

$$Y = Y^{ced} + Y^{net}.$$

No existe un único “claim amount” que sirva indistintamente para todas las preguntas actuariales.

Hasta aquí hemos trabajado con siniestros cuyos importes ya conocemos. Pero Lucía plantea la pregunta que abre el siguiente problema: **si queremos modelar el costo de un siniestro futuro, ¿debemos describir X , Y o Y^{net} , y cómo describimos matemáticamente una cantidad cuyo valor todavía no conocemos?**

Ese cambio exige pasar de un siniestro conocido a una variable aleatoria. Antes de seleccionar modelos de severidad, necesitaremos recuperar las herramientas con las que describiremos esas variables: probabilidades, percentiles, momentos, centro y dispersión.

Ese es el punto de partida de **Section 2.1 - Basics**.

Ejercicios

Ejercicio 1 - Contract transformation and allocation

Un asegurado de la cartera de propiedad comercial sufre un siniestro cuya pérdida *ground-up* X se evalúa en exactamente 90,000 USD. El contrato directo cuenta con las condiciones del contrato base de Meridiano Seguros: deducible $d = 2,500$ USD, límite de pago por encima del deducible $\ell = 75,000$ USD y proporción de coaseguro $c = 90\%$.

1. Calcule el monto retenido por el asegurado por concepto de deducible, coaseguro y pérdida excedente del límite.
2. Calcule el pago bruto final Y que realiza Meridiano Seguros.
3. Asumiendo que Meridiano cuenta con un tratado XoL de 40,000 xs 25,000 aplicado sobre Y , calcule Y^{ced} y Y^{net} .

4. Reconcilie los 90,000 USD de pérdida original demostrando que la suma de la retención del asegurado, el importe financiado económicamente por el reasegurador y el pago neto retenido por Meridiano equivale a la pérdida *ground-up*.

Criterio de éxito para la solución:

$$Y = 0.90 \min((90,000 - 2,500)_+, 75,000) = 0.90(75,000) = 67,500 \text{ USD.}$$

$$Y^{ced} = \min((67,500 - 25,000)_+, 40,000) = 40,000 \text{ USD.}$$

$$Y^{net} = 67,500 - 40,000 = 27,500 \text{ USD.}$$

El límite de cobertura se agota cuando la pérdida *ground-up* alcanza:

$$d + \ell = 77,500 \text{ USD.}$$

Por tanto, el exceso no cubierto es:

$$90,000 - 77,500 = 12,500 \text{ USD.}$$

La retención total del asegurado es:

$$2,500 + 12,500 + 7,500 = 22,500 \text{ USD.}$$

Y la reconciliación completa es:

$$22,500 + 40,000 + 27,500 = 90,000 \text{ USD.}$$

Ejercicio 2 - LER and inflation interpretation

Supongamos que una cartera de seguros de propiedad de Meridiano Seguros registra pérdidas agregadas *ground-up* por 15.00 millones USD. Tras aplicar un deducible específico, el monto agregado remanente se reduce a 13.00 millones USD.

1. Calcule el LER empírico del deducible.
2. Considere un siniestro individual con una pérdida *ground-up* inicial de 50,000 USD bajo un contrato con deducible de 2,500 USD y coaseguro del 90 %, sin límite de cobertura. Calcule el pago bruto inicial.
3. Si la pérdida *ground-up* experimenta una inflación exacta del 10 %, calcule la nueva pérdida y el nuevo pago bruto.
4. Compare los incrementos relativos de la pérdida *ground-up* y del pago de la aseguradora, y explique la causa estructural de la diferencia.

Criterio de éxito para la solución:

$$\text{LER} = \frac{15.00\text{M} - 13.00\text{M}}{15.00\text{M}} = \boxed{13.33 \%}.$$

El pago inicial es:

$$0.90(50,000 - 2,500) = \boxed{42,750 \text{ USD}}.$$

La pérdida inflada es:

$$50,000(1.10) = \boxed{55,000 \text{ USD}}.$$

El nuevo pago es:

$$0.90(55,000 - 2,500) = \boxed{47,250 \text{ USD}}.$$

El crecimiento del pago es:

$$\frac{47,250}{42,750} - 1 = 10.5263 \dots \% \approx \boxed{10.53 \%}.$$

El pago crece más que la pérdida *ground-up* porque el deducible nominal de 2,500 USD permanece fijo.

Ejercicio 3 - Quota Share vs. Excess of Loss comparison

Supongamos que Meridiano Seguros tiene tres siniestros con pagos brutos Y de exactamente 20,000, 45,000 y 67,500 USD. La aseguradora evalúa dos estructuras de reaseguro alternativas aplicables sobre el pago bruto: un Quota Share del 30% cedido y un XoL de 40,000 xs 25,000.

1. Para cada uno de los tres pagos, calcule Y^{ced} y Y^{net} bajo el Quota Share.
2. Para cada uno, calcule Y^{ced} y Y^{net} bajo el XoL.
3. Identifique qué tratado cede una mayor cantidad de dólares en cada nivel.
4. Explique cómo cambia la retención de Meridiano bajo ambas estructuras y por qué estos cálculos, por sí solos, no permiten afirmar que un tratado sea universalmente “mejor” sin considerar el objetivo y el costo del programa de reaseguro.

Criterio de éxito para la solución:

Para $Y = 20,000$ USD:

$$Y_{QS}^{ced} = 0.30(20,000) = 6,000 \text{ USD},$$

$$Y_{QS}^{net} = 14,000 \text{ USD}.$$

Bajo XoL:

$$Y_{XoL}^{ced} = 0,$$

$$Y_{XoL}^{net} = 20,000 \text{ USD.}$$

El Quota Share cede más.

Para $Y = 45,000$ USD:

$$Y_{QS}^{ced} = 13,500 \text{ USD,}$$

$$Y_{QS}^{net} = 31,500 \text{ USD.}$$

Bajo XoL:

$$Y_{XoL}^{ced} = 45,000 - 25,000 = 20,000 \text{ USD,}$$

$$Y_{XoL}^{net} = 25,000 \text{ USD.}$$

El XoL cede más.

Para $Y = 67,500$ USD:

$$Y_{QS}^{ced} = 20,250 \text{ USD,}$$

$$Y_{QS}^{net} = 47,250 \text{ USD.}$$

Bajo XoL:

$$Y_{XoL}^{ced} = \min(67,500 - 25,000, 40,000) = 40,000 \text{ USD},$$

$$Y_{XoL}^{net} = 27,500 \text{ USD}.$$

El XoL cede más.

El Quota Share reduce proporcionalmente todos los pagos a los que se aplica. El XoL no cede por debajo del *attachment*, absorbe una capa definida y vuelve a dejar importes con la cedente después del agotamiento. Los cálculos muestran diferencias de estructura y de allocation; una comparación económica completa requeriría además el costo y el objetivo del programa de reaseguro.

2 - Severity, Frequency, and Aggregate Models

2.1 - Basics

Una media de 18,000 dólares puede ocultar casi toda la historia

2.1.1 Una media de 18,000 dólares puede ocultar casi toda la historia

Cuando analizamos de forma retrospectiva el desempeño financiero de una cartera de seguros de daños, las magnitudes globales suelen presentarse como cifras claras, cerradas y aparentemente autoexplicativas. Consideremos la experiencia histórica de **Meridiano Seguros** para su cartera de propiedad comercial en el **Accident Year 2024**. Al finalizar el periodo de desarrollo, el sistema registra un total de **720 reclamaciones de severidad ground-up** con un **costo total acumulado de 12.960 millones de dólares (12,960,000 USD)**.

Al procesar estas cifras para una primera reunión de evaluación de tarifas, **Lucía** presenta un resumen directo: la severidad promedio de los siniestros de la cartera en 2024 es de exactamente **18,000 USD**. Desde la perspectiva de Pricing, este promedio aritmético se interpreta como la medida central de la severidad del portafolio. No obstante, **Irene**, en su función de control de riesgos y precisión técnica, cuestiona de inmediato la suficiencia de este único dato: *«Ese promedio de 18,000 USD es aritméticamente inobjetable, Lucía, pero ¿qué nos dice realmente sobre la estructura de los siniestros que ocurrieron? Si tuviéramos*

que enfrentar un siniestro de cola en el próximo año de suscripción, ¿cuánta de la verdadera incertidumbre estamos ocultando al resumir 720 eventos en un solo promedio?».

El cuestionamiento de Irene obliga a desagregar el portafolio y revelar sus **anclas empíricas** de severidad observadas en el dataset de 2024:

- La **severidad media** es de **18,000 USD**.
- La **mediana** es de aproximadamente **9,000 USD**.
- El **percentil 90** es de aproximadamente **42,000 USD**.
- El **percentil 95** es de aproximadamente **65,000 USD**.
- El **siniestro máximo registrado** en la cartera es de **310,000 USD**.

Esta desagregación revela una clara asimetría en los importes observados. **La severidad promedio (18,000 USD) duplica a la mediana empírica (9,000 USD)**, mientras que el máximo observado alcanza 310,000 USD. Estas tres cantidades muestran que la media, la posición central y los valores altos observados describen aspectos distintos de la cartera y que la media aritmética, por sí sola, no caracteriza su estructura completa.

La primera lección metodológica es fundamental: **una variable aleatoria es mucho más que su valor promedio**, y describir la severidad de un portafolio requiere un instrumental probabilístico robusto capaz de cartografiar la asimetría, la dispersión y el comportamiento de la cola del riesgo antes de que ocurra la próxima pérdida.

2.1.2 La probabilidad acumulada y la supervivencia describen los umbrales del contrato

Para estructurar la incertidumbre de la severidad, el actuario define formalmente la pérdida ground-up como una **variable aleatoria positiva** X con soporte en $[0, \infty)$. La herramienta fundamental para caracterizar probabilísticamente esta variable es la **Función de Distribución Acumulada (CDF)**, denotada como $F_X(x)$:

$$F_X(x) = P(X \leq x)$$

Para cualquier valor específico de pérdida x , la función $F_X(x)$ determina la **probabilidad o proporción acumulada** de siniestros cuyo costo ground-up es menor o igual a dicho umbral. Si X representa la severidad de la cartera, la CDF nos permite cuantificar la probabilidad de que un siniestro seleccionado al azar no supere un límite monetario definido.

Para el diseño de contratos de seguros y reaseguros, resulta igualmente indispensable medir el escenario opuesto: la probabilidad de que una pérdida exceda un determinado umbral. Para ello, se define la **función de supervivencia o de exceso** (en adelante, función de supervivencia), denotada estrictamente como $\bar{F}_X(x)$ para evitar cualquier confusión de notación con el costo agregado de la cartera (S_X):

$$\bar{F}_X(x) = P(X > x) = 1 - F_X(x)$$

La función de supervivencia describe con precisión matemática la probabilidad de que un siniestro sea un evento de cola que supere un umbral de cobertura, un punto de anclaje de reaseguro o un deducible. La relación de complementariedad entre la distribución acumulada y la supervivencia garantiza que la suma de ambas proporciones en cualquier punto del soporte sea exactamente igual a la unidad:

$$F_X(x) + \bar{F}_X(x) = 1$$

En términos prácticos, esta estructura permite separar la siniestralidad de una cartera en dos grandes regiones respecto a cualquier deducible contractual d : la región de pérdidas eliminadas, cuya probabilidad acumulada es $F_X(d)$, y la región de pérdidas con pago positivo para el asegurador, cuya probabilidad de supervivencia es $\bar{F}_X(d)$.

2.1.3 El intervalo mide el evento y la probabilidad condicional cambia el denominador

Las cláusulas de los contratos de seguro comercial rara vez operan sobre un único punto del soporte de pérdidas. Con frecuencia, el actuario necesita calcular la proporción de siniestros que se ubicarán dentro de una capa o intervalo específico definido por un deducible a y un límite de cobertura b . La probabilidad de que una pérdida ground-up caiga estrictamente dentro de ese intervalo se expresa mediante la diferencia de sus funciones de distribución acumulada:

$$P(a < X \leq b) = F_X(b) - F_X(a) = \bar{F}_X(a) - \bar{F}_X(b)$$

Esta identidad matemática permite modelar eventos contractuales complejos como probabilidades sobre intervalos ordenados.

Consideremos la distribución empírica de las 720 reclamaciones registradas por Meridiano Seguros en 2024 para ilustrar esta mecánica probabilística:

- Exactamente **96 pérdidas** se ubicaron en el intervalo $0 < X \leq 2,500$ USD.
- Exactamente **288 pérdidas** se ubicaron en el intervalo $2,500 < X \leq 10,000$ USD.
- Exactamente **196 pérdidas** se ubicaron en el intervalo $10,000 < X \leq 25,000$ USD.
- Exactamente **87 pérdidas** se ubicaron en el intervalo $25,000 < X \leq 50,000$ USD.
- Exactamente **28 pérdidas** se ubicaron en el intervalo $50,000 < X \leq 77,500$ USD.
- Exactamente **25 pérdidas** fueron superiores a **77,500 USD**.

Si definimos el deducible base de la póliza en $d = 2,500$ USD, la probabilidad empírica de que una reclamación no supere este deducible (pérdida eliminada por contrato) es:

$$F_{\text{emp}}(2,500) = P_{\text{emp}}(X \leq 2,500) = \frac{96}{720} = 13.33\%$$

Por el contrario, la probabilidad empírica de supervivencia por encima del deducible (sinistros que generan pago positivo para la aseguradora directa) es:

$$\bar{F}_{\text{emp}}(2, 500) = P_{\text{emp}}(X > 2, 500) = \frac{624}{720} = 86.67 \%$$

Esta proporción de **86.67 %** corresponde exactamente a los **624 siniestros con pago bruto positivo** analizados en la Parte 1.

Para el cálculo de probabilidades sobre intervalos, si queremos determinar la probabilidad de que una reclamación ground-up se sitúe entre el deducible de 2,500 USD y un límite de reporte de 10,000 USD, aplicamos la diferencia acumulada:

$$P_{\text{emp}}(2, 500 < X \leq 10, 000) = F_{\text{emp}}(10, 000) - F_{\text{emp}}(2, 500) = \frac{96 + 288}{720} - \frac{96}{720} = \frac{288}{720} = 40.00 \%$$

Ahora bien, uno de los conceptos probabilísticos más críticos en la modelación de contratos y reaseguro es la **probabilidad condicional**, definida formalmente para dos eventos A y B como:

$$P(A | B) = \frac{P(A \cap B)}{P(B)} \quad \text{si } P(B) > 0$$

En el contexto actuarial, la probabilidad condicional nos permite responder preguntas sobre siniestros que ya han superado un primer umbral contractual o deducible. Si deseamos estimar la probabilidad de que una reclamación supere los 50,000 USD (evento de cola extrema) *dado que ya ha superado los 10,000 USD* (umbral de siniestro grande), el condicionamiento altera estructuralmente el denominador de la probabilidad:

$$P_{\text{emp}}(X > 50, 000 | X > 10, 000) = \frac{P_{\text{emp}}(X > 50, 000 \cap X > 10, 000)}{P_{\text{emp}}(X > 10, 000)} = \frac{P_{\text{emp}}(X > 50, 000)}{P_{\text{emp}}(X > 10, 000)}$$

A partir del desglose del dataset de 2024, calculamos los componentes:

- El número de reclamaciones superiores a 10,000 USD es: $196 + 87 + 28 + 25 = 336$.
- El número de reclamaciones superiores a 50,000 USD es: $28 + 25 = 53$.

Por lo tanto, la probabilidad condicional empírica es:

$$P_{\text{emp}}(X > 50,000 \mid X > 10,000) = \frac{53}{336} = 15.77\%$$

Este resultado demuestra que **el condicionamiento cambia el universo de análisis**. Mientras que de manera incondicional solo el 7.36 % (53/720) de todas las reclamaciones ground-up superan los 50,000 USD, entre aquellas que ya han rebasado el umbral de 10,000 USD, la proporción que alcanza la cola extrema se eleva significativamente al 15.77 %. Este cambio en el denominador es la base matemática sobre la que se construirá posteriormente el análisis de distribuciones de pago condicionadas a que una pérdida haya superado determinados umbrales.

2.1.4 Los percentiles marcan fronteras pero no describen el riesgo de cola

Cuando el actuario necesita identificar el tamaño que alcanzará un siniestro en escenarios adversos de baja probabilidad pero alta severidad, recurre a los **percentiles o cuantiles** de la distribución. Formalmente, para un nivel de probabilidad o nivel de confianza $p \in (0, 1)$, el percentil x_p se define como el menor valor en el soporte de pérdidas para el cual la probabilidad acumulada alcanza o supera a p :

$$x_p = F_X^{-1}(p) \quad \text{o, en general: } x_p = \inf\{x : F_X(x) \geq p\}$$

Económicamente, el percentil $x_{0.95}$ indica el umbral monetario de pérdida que no será superado por el 95 % de los siniestros de la cartera. El 5 % restante representará la región de pérdidas de cola extrema.

Para comprender la mecánica matemática de los percentiles empíricos sobre muestras finitas y evitar interpolaciones arbitrarias sobre el dataset general, se establece un laboratorio aritmético manual utilizando un **mini-case local y pedagógico** con $n = 10$ observaciones de siniestros ordenados de menor a mayor (valores expresados en miles de USD):

$$X = [1, 3, 7, 10, 10, 12, 16, 21, 30, 40]$$

Para calcular el percentil empírico de orden p sobre una muestra ordenada de tamaño n , adoptaremos en estos mini-casos una **regla de interpolación lineal** definida por la posición del percentil en el rango de los datos. Existen otras convenciones para cuantiles empíricos; aquí utilizaremos de forma consistente la siguiente:

$$\text{Posición: } Pos = 1 + p(n - 1)$$

Si definimos $i = \lfloor Pos \rfloor$ como la parte entera de la posición y $g = Pos - i$ como la parte decimal, el percentil interpolado se calcula como:

$$x_p = x_{(i)} + g \cdot (x_{(i+1)} - x_{(i)})$$

Apliquemos esta regla al mini-case para dos niveles de confianza característicos:

1. Cálculo de la mediana empírica ($p = 0.50$):

- Posición: $Pos = 1 + 0.50(10 - 1) = 1 + 4.5 = 5.5$
- La posición está exactamente a la mitad entre la observación 5 ($x_{(5)} = 10$) y la observación 6 ($x_{(6)} = 12$).
- Mediana: $x_{0.50} = x_{(5)} + 0.5 \cdot (x_{(6)} - x_{(5)}) = 10 + 0.5 \cdot (12 - 10) = 11.00$ mil USD (11,000 USD).

2. Cálculo del percentil 90 empírico ($p = 0.90$):

- Posición: $Pos = 1 + 0.90(10 - 1) = 1 + 8.1 = 9.1$
- La posición se ubica entre la observación 9 ($x_{(9)} = 30$) y la observación 10 ($x_{(10)} = 40$).
- Percentil 90: $x_{0.90} = x_{(9)} + 0.1 \cdot (x_{(10)} - x_{(9)}) = 30 + 0.1 \cdot (40 - 30) = 31.00$ mil USD (31,000 USD).

El contraste entre la mediana local (11.00 mil USD) y el percentil 90 local (31.00 mil USD) ilustra de forma transparente cómo los percentiles marcan fronteras de control en el soporte del riesgo. Sin embargo, Irene advierte sobre un límite conceptual crítico de estas métricas: **el percentil solo actúa como una frontera o puerta de entrada a la cola**. Saber que el percentil 90 es de 31,000 USD nos dice qué probabilidad hay de cruzar esa línea, pero no nos proporciona ninguna información sobre la severidad promedio de las pérdidas una vez que se ha cruzado dicha frontera. Para medir la masa y la forma de la distribución alrededor de su centro y en la cola, el actuario necesita complementar los percentiles con la teoría de momentos.

2.1.5 Los momentos resumen la forma de la incertidumbre en unidades físicas y cuadráticas

Los momentos son operadores matemáticos que resumen las propiedades estructurales de una variable aleatoria de pérdida a través de su valor esperado. Se define el **momento ordinario de orden k** (respecto al origen), denotado como μ'_k , como la esperanza matemática de la variable de pérdida elevada a la potencia k :

$$\mu'_k = E[X^k]$$

Para variables continuas con función de densidad $f_X(x)$, este momento se calcula como la integral:

$$E[X^k] = \int_0^{\infty} x^k f_X(x) dx$$

Esta expresión representa un momento finito solo cuando la integral correspondiente converge. Escribir $E[X^k]$ no garantiza por sí mismo que ese momento exista como cantidad finita; el tratamiento completo de esa cuestión quedará para la sección de medidas de riesgo.

El primer momento ordinario ($k = 1$) corresponde a la **esperanza matemática o severidad media teórica** de la distribución, denotada como $E[X]$ o μ'_1 . Representa el costo promedio a largo plazo que la aseguradora espera financiar por cada reclamación ground-up.

Para medir la dispersión o volatilidad del riesgo, se definen los **momentos centrales**, que miden las desviaciones respecto de la media teórica. El momento central de orden k se denota como μ_k :

$$\mu_k = E[(X - E[X])^k]$$

El segundo momento central ($k = 2$) corresponde a la **varianza teórica**, denotada como $Var(X)$ o μ_2 , y representa la dispersión cuadrática de las pérdidas alrededor de la media. Se calcula operativamente mediante la relación fundamental de momentos:

$$Var(X) = E[X^2] - (E[X])^2$$

Debido a que la varianza acumula desviaciones elevadas al cuadrado, sus unidades físicas se expresan en de forma cuadrática: si la pérdida original X se mide en **USD**, la varianza se mide en **USD**². Para devolver la métrica a las unidades físicas originales de la pérdida y facilitar su interpretación financiera, se define la **desviación estándar** como la raíz cuadrada de la varianza:

$$SD(X) = \sqrt{Var(X)}$$

La varianza posee propiedades algebraicas indispensables para el de modelado de carteras, mientras que la desviación estándar es directamente comparable con la media en términos monetarios.

Para consolidar la práctica de estas métricas, se realiza el cálculo formal paso a paso utilizando el mismo mini-case local de diez observaciones (con valores expresados en miles de USD y una media empírica de exactamente **15.00 mil USD**, es decir, 15,000 USD). Para estos cálculos tratamos las diez observaciones como una distribución empírica que asigna peso $1/10$ a cada valor; por ello utilizaremos E_{emp} , Var_{emp} y SD_{emp} , con divisor n :

1. **Cálculo del segundo momento ordinario empírico ($E_{\text{emp}}[X^2]$):**

$$\sum_{i=1}^{10} X_i^2 = 1^2 + 3^2 + 7^2 + 10^2 + 10^2 + 12^2 + 16^2 + 21^2 + 30^2 + 40^2$$

$$\sum_{i=1}^{10} X_i^2 = 1 + 9 + 49 + 100 + 100 + 144 + 256 + 441 + 900 + 1600 = 3600 \text{ (mil USD)}^2$$

$$E_{\text{emp}}[X^2] = \frac{3600}{10} = 360.00 \text{ (mil USD)}^2$$

2. **Cálculo de la varianza empírica local ($Var_{\text{emp}}(X)$):**

$$Var_{\text{emp}}(X) = E_{\text{emp}}[X^2] - (E_{\text{emp}}[X])^2 = 360.00 - (15.00)^2 = 360.00 - 225.00 = 135.00 \text{ (mil USD)}^2$$

3. **Cálculo de la desviación estándar empírica local ($SD_{\text{emp}}(X)$):**

$$SD_{\text{emp}}(X) = \sqrt{135.00} \approx 11.62 \text{ mil USD} \quad (11,620 \text{ USD})$$

Los momentos responden a reglas de transformación matemática muy específicas ante cambios de escala o traslaciones del riesgo, lo que resulta fundamental para modelar la inflación y los límites contractuales:

- **Propiedad de escala (multiplicación por constante $c > 0$):**

$$E[cX] = cE[X] \quad \text{y} \quad Var(cX) = c^2 Var(X)$$

Si multiplicamos todas las reclamaciones por un factor de escala de 1.20 (inflación del 20 %), la severidad media aumentará un 20 %, pero **la varianza aumentará un 44 %** ($1.20^2 = 1.44$), reflejando el crecimiento cuadrático de la volatilidad absoluta. La desviación estándar conservará la proporcionalidad lineal: $SD(cX) = cSD(X)$.

- **Propiedad de traslación (adición de constante a):**

$$E[X + a] = E[X] + a \quad \text{y} \quad Var(X + a) = Var(X)$$

Si sumamos un cargo fijo uniforme de 2.00 mil USD a cada siniestro (traslación), la media se desplazará linealmente hacia arriba, pero **la varianza permanecerá exactamente igual** ($135.00 \text{ (mil USD)}^2$), debido a que añadir una cantidad cierta a todos los outcomes no altera la dispersión de los datos alrededor del nuevo centro.

2.1.6 El valor observado en el mundo no es la distribución teórica del actuario

Para finalizar la caracterización de los momentos de la severidad, es crucial resolver un conflicto de interpretación conceptual: **dos conjuntos de pérdidas pueden compartir exactamente la misma media y, sin embargo, presentar dispersiones radicalmente distintas.**

Para demostrarlo cuantitativamente, diseñamos un contraste utilizando dos **mini-datasets locales y no canónicos** de tamaño $n = 5$ (valores en miles de USD) que comparten exactamente la misma media aritmética de **15.00 mil USD**:

- **Dataset A (Altamente concentrado):** $Y_A = [12, 14, 15, 16, 18]$
- **Dataset B (Altamente disperso):** $Y_B = [2, 5, 15, 25, 28]$

Procedamos a auditar sus momentos y varianzas:

1. Análisis del Dataset A:

- Suma: $\sum Y_{Ai} = 12 + 14 + 15 + 16 + 18 = 75.00 \Rightarrow$ Media: $\bar{y}_A = 15.00$ mil USD
- Suma de cuadrados: $\sum Y_{Ai}^2 = 12^2 + 14^2 + 15^2 + 16^2 + 18^2 = 144 + 196 + 225 + 256 + 324 = 1145$
- Segundo momento empírico: $E_{\text{emp}}[Y_A^2] = 1145/5 = 229.00$ (mil USD)²
- Varianza empírica: $Var_{\text{emp}}(Y_A) = 229.00 - 15^2 = 229.00 - 225.00 = 4.00$ (mil USD)²
- Desviación estándar empírica: $SD_{\text{emp}}(Y_A) = 2.00$ mil USD (2,000 USD).

2. Análisis del Dataset B:

- Suma: $\sum Y_{Bi} = 2 + 5 + 15 + 25 + 28 = 75.00 \Rightarrow$ Media: $\bar{y}_B = 15.00$ mil USD
- Suma de cuadrados: $\sum Y_{Bi}^2 = 2^2 + 5^2 + 15^2 + 25^2 + 28^2 = 4 + 25 + 225 + 625 + 784 = 1663$
- Segundo momento empírico: $E_{\text{emp}}[Y_B^2] = 1663/5 = 332.60$ (mil USD)²
- Varianza empírica: $Var_{\text{emp}}(Y_B) = 332.60 - 225.00 = 107.60$ (mil USD)²
- Desviación estándar empírica: $SD_{\text{emp}}(Y_B) \approx 10.37$ mil USD (10,370 USD).

Este contraste revela la esencia del análisis de momentos. **Ambos datasets tienen exactamente la misma media aritmética (15.00 mil USD), pero su dispersión es completamente diferente.** El Dataset A se concentra estrechamente alrededor de su media con una desviación estándar de apenas 2,000 USD. El Dataset B presenta una desviación estándar de 10,370 USD y contiene observaciones mucho más alejadas del centro. Eso es lo que los cálculos demuestran; atribuir probabilidades futuras a esos valores requeriría un modelo probabilístico adicional.

Finalmente, es obligatorio trazar una divisoria intelectual entre las cantidades empíricas y teóricas:

- **Las cantidades empíricas (o muestrales)**, como la media aritmética de la cartera (18,000 USD) o la proporción empírica de reclamaciones en o por debajo de 2,500 USD (13.33 %), son resúmenes calculados directamente a partir de datos históricos cerrados y conocidos.
- **Las cantidades teóricas (o de modelo)**, como la esperanza teórica $E[X]$ o la varianza teórica $Var(X)$, son propiedades de una variable aleatoria definida bajo un modelo probabilístico.

En la práctica actuarial, **el valor observado en el mundo (el dato empírico) no es la distribución teórica del actuario**. El dato empírico es una muestra finita generada por un proceso subyacente de riesgo. El siguiente paso será pasar de estas observaciones empíricas finitas a familias de distribuciones de probabilidad y estudiar qué papel desempeñan sus parámetros de escala y forma en la distribución completa.

Cierre y Puente Final

Al concluir este capítulo, regresamos al problema que dio origen a la discusión de esta sección. Al inicio, la afirmación de que la severidad promedio de Meridiano Seguros era de 18,000 USD parecía agotar el análisis descriptivo del portafolio. Al término de esta sección, disponemos de la precisión conceptual y matemática para reconocer que esa cifra representa únicamente la media de una distribución asimétrica compleja. Sabemos ahora que la mediana empírica observada es de aproximadamente 9,000 USD; que el percentil 90 empírico observado es de aproximadamente 42,000 USD; y que, dentro del dataset 2024, si restringimos nuestro análisis al subconjunto de reclamaciones que ya han rebasado los 10,000 USD, la proporción condicional empírica de siniestros superiores a 50,000 USD es de 15.77 %.

La conclusión de todo lo desarrollado es definitiva: **ningún resumen individual -ni la media, ni la varianza, ni un percentil de cola- puede describir por sí mismo toda la incertidumbre de una variable aleatoria de pérdida**. Cada métrica responde a una pregunta actuarial diferente y coordinada.

Hemos aprendido a definir y calcular estas características descriptivas sobre observaciones empíricas finitas. Sin embargo, estas cantidades todavía no nos dicen qué distribución completa puede producirlas. Para avanzar en la modelación, necesitamos estudiar cómo la variación de los parámetros de escala (*scale*) y de forma (*shape*) altera una distribución de severidad y cómo distintas familias pueden representar comportamientos diferentes aun cuando compartan el mismo promedio. Este desafío abre camino directamente a la **Section 2.2 - Severity Models**.

Ejercicios

Ejercicio 1 - Probabilidad de intervalo y condicional empírica

Una cartera de seguros comerciales registra un historial completamente desarrollado de exactamente **1,000 reclamaciones de severidad ground-up**. La distribución empírica de las reclamaciones se agrupa en las siguientes categorías de importes:

- Pérdidas menores o iguales a 5,000 USD: **250 reclamaciones**.
- Pérdidas entre 5,000 y 20,000 USD (inclusive el extremo superior): **450 reclamaciones**.
- Pérdidas entre 20,000 y 100,000 USD (inclusive el extremo superior): **200 reclamaciones**.
- Pérdidas estrictamente superiores a 100,000 USD: **100 reclamaciones**.

1. Calcule la probabilidad acumulada empírica de que un siniestro sea menor o igual a 20,000 USD ($F_{\text{emp}}(20,000)$).
2. Calcule la probabilidad empírica de supervivencia por encima de 5,000 USD ($\bar{F}_{\text{emp}}(5,000)$).
3. Calcule la probabilidad empírica de que una pérdida se sitúe estrictamente en el intervalo entre 5,000 USD y 100,000 USD ($P_{\text{emp}}(5,000 < X \leq 100,000)$).

4. Dado que una reclamación ya ha superado el umbral de 20,000 USD, calcule la probabilidad condicional empírica de que sea un siniestro de cola extrema superior a 100,000 USD ($P_{\text{emp}}(X > 100,000 \mid X > 20,000)$). Explique detalladamente cómo se modifica el denominador en este cálculo.
5. Para cada una de las cuatro cantidades calculadas, escriba una frase breve que interprete actuarialmente qué proporción empírica está midiendo.

Criterio de éxito para la solución:

- $F_{\text{emp}}(20,000) = (250 + 450)/1000 = 70.00\%$ de los siniestros acumulados.
- $\bar{F}_{\text{emp}}(5,000) = 1 - F_{\text{emp}}(5,000) = 1 - (250/1000) = 75.00\%$.
- $P_{\text{emp}}(5,000 < X \leq 100,000) = F_{\text{emp}}(100,000) - F_{\text{emp}}(5,000) = (250 + 450 + 200)/1000 - 250/1000 = 65.00\%$.
- Siniestros superiores a 20,000 USD: $200+100 = 300$ reclamaciones (nuevo denominador condicional). Siniestros superiores a 100,000 USD: 100 reclamaciones. Probabilidad condicional: $100/300 = 33.33\%$. El condicionamiento restringe el universo de análisis únicamente a las 300 reclamaciones excedentes, elevando la probabilidad de pérdida extrema respecto al valor incondicional de 10.00%.

Ejercicio 2 - Percentiles empíricos mediante interpolación lineal

Un actuario extrae una muestra aleatoria de **12 reclamaciones de severidad ground-up** correspondientes a una línea de negocio (importes ordenados de menor a mayor, expresados en miles de USD):

$$X = [2, 4, 5, 8, 9, 11, 13, 15, 20, 25, 32, 50]$$

1. Identifique el tamaño de la muestra n y plantee la fórmula para la posición del percentil empírico de orden p (Pos).

2. Calcule el valor de la mediana empírica de la muestra ($x_{0.50}$) utilizando la regla de interpolación lineal.
3. Calcule el valor del percentil 85 empírico de la muestra ($x_{0.85}$).
4. Explique por qué un percentil no proporciona información sobre la severidad esperada en el peor 15 % de los siniestros de la muestra una vez superada la frontera del percentil 85.

Criterio de éxito para la solución:

- $n = 12$. Fórmula de posición: $Pos = 1 + p(11)$.
- Para la mediana ($p = 0.50$): $Pos = 1 + 0.50(11) = 6.5$. Se ubica entre la observación 6 ($x_{(6)} = 11$) y la observación 7 ($x_{(7)} = 13$). Mediana interpolada: $11 + 0.5(13 - 11) = 12.00$ mil USD (12,000 USD).
- Para el percentil 85 ($p = 0.85$): $Pos = 1 + 0.85(11) = 1 + 9.35 = 10.35$. Se ubica entre la observación 10 ($x_{(10)} = 25$) y la observación 11 ($x_{(11)} = 32$). Percentil 85 interpolado: $25 + 0.35(32 - 25) = 25 + 0.35(7) = 27.45$ mil USD (27,450 USD).
- El percentil 85 identifica estrictamente la frontera monetaria (27.45 mil USD) por debajo de la cual se sitúa el 85 % de las observaciones. No mide la magnitud de los siniestros restantes en la cola (los cuales pueden alcanzar valores extremos como 50 mil USD sin afectar el valor del percentil mismo).

Ejercicio 3 - Momentos con la misma media y distinta dispersión

Se dispone de dos muestras de **5 siniestros individuales** cada una, con valores expresados en miles de USD:

- **Dataset A:** $Y_A = [12, 14, 15, 16, 18]$
- **Dataset B:** $Y_B = [2, 5, 15, 25, 28]$

1. Calcule el primer momento ordinario empírico de cada dataset y verifique que ambos tienen media de exactamente 15.00 mil USD.
2. Calcule el segundo momento ordinario empírico de cada dataset.
3. Calcule la varianza empírica y la desviación estándar empírica de cada dataset, especificando las unidades físicas de cada resultado.
4. Compare los resultados y explique qué información sobre la dispersión aporta el segundo momento, la varianza y la desviación estándar que no proporciona la media común de 15.00 mil USD.

Criterio de éxito para la solución:

- Para ambos datasets, el primer momento ordinario empírico es $E_{\text{emp}}[Y_A] = E_{\text{emp}}[Y_B] = 15.00$ mil USD.
- Dataset A: $E_{\text{emp}}[Y_A^2] = 229.00 (\text{mil USD})^2$, $Var_{\text{emp}}(Y_A) = 4.00 (\text{mil USD})^2$ y $SD_{\text{emp}}(Y_A) = 2.00$ mil USD.
- Dataset B: $E_{\text{emp}}[Y_B^2] = 332.60 (\text{mil USD})^2$, $Var_{\text{emp}}(Y_B) = 107.60 (\text{mil USD})^2$ y $SD_{\text{emp}}(Y_B) \approx 10.37$ mil USD.
- La media común no distingue la dispersión de los dos datasets. El Dataset B tiene un segundo momento y una varianza mucho mayores, y su desviación estándar muestra en las unidades originales que sus observaciones están mucho más dispersas alrededor del mismo centro.

2.2 - Severity Models

Dos distribuciones con la misma media pueden describir riesgos completamente distintos

2.2.1 Dos candidatos que comparten la media pueden esconder colas opuestas

En el diseño de tarifas y en la evaluación del capital de solvencia para una cartera de seguros de daños comerciales como la de Meridiano Seguros, la práctica habitual de resumir la experiencia siniestral a través de un promedio aritmético constituye un peligroso simplismo. Imaginemos que **Lucía**, en su rol de pricing actuary, presenta ante el comité técnico de Meridiano dos modelos probabilísticos continuos candidatos para modelar la severidad ground-up de las reclamaciones de propiedad comercial del Accident Year 2024.

Antes de comparar los modelos conviene separar datos de modelo. En el portfolio empírico de Meridiano, la media observada es $\bar{x} = 18,000$ USD, la mediana observada es aproximadamente 9,000 USD, el percentil 90 observado es aproximadamente 42,000 USD y el percentil 95 observado es aproximadamente 65,000 USD. Los dos modelos que Lucía presenta no han sido demostrados como ajustes estadísticos de esos datos: son **modelos candidatos pedagógicos** escogidos deliberadamente para que su media teórica satisfaga $E[X] = 18,000$ USD. La estimación y validación formal de parámetros pertenece a Part 3.

Con esa distinción establecida, Lucía destaca una coincidencia notable entre las quantities derivadas de los dos modelos:

- El **Modelo A** tiene media teórica de **18,000 USD** y percentil 95 teórico de aproximadamente **62,420 USD**.
- El **Modelo B** tiene media teórica de **18,000 USD** y percentil 95 teórico de aproximadamente **62,701 USD**.

¿Hay alguna razón importante para preferir uno sobre otro si ambos tienen exactamente la misma media teórica y prácticamente el mismo percentil 95? Ante esta aparente simetría, Lucía plantea que, para fines prácticos, ambos modelos podrían describir perfiles de riesgo casi equivalentes. Sin embargo, **Irene**, chief actuary de la compañía, interviene de inmediato con su habitual rigor: «*Ambas curvas lucen idénticas cuando nos limitamos a mirar el 95 % de la cartera, Lucía. Pero, ¿qué está ocurriendo más allá de esa frontera? Si ocurriera un*

sinistro de cola en el reaseguro de exceso de pérdida, ¿cuál de los dos modelos nos colocará al borde de la insolvencia?».

La advertencia de Irene se materializa cuando se compara la dispersión de ambos modelos:

- La desviación estándar teórica del Modelo A es de **31,177 USD**.
- La desviación estándar teórica del Modelo B asciende a **59,699 USD**, casi duplicando la del Modelo A.

Si sus percentiles 95 son casi idénticos, ¿esperaríamos también percentiles 99 prácticamente iguales? No. Al avanzar hacia esa zona de la cola, el Modelo A proyecta aproximadamente **139,253 USD**, mientras que el Modelo B alcanza aproximadamente **153,604 USD**.

Quantity teórica	Modelo A	Modelo B
Mean	18,000 USD	18,000 USD
Median	9,000 USD	≈ 8,000 USD
90th percentile	≈ 40,696 USD	≈ 39,918 USD
95th percentile	≈ 62,420 USD	≈ 62,701 USD
Standard deviation	≈ 31,177 USD	≈ 59,699 USD
99th percentile	≈ 139,253 USD	≈ 153,604 USD

¿Cómo puede haber tanta diferencia en dispersión cuando la media, la mediana y el percentil 95 parecen tan próximos? Solo después de plantear ese contraste revelamos las familias. Detrás del Modelo A se encuentra una distribución **Lognormal**, un modelo con soporte positivo cuya cola decae más rápidamente en términos relativos; detrás del Modelo B se sitúa una distribución **Lomax** (también conocida en la literatura actuarial como **Pareto Tipo II**), caracterizada por un decaimiento polinomial lento y por la posible no existencia de momentos de orden superior, dependiendo de su parámetro de forma.

Este contraste expone una verdad fundamental del modelado actuarial de severidad: **una media y algunos percentiles semejantes no determinan el comportamiento completo de la cola**. La tarea del actuario, por tanto, no consiste en buscar una curva que

simplemente reproduzca una media observada, sino en comprender cómo la interacción entre los parámetros de escala y forma gobierna la distribución de probabilidad en todo el soporte del riesgo.

2.2.2 El parámetro de escala expande la dimensión monetaria sin alterar la forma relativa

Para estructurar formalmente una familia paramétrica de severidad, el actuario debe distinguir el papel de dos tipos de parámetros: el parámetro de escala (*scale*) y el parámetro de forma (*shape*).

¿Qué tipo de parámetro necesitamos si queremos que todas las pérdidas sean, en cierto sentido, más grandes o más pequeñas sin cambiar la forma relativa del riesgo? Esa es la función de un **parámetro de escala**. Si X representa la variable aleatoria ground-up de severidad y realizamos un cambio multiplicativo mediante una constante positiva $c > 0$, la nueva variable transformada es:

$$Y = cX.$$

La función de distribución acumulada de la variable escalada Y se relaciona directamente con la de la variable original mediante la identidad:

$$F_Y(y) = P(Y \leq y) = P(cX \leq y) = P\left(X \leq \frac{y}{c}\right) = F_X\left(\frac{y}{c}\right).$$

De manera correspondiente, para las funciones de densidad y supervivencia, el cambio de escala se transmite como:

$$f_Y(y) = \frac{1}{c} f_X\left(\frac{y}{c}\right) \quad \text{y} \quad \bar{F}_Y(y) = \bar{F}_X\left(\frac{y}{c}\right).$$

Económicamente, esta transformación implica que todos los percentiles de la distribución se escalan linealmente con c :

$$y_p = cx_p.$$

Antes de sustituir números, anticipe el efecto de $Y = 1.20X$: ¿qué ocurre con la media, el percentil 95, la desviación estándar y la varianza? Las tres primeras quantities se multiplican por 1.20; la varianza se multiplica por $1.20^2 = 1.44$.

En lo que respecta a los momentos:

$$E[Y] = E[cX] = cE[X],$$

$$SD(Y) = SD(cX) = cSD(X),$$

$$Var(Y) = Var(cX) = c^2Var(X).$$

La propiedad analítica más relevante de un cambio de escala puro es que **las medidas adimensionales de dispersión relativa permanecen constantes**. El coeficiente de variación (CV), definido como la relación entre la desviación estándar y la media, no experimenta alteración alguna:

$$CV(Y) = \frac{SD(Y)}{E[Y]} = \frac{cSD(X)}{cE[X]} = CV(X).$$

De la misma manera, la relación entre cualquier percentil alto y la mediana permanece invariante:

$$\frac{y_p}{y_{0.50}} = \frac{cx_p}{cx_{0.50}} = \frac{x_p}{x_{0.50}}.$$

Si todos los claims se multiplicaran por 2, ¿cambiaría P_{95}/P_{50} ? No: numerador y denominador se multiplicarían por el mismo factor.

Scale tampoco significa sumar una constante. Las transformaciones

$$Y = cX$$

y

$$Y = X + a$$

son distintas: la primera es un cambio multiplicativo de escala; la segunda es un desplazamiento aditivo. No deben tratarse como operaciones equivalentes solo porque ambas puedan aumentar los importes monetarios.

En las familias de distribuciones actuariales continuas, el parámetro de escala puede identificarse de forma especialmente directa en Lomax. Si

$$X \sim Lomax(\alpha, \theta),$$

el parámetro θ actúa como escala monetaria. Si definimos $Y = cX$, la variable transformada sigue perteneciendo a la misma familia, conserva α y modifica la escala a $c\theta$:

$$Y \sim Lomax(\alpha, c\theta).$$

El modelo Lomax canónico permite ejecutar el experimento completo. Partimos de $\alpha = 2.2$, $\theta = 21,600$ USD, $E[X] = 18,000$ USD, $SD(X) \approx 59,699$ USD, $Var(X) = 3,564,000,000$ USD², $P_{50} \approx 8,000$ USD y $P_{95} \approx 62,701$ USD. Si $Y = 1.20X$, la forma permanece fija y la nueva escala es:

$$\theta' = 1.20(21,600) = 25,920 \text{ USD.}$$

Por tanto:

$$E[Y] = 1.20(18,000) = 21,600 \text{ USD,}$$

$$SD(Y) \approx 1.20(59,699) = 71,639 \text{ USD},$$

$$Var(Y) = 1.20^2(3,564,000,000) = 5,132,160,000 \text{ USD}^2,$$

$$P_{50}(Y) \approx 1.20(8,000) = 9,600 \text{ USD},$$

$$P_{95}(Y) \approx 1.20(62,701) = 75,241 \text{ USD}.$$

La varianza aumenta un 44.00 %, mientras que el ratio adimensional permanece, salvo redondeo, en el mismo nivel:

$$\frac{P_{95}(Y)}{P_{50}(Y)} \approx \frac{75,241}{9,600} \approx 7.84,$$

frente a

$$\frac{P_{95}(X)}{P_{50}(X)} \approx \frac{62,701}{8,000} \approx 7.84.$$

En la distribución Lognormal, la escala no se visualiza mediante un parámetro multiplicador directo en su densidad, sino a través de una transformación exponencial. Si $\ln X \sim Normal(\mu, \sigma^2)$, al aplicar $Y = cX$ se tiene:

$$\ln Y = \ln c + \ln X.$$

Dado que $\ln X$ sigue una distribución Normal, añadir la constante $\ln c$ desplaza la media de la Normal sin alterar su varianza:

$$\ln Y \sim Normal(\mu + \ln c, \sigma^2) \Rightarrow Y \sim Lognormal(\mu + \ln c, \sigma^2).$$

El parámetro μ funciona así como un parámetro de localización en escala logarítmica que absorbe el cambio de escala monetaria, mientras σ permanece fijo.

2.2.3 El parámetro de forma esculpe la asimetría y el espesor de la cola

A diferencia de la escala, el **parámetro de forma** (*shape*) es una cantidad adimensional que modifica la geometría interna de la distribución de probabilidad. Su alteración no representa un mero cambio en las unidades de medida o en el volumen de los siniestros, sino una redistribución de la masa de probabilidad entre el cuerpo central de la distribución y su cola extrema.

Un parámetro de forma puede alterar:

- La asimetría (*skewness*) y la pesadez relativa de la cola.
- El coeficiente de variación y los ratios adimensionales de percentiles (P_p/P_{50}).
- La velocidad de decaimiento de la supervivencia ($\bar{F}_X(x)$).
- En ciertas familias, la existencia de momentos de orden superior.

No todos los parámetros de forma modifican todas estas propiedades de la misma manera. La interpretación depende de la familia y de qué otros parámetros se mantienen fijos. Para la distribución Lognormal, σ -la desviación estándar en escala logarítmica- actúa como parámetro de forma. Para la distribución Lomax, ese papel queda gobernado por α .

Un principio metodológico crucial es que **el análisis del impacto de la forma exige declarar qué quantity se mantiene fija**. Si un actuario modifica de manera aislada α en Lomax o σ en Lognormal sin ajustar otro parámetro, la media también puede cambiar.

¿Podemos aumentar σ en una Lognormal y mantener la media teórica exactamente en 18,000 USD dejando μ sin cambios? No. Para que la comparación de forma sea interpretable, debemos compensar el otro parámetro.

- **Para la distribución Lognormal:** La media teórica es

$$E[X] = \exp\left(\mu + \frac{\sigma^2}{2}\right).$$

Si queremos cambiar σ a σ' manteniendo la media constante en un nivel M , el parámetro de localización logarítmica debe convertirse en:

$$\mu' = \ln(M) - \frac{(\sigma')^2}{2}.$$

- **Para la distribución Lomax:** Para $\alpha > 1$,

$$E[X] = \frac{\theta}{\alpha - 1}.$$

Si modificamos el parámetro de forma de α a α' y queremos mantener la media en M , debemos ajustar simultáneamente la escala:

$$\theta' = M(\alpha' - 1).$$

El experimento aprobado con la Lognormal canónica hace visible la diferencia entre scale y shape. El caso base utiliza

$$\sigma = \sqrt{2 \ln 2} \approx 1.1774, \quad \mu = \ln(9,000),$$

con $E[X] = 18,000$ USD, $SD(X) \approx 31,177$ USD, $CV(X) \approx 1.73$, $P_{50} = 9,000$ USD y $P_{95} \approx 62,420$ USD. Ahora incrementamos la forma a

$$\sigma' = 1.30$$

manteniendo fija la media teórica de 18,000 USD. El ajuste requerido es:

$$\mu' = \ln(18,000) - \frac{1.30^2}{2} \approx 9.798127 - 0.845 \approx 8.953127.$$

Con estos parámetros:

$$E[X'] = 18,000 \text{ USD},$$

$$Var(X') = (e^{1.69} - 1)(18,000)^2 \approx 1,431,911,748 \text{ USD}^2,$$

$$SD(X') \approx 37,840.61 \text{ USD},$$

$$CV(X') \approx \frac{37,840.61}{18,000} \approx 2.10,$$

$$P_{50}(X') = e^{\mu'} \approx 7,732.03 \text{ USD},$$

$$P_{95}(X') = \exp(\mu' + 1.30 \times 1.64485) \approx 65,606.63 \text{ USD}.$$

El ratio también cambia:

$$\frac{P_{95}(X')}{P_{50}(X')} \approx \frac{65,606.63}{7,732.03} \approx 8.49,$$

frente a aproximadamente 6.94 en el modelo base. Aquí la media sigue siendo 18,000 USD, pero la mediana cae, el percentil 95 sube y la dispersión relativa aumenta. Eso es un cambio de forma, no un simple cambio de escala.

2.2.4 Lognormal y Lomax revelan la divergencia invisible en la cola extrema

Para modelar las pérdidas ground-up de Meridiano Seguros, Lucía analiza formalmente las propiedades analíticas y los resultados numéricos de los dos modelos candidatos construidos

deliberadamente para compartir una media teórica de 18,000 USD. Esta coincidencia con la media empírica de 2024 no constituye evidencia de fitting o validación estadística.

Modelo A: Distribución Lognormal (Cola moderadamente pesada)

La variable X sigue una distribución Lognormal con parámetros congelados:

$$\mu = \ln(9,000) \approx 9.10498 \quad \text{y} \quad \sigma = \sqrt{2 \ln 2} \approx 1.17741$$

La función de densidad de probabilidad (PDF) teórica está dada por:

$$f_X(x) = \frac{1}{x\sigma\sqrt{2\pi}} \exp\left(-\frac{(\ln x - \mu)^2}{2\sigma^2}\right) \quad \text{para } x > 0$$

Al aplicar las fórmulas de momentos y percentiles específicos de la Lognormal, se obtienen las siguientes características teóricas exactas:

- **Media Teórica ($E[X]$):**

$$E[X] = \exp\left(\mu + \frac{\sigma^2}{2}\right) = \exp(\ln(9,000) + \ln 2) = 9,000 \times 2 = 18,000 \text{ USD}$$

- **Varianza Teórica ($Var(X)$):**

$$Var(X) = (e^{\sigma^2} - 1) \exp(2\mu + \sigma^2) = (e^{2 \ln 2} - 1) \exp(2 \ln(9,000) + 2 \ln 2)$$

$$Var(X) = (4 - 1) \times 9,000^2 \times 4 = 3 \times 324,000,000 = 972,000,000 \text{ USD}^2$$

- **Desviación Estándar ($SD(X)$):**

$$SD(X) = \sqrt{972,000,000} \approx 31,177 \text{ USD}$$

■ **Percentil 50 % (Mediana):**

$$x_{0.50} = e^\mu = e^{\ln(9,000)} = 9,000 \text{ USD}$$

- **Percentiles de cola teóricos:** Aplicando $x_p = \exp(\mu + \sigma z_p)$ con los cuantiles correspondientes de la Normal estándar, se obtienen:

- $P_{90} \approx 40,696 \text{ USD}$
- $P_{95} \approx 62,420 \text{ USD}$
- $P_{99} \approx 139,253 \text{ USD}$

En el Modelo A, todos los momentos ordinarios positivos $E[X^k]$ existen para cualquier $k > 0$, lo que indica que es posible calcular teóricamente cualquier momento de orden superior (asimetría, curtosis, etc.).

Modelo B: Distribución Lomax / Pareto Tipo II (Cola pesada)

La variable X se modela bajo una distribución Lomax con parámetros canónicos:

$$\alpha = 2.2 \quad \text{y} \quad \theta = 21,600 \text{ USD}$$

La función de supervivencia teórica que rige este modelo se define como:

$$\bar{F}_X(x) = \left(1 + \frac{x}{\theta}\right)^{-\alpha} = \left(1 + \frac{x}{21,600}\right)^{-2.2} \quad \text{para } x \geq 0$$

A partir de esta estructura, las propiedades analíticas del Modelo B se calculan como:

- **Media Teórica ($E[X]$):** Dado que $\alpha = 2.2 > 1$, el primer momento existe:

$$E[X] = \frac{\theta}{\alpha - 1} = \frac{21,600}{2.2 - 1} = \frac{21,600}{1.2} = 18,000 \text{ USD}$$

- **Varianza Teórica ($Var(X)$):** Dado que $\alpha = 2.2 > 2$, el segundo momento central es finito:

$$Var(X) = \frac{\theta^2 \alpha}{(\alpha - 1)^2 (\alpha - 2)} = \frac{21,600^2 \times 2.2}{(1.2)^2 \times 0.2} = \frac{466,560,000 \times 2.2}{0.288} = 3,564,000,000 \text{ USD}^2$$

- **Desviación Estándar ($SD(X)$):**

$$SD(X) = \sqrt{3,564,000,000} \approx 59,699 \text{ USD}$$

- **Percentiles teóricos:** Invirtiendo analíticamente la supervivencia, se tiene $x_p = \theta [(1 - p)^{-1/\alpha} - 1]$:
 - **Mediana:** $x_{0.50} = 21,600 \times [2^{1/2.2} - 1] \approx 21,600 \times [1.37035 - 1] = 7,999.56 \approx 8,000 \text{ USD}$
 - **Percentil 90:** $x_{0.90} = 21,600 \times [10^{1/2.2} - 1] \approx 21,600 \times [2.84804 - 1] \approx 39,918 \text{ USD}$
 - **Percentil 95:** $x_{0.95} = 21,600 \times [20^{1/2.2} - 1] \approx 21,600 \times [3.90282 - 1] \approx 62,701 \text{ USD}$
 - **Percentil 99:** $x_{0.99} = 21,600 \times [100^{1/2.2} - 1] \approx 21,600 \times [8.11130 - 1] \approx 153,604 \text{ USD}$

El comportamiento de los momentos en el Modelo B revela una restricción teórica de extrema relevancia: **los momentos ordinarios $E[X^k]$ existen únicamente si $k < \alpha$** . Dado que para este modelo $\alpha = 2.2$, la media ($k = 1 < 2.2$) y la varianza ($k = 2 < 2.2$) existen de forma finita, pero **el tercer momento ordinario es divergente (infinito)** (puesto que $3 > 2.2$).

En consecuencia, el coeficiente de asimetría teórico ordinario no está finitamente definido bajo esta parametrización, porque requiere un tercer momento finito. Aquí esta observación

funciona únicamente como puente: el tratamiento formal de la existencia de momentos se reserva para Section 2.6.

2.2.5 Las familias de distribuciones se entrelazan mediante transformaciones y límites

Si $\ln X$ sigue una distribución Normal, ¿qué familia sigue X en escala monetaria? Reconocer la respuesta exige pensar en una transformación, no en dos nombres de distribuciones sin relación.

Las clases de distribuciones continuas utilizadas para el modelado de severidad ground-up no se presentan de forma aislada, sino que se vinculan mediante transformaciones matemáticas rigurosas que facilitan su reconocimiento y estandarización analítica:

1. **Relación Normal-Lognormal (Transformación Logarítmica):** Si Z es una variable aleatoria con distribución $Normal(\mu, \sigma^2)$ sobre toda la recta real, la transformación exponencial $X = e^Z$ genera una variable aleatoria X estrictamente positiva con distribución $Lognormal(\mu, \sigma^2)$. Los percentiles se transforman directamente mediante la propiedad monótona exponencial $x_p = e^{z_p}$.
2. **Equivalencia Lomax-Pareto II:** La distribución Lomax es analíticamente idéntica a la distribución de Pareto Tipo II bajo soporte positivo $[0, \infty)$. Esta correspondencia es de gran importancia para que el actuario pueda identificar y unificar la nomenclatura de modelos de cola pesada en bases de datos y literatura técnica diversa.
3. **Conservación de Familia bajo Cambios de Escala:** La distribución Lomax es cerrada bajo transformaciones de escala pura. Si $X \sim Lomax(\alpha, \theta)$ y aplicamos un factor de escala monetaria $c > 0$, la nueva variable $Y = cX$ sigue perteneciendo de forma exacta a la familia Lomax con parámetros $Y \sim Lomax(\alpha, c\theta)$, lo que permite que el parámetro de forma α permanezca perfectamente aislado ante ajustes inflacionarios o conversiones de moneda.

Cierre y Puente Final

Al concluir este capítulo, disponemos de un marco de comparación sistemático para contrastar el comportamiento de los modelos continuos candidatos en Meridiano Seguros:

			Divergencia Relativa
Métrica /	Modelo A:	Modelo B: Lomax /	/ Explicación
Característica	Lognormal	Pareto Tipo II	Actuarial
Parámetro de Localización / Escala	$\mu = \ln(9,000) \approx 9.10498$	$\theta = 21,600 \text{ USD}$	Parámetros específicos de cada familia que determinan la escala monetaria base.
Parámetro de Forma	$\sigma = \sqrt{2 \ln 2} \approx 1.17741$	$\alpha = 2.2$	Parámetros adimensionales que controlan el espesor de la cola y la dispersión relativa.
Media Teórica ($E[X]$)	18,000 USD	18,000 USD	Coincidencia teórica deliberada: ambos modelos comparten la misma media esperada de pérdidas.
Desviación Estándar ($SD(X)$)	$\approx 31,177 \text{ USD}$	$\approx 59,699 \text{ USD}$	Divergencia de dispersión: Lomax incrementa la volatilidad absoluta en un 91.48 % frente a Lognormal.

Métrica / Característica	Modelo A: Lognormal	Modelo B: Lomax / Pareto Tipo II	Divergencia Relativa / Explicación
			Actuarial
Percentil 50 % (Mediana)	9,000 USD	≈ 8,000 USD	La mediana de Lomax es inferior, reflejando mayor concentración de siniestros ordinarios de tamaño pequeño.
Percentil 95 %	≈ 62,420 USD	≈ 62,701 USD	El punto de cruce de colas: Los percentiles difieren en apenas un 0.45 % , simulando un comportamiento idéntico.
Percentil 99 %	≈ 139,253 USD	≈ 153,604 USD	Divergencia extrema en la cola: En el percentil 99, Lomax supera a Lognormal por más de 14,350 USD (+10.31 %).

Existencia de Momentos ($E[X^k]$)	Todos los momentos existen	Existen únicamente momentos de orden $k < 2.2$	En Lomax, el tercer momento ordinario es divergente (infinito) , reflejando el decaimiento lento de su cola.
--	-----------------------------------	--	---

Este análisis sistemático corrobora la tesis central del capítulo: **ninguna modelación de severidad puede considerarse completa limitándose al estudio del centro de la distribución**. La media y la mediana describen aspectos distintos del centro, mientras que la desviación estándar, los percentiles altos y sus relaciones revelan diferencias de dispersión y cola gobernadas por la interacción de escala y forma.

Hemos aprendido a caracterizar estas propiedades sobre variables de severidad ground-up completas (X). Sin embargo, en la práctica aseguradora, Meridiano Seguros nunca financia las pérdidas a primer dólar: el contrato directo de seguro interpone deducibles, límites de cobertura y proporciones de coaseguro. **Esto nos exige dar el siguiente paso en la modelación y analizar detalladamente cómo la existencia de estas cláusulas contractuales transforma probabilísticamente las distribuciones continuas ground-up en distribuciones de pago bruto efectivo, abriendo paso directamente a la Section 2.3 - Severity Models with Coverage Modifications.**

Ejercicios

Ejercicio 1 - Propiedades de escala y transformaciones en Lomax

Supongamos que la severidad de pérdidas ground-up de una cartera es modelada bajo una distribución Lomax (Pareto Tipo II) con parámetros de forma $\alpha = 2.5$ y escala $\theta = 15,000$ USD.

1. Verifique si la media y la varianza teórica de esta distribución existen de forma finita bajo la condición de momentos.
2. Calcule la media teórica, la varianza y la desviación estándar de la distribución de severidad.
3. Calcule el percentil 50 % (mediana) y el percentil 95 % teóricos de esta distribución.
4. Asuma que toda la cartera de pérdidas ground-up experimenta una inflación de severidad del 20 % que actúa de manera multiplicativa ($Y = 1.20X$). Determine la nueva distribución del modelo indicando sus parámetros, y calcule la nueva media, la nueva desviación estándar y la relación de percentiles (P_{95}/P_{50}) de la variable escalada.

Criterio de éxito para la solución:

- $\alpha = 2.5 > 2$; por lo tanto, la media y la varianza son finitas ya que $k < \alpha$ para $k = 1, 2$.
- $E[X] = 15,000/(2.5 - 1) = 10,000$ USD.
- $Var(X) = \frac{15,000^2 \times 2.5}{(1.5)^2 \times 0.5} = 500,000,000 \text{ USD}^2 \Rightarrow SD(X) \approx 22,360.68$ USD.
- $x_{0.50} = 15,000 \times [2^{1/2.5} - 1] \approx 4,792.62$ USD; $x_{0.95} = 15,000 \times [20^{1/2.5} - 1] \approx 34,716.81$ USD.
- Bajo $Y = 1.20X$, la nueva distribución es $Lomax(2.5, \theta' = 18,000)$.
- $E[Y] = 1.20 \times 10,000 = 12,000$ USD; $SD(Y) = 1.20 \times 22,360.68 = 26,832.82$ USD; $Var(Y) = 1.20^2 \times 500,000,000 = 720,000,000 \text{ USD}^2$.
- $y_{0.50} = 1.20 \times 4,792.62 \approx 5,751.14$ USD; $y_{0.95} = 1.20 \times 34,716.81 \approx 41,660.17$ USD.
- Ratio $y_{0.95}/y_{0.50} = 41,660.17/5,751.14 \approx 7.24$ (permanece estrictamente idéntico al ratio original $34,716.81/4,792.62 \approx 7.24$), demostrando que la escala monetaria conserva las proporciones adimensionales de la distribución.

Ejercicio 2 - Modificación de forma con media teórica fija en Lognormal

Se dispone de un modelo inicial ground-up modelado mediante una distribución $X \sim \text{Lognormal}(\mu = 8.5, \sigma^2 = 1.00)$.

1. Calcule la media teórica, la desviación estándar y el coeficiente de variación (CV) de este modelo base.
2. Calcule el percentil 50 % (mediana), el percentil 95 % y la relación adimensional de percentiles (P_{95}/P_{50}) del modelo base.
3. Asuma que para modelar una mayor asimetría en la cartera, el actuario eleva el parámetro de forma de $\sigma = 1.00$ a $\sigma' = 1.20$. Calcule el nuevo parámetro μ' bajo la condición obligatoria de mantener la media teórica del portafolio perfectamente constante.
4. Calcule la nueva desviación estándar, el nuevo coeficiente de variación, la nueva mediana, el nuevo percentil 95 % y la nueva relación adimensional (P_{95}/P_{50}) del modelo con asimetría modificada. Explique físicamente el efecto de la forma sobre la concentración de masa de probabilidad.

Criterio de éxito para la solución:

- Media base $E[X] = \exp(8.5 + 0.5) = e^9 \approx 8,103.08$ USD.
- Varianza base $Var(X) = (e^1 - 1)e^{18} \approx 1.71828 \times 65,659,969.14 \approx 112,822,331.83$ USD² $\Rightarrow$ $SD(X) \approx 10,621.79$ USD. CV base $\approx 10,621.79/8,103.08 \approx 1.31$.
- Percentiles base: $x_{0.50} = e^{8.5} \approx 4,914.77$ USD; $x_{0.95} = \exp(8.5 + 1.64485) \approx 25,459.65$ USD. Ratio $P_{95}/P_{50} \approx 5.18$.
- Ajuste compensatorio de escala: $M = e^9$. $\mu' = 9 - (1.20^2)/2 = 9 - 0.72 = 8.28$.
- Nueva desviación estándar $SD(X') = \sqrt{(e^{1.44} - 1)e^{18}} = \sqrt{(4.22070 - 1)e^{18}} \approx \sqrt{3.22070 \times 65,659,969.14} \approx 14,542.04$ USD. Nuevo CV $\approx 14,542.04/8,103.08 \approx 1.79$ (refleja el aumento de volatilidad relativa).

- Nuevos percentiles: $y_{0.50} = e^{8.28} \approx 3,944.19$ USD (cae); $y_{0.95} = \exp(8.28 + 1.20 \times 1.64485) = e^{10.25382} \approx 28,390.79$ USD (sube). Nuevo ratio $y_{0.95}/y_{0.50} = 28,390.79/3,944.19 \approx 7.20$ (se incrementa desde 5.18).
- Explicación: Al elevar la asimetría y mantener la media fija, la masa de probabilidad se desplaza. Los siniestros ordinarios se vuelven más pequeños (la mediana disminuye de 4,914.77 a 3,944.19 USD), pero los siniestros extremos se expanden y se ensanchan considerablemente (el percentil 95 se eleva de 25,459.65 a 28,390.79 USD).

Ejercicio 3 - Comparación estructural de colas (Lognormal vs Lomax)

Se evalúan dos modelos de severidad continuos alternativos con idéntico costo promedio esperado $E[X] = 12,000$ USD para una cartera de seguros de propiedad:

- **Modelo A (Lognormal):** $\mu = \ln(6,000)$, $\sigma = \sqrt{2 \ln 2} \approx 1.1774$.
- **Modelo B (Lomax):** $\alpha = 2.5$, $\theta = 18,000$ USD.

1. Verifique analíticamente que ambos modelos cumplen exactamente con la media esperada de 12,000 USD.
2. Calcule y compare la desviación estándar de la pérdida ground-up bajo ambos candidatos.
3. Calcule el percentil 95 teórico bajo ambos modelos e indique la diferencia absoluta y porcentual entre sus estimaciones.
4. Calcule la relación adimensional P_{95}/P_{50} para cada modelo, identifique cuál presenta mayor dispersión relativa hacia la cola superior y explique por qué una misma media no implica el mismo perfil de severidad.

Criterio de éxito para la solución:

- $E[X_A] = \exp(\ln(6,000) + \ln 2) = 6,000 \times 2 = 12,000$ USD. $E[X_B] = 18,000/(2.5 - 1) = 12,000$ USD. Ambos tienen la media requerida.

- $SD(X_A) = \sqrt{(4-1) \times 6,000^2 \times 4} = \sqrt{432,000,000} \approx 20,784.61$ USD.
- $SD(X_B) = \sqrt{\frac{18,000^2 \times 2.5}{1.5^2 \times 0.5}} = \sqrt{720,000,000} \approx 26,832.82$ USD. El Modelo B presenta mayor dispersión absoluta.
- $P_{95}^{LN} = 6,000 \times e^{1.17741 \times 1.64485} \approx 41,613.40$ USD.
- $P_{95}^{Lomax} = 18,000 \times [20^{1/2.5} - 1] \approx 41,660.17$ USD.
- Diferencia absoluta de percentiles 95: $41,660.17 - 41,613.40 = 46.77$ USD, equivalente a aproximadamente 0.11 % respecto del percentil 95 Lognormal.
- Las medianas son $P_{50}^{LN} = 6,000$ USD y $P_{50}^{Lomax} = 18,000[2^{1/2.5} - 1] \approx 5,751.14$ USD. Por tanto:

$$\frac{P_{95}^{LN}}{P_{50}^{LN}} \approx \frac{41,613.40}{6,000} \approx 6.94,$$

$$\frac{P_{95}^{Lomax}}{P_{50}^{Lomax}} \approx \frac{41,660.17}{5,751.14} \approx 7.24.$$

- El Modelo B presenta mayor dispersión relativa hacia la cola superior: pese a compartir la misma media y un percentil 95 casi idéntico con el Modelo A, combina una desviación estándar mayor con un ratio P_{95}/P_{50} mayor. La igualdad de la media, por tanto, no determina la forma relativa de la distribución de severidad.

2.3 - Severity Models with Coverage Modifications

El contrato puede cambiar una distribución sin cambiar el riesgo que ocurrió

2.3.1 Dos promedios correctos revelan que el denominador determina el significado del pago

Al evaluar el desempeño financiero y estimar la prima pura de una cartera de seguros de daños como la de **Meridiano Seguros**, los actuarios suelen iniciar su análisis comparando magnitudes globales agregadas de siniestralidad. Consideremos la experiencia histórica completamente desarrollada del **Accident Year 2024** para la cartera de propiedad comercial. Al cierre del ejercicio, el sistema registra un total de **720 reclamaciones ground-up** que representaron un costo total acumulado de **12.960 millones de dólares (12,960,000 USD)**, lo que equivale a una severidad promedio por siniestro de exactamente **18,000 USD**.

Sin embargo, cuando la aseguradora aplica las condiciones del contrato base -interponiendo un deducible de **2,500 USD**, un límite de pago de **75,000 USD** por encima del deducible y una proporción de coaseguro del **90 %**- el costo total pagado por la aseguradora se reduce a **9.360 millones de dólares (9,360,000 USD)**. Al procesar estas cifras para presentar los resultados de severidad de pago bruto al comité técnico, surge de inmediato una discrepancia en el equipo de modelación:

- **Lucía** calcula la severidad de pago promedio dividiendo el cargo total del seguro directo (9.360M USD) entre la totalidad de los 720 siniestros que ocurrieron en la cartera. El resultado es un pago promedio de exactamente **13,000 USD por pérdida**.
- **Mateo**, desde el departamento de reclamaciones y liquidación de siniestros, obtiene un promedio diferente: divide el mismo pago total de 9.360M USD únicamente entre las **624 reclamaciones que de hecho superaron el deducible** y generaron un desembolso positivo para la aseguradora. Su resultado es de exactamente **15,000 USD por pago**.

¿Cuál de los dos promedios es el correcto? Ambos lo son. La diferencia entre **13,000 USD** y **15,000 USD** no se origina en un error de cálculo ni en una divergencia en la base de datos. Procede, de manera fundamental, de **la elección de dos denominadores distintos**.

Para formalizar analíticamente este fenómeno y evitar costosas confusiones interpretativas, el actuario debe definir con absoluta precisión las dos bases de pago (*payment basis*) que rigen bajo modificaciones de cobertura:

- El **pago por pérdida** (*payment per loss*), denotado formalmente como Y_L , es una variable aleatoria que distribuye el costo pagado por el asegurador entre todas las reclamaciones ground-up que ocurren en el portafolio. Esta variable incluye de manera explícita valores de cero dólares para todos aquellos siniestros cuyo importe ground-up fue menor o igual al deducible. Su esperanza matemática, $E[Y_L]$, es la base de severidad utilizada para estimar la prima pura de la cartera.
- El **pago por pago** (*payment per payment*), denotado formalmente como Y_P , es la variable aleatoria de pago condicionada estrictamente a que el desembolso de la aseguradora sea positivo. Esta variable excluye del análisis todos los eventos eliminados por el deducible, restringiendo el denominador al subconjunto de siniestros con pago efectivo. Su relación probabilística condicional respecto al pago por pérdida se formula como:

$$Y_P \stackrel{d}{=} Y_L \mid Y_L > 0$$

Aceptar esta distinción metodológica revela que las modificaciones de cobertura no se limitan a reducir de forma lineal el promedio de los siniestros: transforman la variable aleatoria completa, alterando su soporte, su densidad y la probabilidad de cada escenario antes de que el actuario construya el modelo de riesgo. La pregunta central de esta sección es, por tanto: **si conocemos la distribución de las pérdidas ground-up, ¿qué ocurre con toda esa distribución cuando el contrato decide qué parte realmente paga el asegurador?**

2.3.2 El deducible acumula masa en el cero y desplaza los pagos positivos

Para modelar de forma continua el impacto de un deducible ordinario (*ordinary deductible*) d sobre la distribución de severidad, definimos una variable de pérdida ground-up continua y positiva X con función de distribución acumulada $F_X(x)$. La interposición del deducible transforma la variable X en una variable de pago después de deducible, representada mediante el operador de parte positiva $(X - d)_+$:

$$Y_d = (X - d)_+ = \begin{cases} 0 & X \leq d \\ X - d & X > d \end{cases}$$

Esta transformación altera profundamente la naturaleza probabilística de la severidad. Aunque la variable ground-up original X sea estrictamente continua y carezca de puntos de acumulación discreta, la nueva variable de pago Y_d se convierte en una **variable aleatoria mixta**.

Toda la probabilidad acumulada por debajo de la barrera del deducible colapsa en un único punto discreto de probabilidad en el origen, denominado **masa o átomo en el cero**:

$$P(Y_d = 0) = P(X \leq d) = F_X(d)$$

Por el contrario, la probabilidad de que la aseguradora enfrente un siniestro que genere un pago efectivo mayor a cero es complementaria y se describe mediante la función de supervivencia en el umbral del deducible:

$$P(Y_d > 0) = P(X > d) = \bar{F}_X(d)$$

En la región estrictamente positiva del soporte, la distribución de pagos se desplaza de forma continua hacia la izquierda en la cuantía del deducible. Para cualquier valor de pago $y > 0$, la función de distribución acumulada de la variable de pago después de deducible se calcula

como:

$$F_{Y_d}(y) = P(Y_d \leq y) = P(X - d \leq y) = P(X \leq d + y) = F_X(d + y)$$

Para comprender la mecánica teórica de esta transformación, utilicemos el modelo de severidad **Lognormal** (Modelo A) de Meridiano Seguros, parametrizado bajo los valores canónicos $\mu = \ln(9,000)$ y $\sigma = \sqrt{2 \ln 2} \approx 1.1774$, el cual arroja una severidad media ground-up teórica de **18,000 USD**:

1. **Cálculo de la masa discreta en cero ($d = 2,500$ USD):**

Utilizando la CDF de la Lognormal y el cuantil de la Normal estándar, calculamos la proporción de reclamaciones que no superarán el deducible:

$$F_X(2,500) = \Phi\left(\frac{\ln(2,500) - \ln(9,000)}{1.17741}\right) = \Phi\left(\frac{7.824046 - 9.104980}{1.177410}\right) = \Phi(-1.0879) \approx 13.83\%$$

Esto significa que, bajo el Modelo A, el **13.83 %** de los siniestros que ocurran en la cartera de Meridiano se acumularán teóricamente en un pago de cero dólares, eliminándose de la responsabilidad directa de la aseguradora.

2. **Cálculo de la probabilidad de pago positivo:**

$$\bar{F}_X(2,500) = 1 - F_X(2,500) \approx 1 - 0.1383 = 86.17\%$$

El **86.17 %** restante representará la porción de siniestros con pago bruto positivo.

Para calcular el valor esperado del pago por pérdida con deducible puro, puede partirse de la densidad sobre la región activa del contrato:

$$E[(X - d)_+] = \int_d^{\infty} (x - d) f_X(x) dx$$

La misma esperanza puede expresarse mediante la identidad fundamental de la **esperanza de exceso o stop-loss** (*expected excess loss*) como una integral de la función de supervivencia:

$$E[(X - d)_+] = \int_d^\infty \bar{F}_X(x) dx$$

Bajo la parametrización del modelo Lognormal (Modelo A), el cálculo analítico de esta integral arroja un valor esperado de exceso de exactamente **15,634.36 USD**.

Este resultado cuantitativo permite mostrar por qué **una intuición común del pricing de seguros es incorrecta**: «*Si la severidad promedio ground-up es de 18,000 USD y aplicamos un deducible de 2,500 USD, el costo promedio de los pagos se reducirá linealmente en exactamente 2,500 USD, resultando en 15,500 USD*».

Este razonamiento es falso porque el deducible no resta 2,500 USD a todas las reclamaciones posibles. Para las reclamaciones inferiores al deducible (el 13.83 % teórico), el deducible elimina únicamente el importe real del siniestro (por ejemplo, si ocurre una pérdida de 1,000 USD, el deducible de Meridiano elimina 1,000 USD, no 2,500 USD), limitando el pago a cero y protegiendo al asegurador de saldos negativos. En consecuencia, el costo promedio teórico del pago por pérdida se sitúa en **15,634.36 USD**, lo que significa que la introducción del deducible de 2,500 USD redujo la severidad esperada en únicamente **2,365.64 USD** (menos que su valor nominal).

2.3.3 El factor de eliminación de pérdidas mide dólares, no conteos de siniestros

La reducción del costo esperado que un deducible aporta al portafolio se cuantifica mediante el **factor de eliminación de pérdidas** (*loss elimination ratio*, LER). El LER se define como la proporción del valor esperado ground-up que la aseguradora deja de pagar debido a la interposición del deducible d , asumiendo que no existen otras modificaciones de cobertura como límites o coaseguro:

$$LER(d) = \frac{E[X] - E[(X - d)_+]}{E[X]} = \frac{E[\min(X, d)]}{E[X]} = 1 - \frac{E[(X - d)_+]}{E[X]}$$

Para ilustrar con rigor la diferencia entre las métricas empíricas y teóricas del LER, contrastemos primero la experiencia real observada de Meridiano AY 2024 con el comportamiento de los modelos continuos candidatos:

■ **LER Empírico de Meridiano AY 2024 (Dato Histórico Cerrado):**

A partir de la descomposición auditada de las 720 reclamaciones del portafolio, sabemos que las exactamente 96 pérdidas que se ubicaron por debajo del deducible de 2,500 USD acumularon un costo total de **120,000 USD** (96 claims con media interna de 1,250 USD). Para las otras 624 reclamaciones que superaron el deducible, este eliminó exactamente los primeros 2,500 USD de cada pérdida, totalizando **1.560 millones de dólares (1,560,000 USD)**.

Sumando ambos componentes, el deducible de 2,500 USD eliminó un total de **1.680 millones de dólares** de la siniestralidad ground-up. El LER empírico resultante es:

$$LER_{\text{emp}}(2,500) = \frac{1,680,000}{12,960,000} = 12.96 \%$$

Este resultado demuestra pedagógicamente que **el LER mide dólares eliminados, no conteos de siniestros**. Mientras que el deducible eliminó físicamente el **13.33 % de la frecuencia** de los siniestros (96 de 720 reclamaciones), solo logró eliminar el **12.96 % del costo financiero** de las pérdidas de la cartera.

■ **LER Teórico del Modelo A (Lognormal Candidate):**

Utilizando la esperanza matemática teórica derivada bajo la curva Lognormal ($E[X] = 18,000$ USD, $E[(X - d)_+] \approx 15,634.36$ USD), el LER teórico se calcula como:

$$LER_{LN}(2,500) = 1 - \frac{15,634.36}{18,000} = 13.14 \%$$

■ **LER Teórico del Modelo B (Lomax Candidate):**

Consideremos ahora el segundo modelo candidato continuo, la distribución **Lomax** (Pareto Tipo II) con parámetros canónicos $\alpha = 2.2$ y $\theta = 21,600$ USD, que comparte la misma media de 18,000 USD. Bajo este modelo, el costo esperado teórico de pago tras el deducible de 2,500 USD es de aproximadamente **15,783.25 USD**. Al calcular su LER teórico, obtenemos:

$$LER_{\text{Lomax}}(2,500) = 1 - \frac{15,783.25}{18,000} = 12.32\%$$

El contraste entre el LER del Modelo A (**13.14 %**) y del Modelo B (**12.32 %**) revela que **dos distribuciones con idéntico promedio ground-up responden de forma diferente ante el mismo deducible contractual**. La distribución Lomax (Modelo B) concentra una mayor masa de probabilidad en siniestros sumamente pequeños cerca del origen, pero compensa esta frecuencia mediante una cola extremadamente pesada que decae de forma lenta. En consecuencia, para un deducible de 2,500 USD, el Modelo B elimina proporcionalmente menos dólares esperados de la cartera que el Modelo Lognormal (Modelo A), evidenciando cómo la elección de la familia paramétrica impacta de forma directa sobre la tarificación del deducible.

2.3.4 El límite trunca la cola extrema y crea un punto de acumulación contractual

Para completar la modelación del contrato base de Meridiano Seguros, el actuario debe incorporar simultáneamente el deducible d , el límite de pago ℓ por encima del deducible y la proporción de coaseguro c . La variable de pago por pérdida de la aseguradora, Y_L , se formula formalmente como:

$$Y_L = c \min((X - d)_+, \ell)$$

Bajo este contrato completo, la variable de pago ground-up continua X se mapea y fragmenta de forma no lineal en tres grandes regiones del soporte, tal como se cartografía a continuación:

1. **Región de pérdidas eliminadas** ($0 \leq X \leq d$):

Cualquier pérdida en este intervalo genera un pago de cero dólares ($Y_L = 0$). Toda esta probabilidad continua se acumula de forma discreta en el origen, creando el **átomo de cero** con probabilidad $F_X(d)$.

2. **Región continua de cobertura** ($d < X < d + \ell$):

La pérdida supera el deducible pero no agota la cobertura. La aseguradora paga una proporción constante del exceso: $Y_L = c(X - d)$. En este intervalo (para Meridiano, entre 2,500 y 77,500 USD), la variable conserva un comportamiento continuo con CDF igual a $F_X(d + y/c)$.

3. **Región de pérdidas saturadas o excedidas** ($X \geq d + \ell$):

El siniestro iguala o supera el umbral de agotamiento contractual $d + \ell$ (en Meridiano, $2,500 + 75,000 = 77,500$ USD). Sin importar el tamaño final del siniestro extremo, el pago del asegurador directo se congela de forma determinista en el pago máximo bruto permitido: $Y_L = c\ell$.

Toda esta masa de probabilidad de la cola se acumula de forma discreta en el extremo superior de la distribución de pagos, creando el **átomo de límite**:

$$P(Y_L = c\ell) = P(X \geq d + \ell) = \bar{F}_X(d + \ell)$$

Para el Modelo A (Lognormal) de Meridiano, la probabilidad de que un siniestro sea tan severo que sature el límite de pago (superando los 77,500 USD de pérdida ground-up) es aproximadamente **3.37 %** ($\bar{F}_X(77,500) \approx 3.37\%$).

El coaseguro no cambia qué siniestros producen pago positivo mientras $c > 0$: $Y_L > 0$ sigue siendo equivalente a $X > d$. Su efecto es escalar los pagos positivos y el pago máximo de ℓ a $c\ell$. Por tanto, un coaseguro de 90 % no elimina 10 % de los claims; reduce a 90 % los dólares cubiertos definidos por el contrato.

Antes del coaseguro, si definimos $W = \min((X - d)_+, \ell)$, el pago limitado esperado es:

$$E[W] = E[\text{mín}((X - d)_+, \ell)] = \int_d^{d+\ell} \bar{F}_X(x) dx$$

Después del coaseguro, el valor esperado del pago por pérdida es:

$$E[Y_L] = c \int_d^{d+\ell} \bar{F}_X(x) dx$$

Como $P(Y_L > 0) = \bar{F}_X(d)$, la esperanza del pago por pago satisface:

$$E[Y_P] = E[Y_L \mid Y_L > 0] = \frac{E[Y_L]}{\bar{F}_X(d)}$$

Además, para $0 < y < c\ell$, su CDF condicional es:

$$F_{Y_P}(y) = P(Y_L \leq y \mid Y_L > 0) = \frac{F_X(d + y/c) - F_X(d)}{\bar{F}_X(d)}$$

El condicionamiento renormaliza la probabilidad después de retirar del denominador los siniestros con pago cero. Apliquemos estas fórmulas a los dos modelos de severidad continuos candidatos y contrastemos los resultados con la experiencia histórica observada de la cartera de Meridiano:

■ **Modelo A (Lognormal Candidate):**

La integral de supervivencia Lognormal entre 2,500 USD y 77,500 USD arroja una esperanza limitada de **13,614.10 USD** antes de coaseguro. Al incorporar el coaseguro del 90 % ($c = 0.90$), obtenemos el valor esperado del pago por pérdida:

$$E[Y_L]_{LN} = 0.90 \times 13,614.10 = \mathbf{12,252.69 \text{ USD}}$$

De manera condicional, dividiendo entre la probabilidad de pago positivo (86.17 %), obtenemos la severidad esperada del pago por pago:

$$E[Y_P]_{LN} = \frac{12,252.69}{0.8616859} \approx \mathbf{14,219.44 \text{ USD}}$$

■ **Modelo B (Lomax Candidate):**

Bajo la curva Lomax de cola pesada, la integral de supervivencia entre los mismos límites resulta en una esperanza de **12,890.39 USD** antes de coaseguro. Al aplicar el coaseguro del 90 %, el pago por pérdida esperado se sitúa en:

$$E[Y_L]_{\text{Lomax}} = 0.90 \times 12,890.39 = \mathbf{11,601.35 \text{ USD}}$$

■ **Experiencia Real de Meridiano AY 2024 (Empírica):**

El balance real desarrollado registra un costo de pago por pérdida empírico de exactamente **13,000 USD** y un pago por pago promedio de exactamente **15,000 USD**.

En la comparación entre experiencia y modelo, la media ground-up empírica y la media teórica Lognormal coinciden en **18,000 USD**, pero el pago bruto por pérdida es **13,000 USD empírico** frente a **12,252.69 USD model-derived**, y la proporción de pagos positivos es **86.67 % empírica** frente a **86.17 % model-derived**. Estas proximidades son comparaciones de cantidades paralelas y no constituyen por sí mismas evidencia de ajuste del modelo.

El análisis comparativo de estas cifras revela un contraste relevante para el modelado actuarial: **bajo el contrato limitado de Meridiano, la distribución Lomax (Modelo B) genera un pago esperado por pérdida (11,601.35 USD) sensiblemente inferior al del Modelo Lognormal (12,252.69 USD), a pesar de que Lomax posee una cola mucho más pesada y una volatilidad incondicional casi del doble (SD Lomax = 59,699 USD vs. SD Lognormal = 31,177 USD).**

La explicación técnica es que una parte importante de la severidad extrema de la cola de Lomax se ubica por encima del umbral de 77,500 USD, región donde el seguro se ha agotado. Por contrato, esa severidad por encima del umbral es recortada por el límite del seguro (quedando como pérdida no financiada por el asegurador directo), de modo que Meridiano no asume el costo de esa volatilidad extrema. En cambio, la distribución Lognormal concentra una proporción mayor de sus pérdidas esperadas dentro de la capa útil de cobertura (entre

2,500 y 77,500 USD), resultando en un costo de pago promedio más alto para este contrato específico.

2.3.5 Los límites incrementados dependen del comportamiento asintótico de la cola

Cuando una aseguradora necesita evaluar la conveniencia financiera de expandir sus límites de retención, o cuando Pricing diseña tarifas para diferentes opciones de cobertura, utiliza los **factores de límites incrementados** (*increased limits factors*, ILF). El ILF se define como la razón que mide el incremento del costo esperado cubierto a medida que se aumenta el límite de cobertura de un nivel básico ℓ_b a un nivel incrementado ℓ_h , asumiendo que el deducible d se mantiene constante:

$$ILF(\ell_b \rightarrow \ell_h) = \frac{E[\min((X - d)_+, \ell_h)]}{E[\min((X - d)_+, \ell_b)]} = \frac{\int_d^{d+\ell_h} \bar{F}_X(x) dx}{\int_d^{d+\ell_b} \bar{F}_X(x) dx}$$

Para analizar de forma rigurosa este factor, definamos una cobertura básica con límite $\ell_b = 25,000$ USD y comparémosla con el límite estándar de Meridiano de $\ell_h = 75,000$ USD, manteniendo el deducible de 2,500 USD:

■ **Bajo el Modelo A (Lognormal Candidate):**

- La esperanza limitada a límite básico es: $E[\min((X - 2500)_+, 25000)] \approx 9,719.34$ USD.
- La esperanza limitada a límite incrementado es: $E[\min((X - 2500)_+, 75000)] \approx 13,614.10$ USD.
- El factor de límite incrementado es:

$$ILF_{LN}(25k \rightarrow 75k) = \frac{13,614.10}{9,719.34} = 1.4007$$

■ **Bajo el Modelo B (Lomax Candidate):**

- La esperanza limitada a límite básico es: $E[\min((X - 2500)_+, 25000)] \approx 9,064.03$ USD.
- La esperanza limitada a límite incrementado es: $E[\min((X - 2500)_+, 75000)] \approx 12,890.39$ USD.
- El factor de límite incrementado es:

$$ILF_{\text{Lomax}}(25k \rightarrow 75k) = \frac{12,890.39}{9,064.03} = \mathbf{1.4221}$$

Este cálculo desmonta otra intuición equivocada que con frecuencia asumen los suscriptores: «Si triplicamos el límite de cobertura de 25,000 USD a 75,000 USD, el costo de la pérdida esperada para el asegurador se triplicará (multiplicándose por 3.0)». Esto es falso debido a que la gran mayoría de los siniestros ordinarios se resuelven muy por debajo de ambos límites sin verse afectados por la expansión de la capa.

La consecuencia más relevante de este análisis es que **el ILF de la distribución Lomax (1.4221) supera al de la distribución Lognormal (1.4007), a pesar de que Lomax genera costos esperados absolutos más bajos en ambos límites**. Al expandir el límite de cobertura, la cola pesada de decaimiento lento polinomial de Lomax continúa aportando de forma asintótica más costo esperado en la capa superior (25,000 a 75,000 USD) de lo que aporta la cola Lognormal, demostrando que los factores de límites incrementados son sensibles a la forma paramétrica de la cola.

2.3.6 La inflación interactúa de forma no lineal con los umbrales nominales fijos

En el análisis retrospectivo de la severidad, la inflación suele representarse de forma homogénea como un factor multiplicativo constante $a = 1 + i$ que desplaza linealmente la variable ground-up completa. Si la inflación de severidad del portafolio es del **6%** ($a = 1.06$), la nueva variable de pérdida ground-up inflada es:

$$X^{(a)} = aX = 1.06X$$

Con deducible y límite nominales fijos, el pago por pérdida inflado es:

$$Y_L^{(a)} = c \min((aX - d)_+, \ell)$$

Equivalentemente:

$$Y_L^{(a)} = ca \min\left(\left(X - \frac{d}{a}\right)_+, \frac{\ell}{a}\right)$$

Por tanto, su valor esperado puede escribirse como:

$$E[Y_L^{(a)}] = ca \int_{d/a}^{(d+\ell)/a} \bar{F}_X(x) dx$$

Esta forma muestra que la inflación desplaza la distribución ground-up respecto de umbrales contractuales que permanecen fijos: en unidades de la variable original, el deducible efectivo pasa a d/a y el punto de agotamiento a $(d + \ell)/a$. No obstante, cuando el actuario analiza el impacto de esta inflación sobre las pérdidas cubiertas por el seguro, descubre que **la inflación aplicada a las pérdidas ground-up no se traduce en el mismo crecimiento porcentual sobre la distribución de pagos de la aseguradora**. Al conservar los umbrales del contrato (deducible y límites) fijos en términos nominales, la interacción con la inflación genera distorsiones altamente no lineales que dependen de la región de severidad que se estudie:

▪ **Efecto Amplificador del Deducible Fijo (Siniestro B individual):**

Consideremos el escenario pedagógico local **Claim B**, que ingresa al sistema con una pérdida ground-up inicial de **40,000 USD**. El pago inicial bajo el deducible y coaseguro (sin límite) es de **33,750 USD**. Si aplicamos la inflación del 6 %, la pérdida ground-up se eleva a **42,400 USD**. Al recalcular el pago bruto de la aseguradora, obtenemos:

$$Y_{\text{inflado}} = 0.90 \times (42,400 - 2,500) = \mathbf{35,910 \text{ USD}}$$

Mientras que la pérdida física aumentó exactamente un **6.00 %**, el pago efectivo de la aseguradora directa aumentó un **6.40 %**. Este crecimiento amplificado ocurre porque **el deducible nominal se mantiene fijo en 2,500 USD**. Al no inflarse el deducible, toda la carga inflacionaria del primer dólar se transfiere de forma amplificada a la porción de pago que excede el deducible.

- **Efecto Amplificador a Nivel de Cartera (Lognormal con Deducible Puro):**

Si escalamos la distribución Lognormal completa de Meridiano por el factor inflacionario del 6 % bajo un deducible puro de 2,500 USD y coaseguro del 90 %, el costo promedio esperado del pago por pérdida se eleva de **14,070.92 USD** a **15,032.22 USD**. El crecimiento del pago esperado por pérdida es del **6.83 %**, confirmando que el deducible fijo amplifica el crecimiento relativo del pago bajo este modelo.

- **Efecto de Mitigación del Límite de Pago Fijo (Contrato Completo Lognormal):**

¿Qué ocurre si reincorporamos el límite de pago nominal de 75,000 USD? Bajo el contrato completo de Meridiano, la severidad promedio esperada del pago por pérdida (Modelo A) aumenta de **12,252.69 USD** a **12,955.83 USD** tras la inflación del 6 %. El crecimiento del pago esperado por pérdida se sitúa en **5.74 %**.

Este resultado cuantitativo revela el comportamiento asimétrico del contrato. Por un lado, el deducible fijo amplifica la inflación (crecimiento del 6.83 % en deducible puro); por otro lado, **el límite de pago fijo de 75,000 USD actúa como un dique o amortiguador que congela los siniestros de la cola extrema en el pago máximo de 67,500 USD**. Este efecto de tope contractual neutraliza el impacto inflacionario en los grandes siniestros, compensando con creces la amplificación del deducible y mitigando el crecimiento del pago esperado por pérdida al 5.74 % (por debajo de la inflación ground-up del 6 %).

Cierre y Puente Final

Al concluir esta sección, hemos completado la caracterización individual y contractual del costo de los siniestros. Al inicio, la existencia de dos promedios de pago (13,000 USD y 15,000

USD) parecía una contradicción aritmética irresoluble. Ahora reconocemos que el pago por pérdida (Y_L) y el pago por pago (Y_P) son dos representaciones matemáticas igualmente válidas que responden a denominadores y condicionamientos distintos sobre una misma distribución mixta de pagos. Hemos aprendido que las modificaciones de cobertura moldean geoméricamente la distribución: el deducible acumula masa discreta en cero, el límite trunca la cola acumulando probabilidad en el pago máximo, el coaseguro escala linealmente los dólares y la inflación interactúa de forma no lineal con estos umbrales nominales fijos.

Disponemos de un motor probabilístico robusto para describir el costo de un siniestro individual una vez que ocurre (Y_L). Sin embargo, el costo financiero anual de la cartera de Meridiano Seguros sigue estando incompleto: la severidad, por sí sola, no puede determinar cuántos siniestros ocurrirán durante el periodo de exposición. La nueva variable será N , el número de claims durante una unidad definida de exposición; todavía no la modelamos aquí. La pregunta que abre la **Section 2.4 - Frequency Models** es: **¿qué modelo de probabilidad describe cuántos claims llegan durante un periodo de exposición?**

Ejercicios

Ejercicio 1 - Deducible, límite y bases de pago

Se modela la severidad de pérdidas ground-up continuas X de una cartera mediante una distribución exponencial con media de 10,000 USD, cuya función de supervivencia se define como $\bar{F}_X(x) = e^{-x/10000}$ para $x \geq 0$. El contrato de seguro establece un deducible $d = 2,000$ USD, un límite de pago $\ell = 10,000$ USD por encima del deducible (de modo que el punto de agotamiento es $d + \ell = 12,000$ USD) y una proporción de coaseguro $c = 80\%$.

1. Calcule la masa discreta de probabilidad que se acumula en el pago de cero dólares ($P(Y_L = 0)$).
2. Calcule la masa discreta de probabilidad que se acumula en el pago máximo bruto permitido ($P(Y_L = c\ell)$).

3. Calcule el valor esperado del pago por pérdida ($E[Y_L]$) utilizando la integral de la función de supervivencia sobre la capa útil de cobertura.
4. Calcule el valor esperado del pago por pago ($E[Y_P]$) de la aseguradora, explicando detalladamente qué cambio conceptual ocurre en el denominador respecto al pago por pérdida.

Criterio de éxito para la solución:

- Masa en cero: $P(Y_L = 0) = F_X(2,000) = 1 - e^{-2000/10000} = 1 - e^{-0.2} \approx 18.13\%$.
- Masa en el límite: El pago máximo es $c\ell = 0.80 \times 10,000 = 8,000$ USD. Ocurre si la pérdida ground-up excede los 12,000 USD. La probabilidad es: $P(Y_L = 8,000) = \bar{F}_X(12,000) = e^{-12000/10000} = e^{-1.2} \approx 30.12\%$.
- Esperanza del pago por pérdida:

$$E[Y_L] = c \int_d^{d+\ell} \bar{F}_X(x) dx = 0.80 \int_{2000}^{12000} e^{-x/10000} dx = 0.80 \times 10,000 \times (e^{-0.2} - e^{-1.2})$$

$$E[Y_L] = 8,000 \times (0.81873075 - 0.30119421) \approx 4,140.29 \text{ USD}$$

- Esperanza del pago por pago: El denominador condicional es la probabilidad de que la pérdida supere el deducible: $P(X > 2,000) = e^{-0.2} \approx 81.87\%$.

$$E[Y_P] = \frac{E[Y_L]}{\bar{F}_X(2,000)} = \frac{4,140.29}{e^{-0.2}} \approx 5,056.96 \text{ USD}$$

El paso del pago por pérdida al pago por pago elimina los siniestros menores a 2,000 USD del denominador, elevando la severidad promedio esperada de 4,140.29 a 5,056.96 USD.

Ejercicio 2 - LER y factores de límites incrementados (ILF)

Una compañía de seguros analiza el comportamiento de la severidad ground-up teórica de su portafolio bajo una distribución exponencial con media de 20,000 USD ($\bar{F}_X(x) = e^{-x/20000}$). Se asume un deducible constante $d = 5,000$ USD. Se definen dos límites de pago alternativos por encima del deducible: un límite básico $\ell_b = 20,000$ USD y un límite incrementado $\ell_h = 60,000$ USD.

1. Calcule el LER producido únicamente por el deducible de 5,000 USD respecto de la severidad ground-up esperada.
2. Calcule la esperanza limitada del pago por encima del deducible a límite básico ($E[\min((X - d)_+, \ell_b)]$).
3. Calcule la esperanza limitada del pago por encima del deducible a límite incrementado ($E[\min((X - d)_+, \ell_h)]$).
4. Calcule el factor de límite incrementado ($ILF(20k \rightarrow 60k)$) para esta cartera.
5. Explique conceptualmente por qué triplicar el límite de pago (de 20,000 a 60,000 USD) no triplica el costo esperado para la aseguradora directa.

Criterio de éxito para la solución:

- LER del deducible: el pago esperado con deducible puro es $E[(X - 5,000)_+] = 20,000e^{-0.25} \approx 15,576.02$ USD, de modo que:

$$LER(5,000) = 1 - \frac{15,576.02}{20,000} \approx 22.12\%$$

La base del ratio es la severidad ground-up esperada de 20,000 USD.

- Esperanza a límite básico: El intervalo de integración es de $d = 5,000$ a $d + \ell_b = 25,000$ USD.

$$E[\text{mín}((X - d)_+, 20,000)] = \int_{5000}^{25000} e^{-x/20000} dx = 20,000 \times (e^{-0.25} - e^{-1.25})$$

$$E[\text{mín}((X - d)_+, 20,000)] = 20,000 \times (0.77880078 - 0.28650480) \approx 9,845.92 \text{ USD}$$

- Esperanza a límite incrementado: El intervalo de integración es de 5,000 a $d + \ell_h = 65,000$ USD.

$$E[\text{mín}((X - d)_+, 60,000)] = \int_{5000}^{65000} e^{-x/20000} dx = 20,000 \times (e^{-0.25} - e^{-3.25})$$

$$E[\text{mín}((X - d)_+, 60,000)] = 20,000 \times (0.77880078 - 0.03877421) \approx 14,800.53 \text{ USD}$$

- Cálculo del ILF:

$$ILF(20k \rightarrow 60k) = \frac{14,800.53}{9,845.92} \approx 1.5032$$

- Explicación cualitativa: El ILF resultante de 1.5032 indica que expandir el límite de pago en un 200 % (triplicarlo) solo incrementa la siniestralidad esperada cubierta en un 50.32 %. Esto ocurre porque la mayor parte de la masa de probabilidad de los siniestros se concentra en valores pequeños que nunca alcanzan el límite básico de 20,000 USD, permaneciendo inalterados ante la expansión del límite.

Ejercicio 3 - Interacción no lineal de la inflación y las cláusulas nominales

La severidad de las pérdidas ground-up de una cartera sigue una distribución exponencial con media de 10,000 USD ($\bar{F}_X(x) = e^{-x/10000}$). El contrato establece un deducible nominal fijo $d = 2,000$ USD y un límite nominal fijo $\ell = 20,000$ USD por encima del deducible (con coaseguro $c = 100\%$ para simplificar).

1. Calcule el valor esperado del pago por pérdida inicial de la aseguradora ($E[Y_L]$).
2. Asuma que toda la severidad ground-up experimenta una inflación uniforme del 10% ($a = 1.10$). Calcule el nuevo valor esperado del pago por pérdida ($E[Y_L^{(a)}]$) manteniendo el deducible y el límite nominales fijos en 2,000 y 20,000 USD. Obtenga el crecimiento porcentual de los pagos de la aseguradora.
3. Asuma ahora un escenario alternativo en el que, en lugar de mantener las cláusulas fijas, el deducible y el límite se indexan perfectamente a la inflación ($d' = 1.10d = 2,200$ USD; $\ell' = 1.10\ell = 22,000$ USD). Calcule el nuevo pago esperado y su tasa de crecimiento.
4. Compare ambos escenarios e interprete por qué la inflación de los pagos de la aseguradora difiere de la inflación ground-up del 10% únicamente cuando los límites y deducibles nominales se mantienen fijos.

Criterio de éxito para la solución:

- Pago esperado inicial: El intervalo es de 2,000 a 22,000 USD.

$$E[Y_L] = \int_{2000}^{22000} e^{-x/10000} dx = 10,000 \times (e^{-0.2} - e^{-2.2}) = 10,000 \times (0.81873075 - 0.1180316) \approx 7,007$$

- Pago esperado inflado (cláusulas fijas): La nueva variable es $X' = 1.10X$. Su supervivencia es $e^{-x/11000}$.

$$E[Y_L^{(a)}] = \int_{2000}^{22000} e^{-x/11000} dx = 11,000 \times (e^{-2000/11000} - e^{-22000/11000}) = 11,000 \times (e^{-0.18182} - e^{-2})$$

$$E[Y_L^{(a)}] = 11,000 \times (0.83375292 - 0.13533528) \approx 7,682.59 \text{ USD}$$

Crecimiento porcentual: $7,682.59/7,079.28 - 1 \approx 8.52\%$.

- Pago esperado inflado (cláusulas indexadas): Al indexar los límites, la integral se realiza sobre los nuevos límites ajustados:

$$E[Y_L^{\text{ind}}] = \int_{2200}^{24200} e^{-x/11000} dx = 11,000 \times (e^{-2200/11000} - e^{-24200/11000}) = 11,000 \times (e^{-0.2} - e^{-2.2})$$

$$E[Y_L^{\text{ind}}] = 11,000 \times (0.81873075 - 0.11080316) \approx 7,787.20 \text{ USD}$$

Crecimiento porcentual: $7,787.20/7,079.28 - 1 \approx \mathbf{10.00\%}$.

- Interpretación: Si las cláusulas del contrato se indexan, la escala de la variable de pago se ajusta perfectamente y los pagos de la aseguradora crecen al mismo ritmo del 10.00 % que la severidad física. Sin embargo, si el deducible y el límite nominales permanecen fijos, la inflación de los pagos de la aseguradora cae al 8.52 %, debido a que el límite nominal fijo de 20,000 USD absorbe y detiene la inflación de los grandes siniestros de la cola, amortiguando el impacto global en la cartera.

2.4 - Frequency Models

Una frecuencia media de 0.060 no decide cuántos claims veremos

2.4.1 Una frecuencia media de 0.060 no decide cuántos claims veremos

Meridiano Seguros cerró el Accident Year 2024 con **12,000 policy-years** de exposición y **720 reclamaciones ground-up**. La primera cifra que resume esa experiencia es la frecuencia media empírica:

$$\lambda_{\text{empirical}} = \frac{720}{12,000} = 0.060 \text{ claims por policy-year.}$$

¿Eso basta para concluir que el número de claims por policy-year debe modelarse con una distribución de Poisson?

Todavía no.

En esta sección, salvo que se indique expresamente otra unidad de observación,

$$N$$

representa el **número de ground-up claims por policy-year**. La cifra 0.060 significa que, al promediar sobre las exposiciones observadas, se registraron 0.060 claims por policy-year. No significa que cada policyholder experimente literalmente 0.060 claims.

La distribución empírica observada fue:

		Proporción empírica
Claims por policy-year (<i>k</i>)	Policy-years observados	observada
0	11,325	94.3750 %
1	635	5.2917 %
2	35	0.2917 %
3	5	0.0417 %
Total	12,000	100.00 %

La reconciliación del total de claims es:

$$635 + 2(35) + 3(5) = 635 + 70 + 15 = 720 \text{ claims.}$$

La media empírica puede recuperarse directamente desde la tabla:

$$E_{\text{emp}}[N] = \frac{0(11,325) + 1(635) + 2(35) + 3(5)}{12,000} = \frac{720}{12,000} = 0.060.$$

El segundo momento ordinario empírico es:

$$E_{\text{emp}}[N^2] = \frac{0^2(11,325) + 1^2(635) + 2^2(35) + 3^2(5)}{12,000} = \frac{820}{12,000} \approx 0.0683333.$$

Por tanto, la varianza poblacional empírica es:

$$\begin{aligned} Var_{\text{emp}}(N) &= E_{\text{emp}}[N^2] - (E_{\text{emp}}[N])^2 \\ &= 0.0683333 - (0.060)^2 = 0.0647333. \end{aligned}$$

El ratio de dispersión es entonces:

$$\frac{Var_{\text{emp}}(N)}{E_{\text{emp}}[N]} = \frac{0.0647333}{0.060} \approx 1.07889.$$

La muestra presenta, por tanto, **ligera sobre-dispersión empírica** respecto de la relación teórica de equidispersión de Poisson.

Desafío al lector. Si Poisson exige teóricamente $Var(N) = E[N]$, pero Meridiano observa $0.0647333 > 0.060$, ¿queda automáticamente descartado un modelo de Poisson?

No. Los momentos de una muestra finita no tienen por qué coincidir exactamente con los momentos teóricos del modelo que pudiera haber generado los datos. La diferencia puede deberse a sampling variation, heterogeneidad, clustering, cambios temporales u otras desviaciones entre el modelo y el proceso observado. La discrepancia es un **diagnóstico que**

genera una pregunta, no una prueba automática de que Poisson sea incorrecta.

Lucía propone utilizar una distribución de Poisson con $\lambda = 0.060$ como punto de partida porque reproduce exactamente la frecuencia media observada. Irene acepta que puede ser un baseline razonable, pero plantea la pregunta que gobernará el resto de la sección:

Si dos modelos pueden compartir la misma media, ¿qué otras propiedades del conteo necesitamos examinar para decidir cómo repartir probabilidad entre cero, uno, dos o varios claims?

La respuesta exige estudiar no solo la media, sino también la varianza, el soporte, la probabilidad en cero, las probabilidades de múltiples claims y el mecanismo que genera u observa los conteos.

2.4.2 La clase $(a, b, 0)$ unifica las distribuciones discretas mediante su relación recursiva

Para una variable discreta de conteo, escribimos:

$$p_k = P(N = k), \quad k = 0, 1, 2, \dots$$

según el soporte del modelo.

La **clase** $(a, b, 0)$ agrupa distribuciones cuyas probabilidades sucesivas satisfacen:

$$p_k = \left(a + \frac{b}{k}\right) p_{k-1}, \quad k = 1, 2, \dots$$

o, equivalentemente,

$$\frac{p_k}{p_{k-1}} = a + \frac{b}{k}.$$

La relación permite construir cada probabilidad a partir de la anterior. Una vez conocidos los parámetros a y b y determinada correctamente la probabilidad inicial p_0 , no es necesario recalcular desde cero factoriales o coeficientes combinatorios para cada nuevo valor de k .

Además, la estructura de los cocientes

$$\frac{p_k}{p_{k-1}}$$

permite reconocer relaciones comunes entre distintas familias de conteo.

Existe una aclaración notacional esencial:

El “0” de $(a, b, 0)$ no significa que $p_0 = 0$.

Por ejemplo, para una Poisson,

$$p_0 = e^{-\lambda} > 0.$$

La etiqueta identifica la clase recursiva y el punto desde el cual la recurrencia determina las probabilidades, no una prohibición de observar cero claims.

El inicio de la recurrencia en $k = 1$ conecta directamente p_1 con p_0 :

$$p_1 = (a + b)p_0.$$

A partir de allí:

$$p_2 = \left(a + \frac{b}{2}\right) p_1,$$

$$p_3 = \left(a + \frac{b}{3}\right) p_2,$$

y así sucesivamente mientras el soporte de la distribución lo permita.

2.4.3 Poisson, Binomial y Binomial Negativa representan tres estructuras de dispersión distintas

Dentro del alcance de esta sección, las tres familias base de la clase $(a, b, 0)$ son:

- Poisson;
- Binomial;
- Binomial Negativa.

La distribución Geométrica aparecerá como un caso especial de la Binomial Negativa.

Estas familias permiten representar tres estructuras distintas respecto de la relación entre media y varianza y también diferencias fundamentales de soporte.

Poisson - equidispersión

Sea:

$$N \sim \text{Poisson}(\lambda).$$

Sus parámetros recursivos son:

$$a = 0, \quad b = \lambda.$$

Por tanto:

$$p_k = \frac{\lambda}{k} p_{k-1}.$$

La propiedad teórica característica es:

$$E[N] = \text{Var}(N) = \lambda.$$

Para Meridiano, utilizamos como baseline una Poisson con:

$$\lambda = 0.060,$$

elegida para igualar la media empírica observada.

La probabilidad inicial es:

$$p_0 = e^{-0.06} \approx 0.941765.$$

Desafío al lector. A partir de ese p_0 , ¿qué probabilidades p_1 , p_2 y p_3 produce la recurrencia Poisson?

Aplicando:

$$p_k = \frac{0.06}{k} p_{k-1},$$

obtenemos:

$$p_1 = \frac{0.06}{1} (0.941765) \approx 0.056506,$$

$$p_2 = \frac{0.06}{2} (0.056506) \approx 0.001695,$$

$$p_3 = \frac{0.06}{3} (0.001695) \approx 0.000034.$$

Estas probabilidades pueden compararse directamente con la experiencia observada. Sobre 12,000 policy-years, la Poisson baseline implica aproximadamente:

$$12,000 p_0 \approx 11,301.2$$

policy-years con cero claims,

$$12,000p_1 \approx 678.1$$

con exactamente un claim,

$$12,000p_2 \approx 20.3$$

con exactamente dos claims, y

$$12,000p_3 \approx 0.4$$

con exactamente tres claims.

La comparación es:

k	Observed policy-years	Poisson expected policy-years
0	11,325	$\approx 11,301.2$
1	635	≈ 678.1
2	35	≈ 20.3
3	5	≈ 0.4

La discrepancia se concentra especialmente en que la muestra contiene menos one-claim exposures y más multiple-claim exposures que los sugeridos por esta Poisson con mean 0.060.

Eso es consistente con la ligera sobre-dispersión empírica observada, pero **no demuestra** que Poisson esté rechazada ni que otra familia determinada sea correcta. Solo justifica preguntar si una estructura con mayor dispersión podría representar mejor los múltiples claims.

Binomial - subdispersión y soporte finito

La distribución Binomial resulta natural cuando cada unidad de exposición contiene un número máximo real de oportunidades de generar el evento.

Sea:

$$N \sim \text{Binomial}(m, q),$$

donde m es el número finito de oportunidades y q la probabilidad asociada a cada una dentro del modelo.

Sus parámetros de la clase $(a, b, 0)$ son:

$$a = -\frac{q}{1-q},$$

$$b = \frac{(m+1)q}{1-q}.$$

Como $q > 0$:

$$a < 0.$$

La media y la varianza son:

$$E[N] = mq,$$

$$\text{Var}(N) = mq(1-q) < mq = E[N].$$

Consideremos el caso local:

$$N \sim \text{Binomial}(m = 4, q = 0.20).$$

Entonces:

$$a = -\frac{0.20}{0.80} = -0.25,$$

$$b = \frac{5(0.20)}{0.80} = 1.25.$$

La probabilidad inicial es:

$$p_0 = (1 - q)^m = 0.80^4 = 0.4096.$$

La recurrencia produce:

$$p_1 = (-0.25 + 1.25)(0.4096) = 0.4096,$$

$$p_2 = \left(-0.25 + \frac{1.25}{2}\right)(0.4096) = 0.1536,$$

$$p_3 = \left(-0.25 + \frac{1.25}{3}\right)(0.1536) = 0.0256,$$

$$p_4 = \left(-0.25 + \frac{1.25}{4}\right)(0.0256) = 0.0016.$$

Al intentar avanzar a $k = 5$:

$$p_5 = \left(-0.25 + \frac{1.25}{5}\right)p_4 = 0.$$

El factor recursivo vale exactamente cero en $k = 5$. Como $p_5 = 0$, las probabilidades posteriores permanecen también en cero. La recurrencia revela así el soporte finito:

$$N \in \{0, 1, 2, 3, 4\}.$$

Este ejemplo es local y no constituye una afirmación sobre la cartera de Meridiano.

Binomial Negativa - sobre-dispersión y soporte no acotado

Cuando los counts altos aparecen con mayor frecuencia que bajo una Poisson y no existe un límite superior natural, una familia importante a considerar es la Binomial Negativa.

Bajo la parametrización utilizada en esta serie:

$$p_k = \binom{r+k-1}{k} (1-q)^r q^k,$$

con:

$$r > 0, \quad 0 < q < 1.$$

Sus parámetros recursivos son:

$$a = q,$$

$$b = q(r-1).$$

Como:

$$a = q > 0,$$

la distribución tiene soporte no acotado en los enteros no negativos.

Sus momentos son:

$$E[N] = \frac{rq}{1-q},$$

$$Var(N) = \frac{rq}{(1-q)^2} = \frac{E[N]}{1-q} > E[N].$$

Consideremos el caso local:

$$N \sim NB(r = 2, q = 0.25).$$

Los parámetros recursivos son:

$$a = 0.25,$$

$$b = 0.25(2 - 1) = 0.25.$$

La probabilidad inicial es:

$$p_0 = (1 - q)^r = 0.75^2 = 0.5625.$$

Aplicando la recurrencia:

$$p_1 = \left(0.25 + \frac{0.25}{1}\right) (0.5625) = 0.281250,$$

$$p_2 = \left(0.25 + \frac{0.25}{2}\right) (0.281250) = 0.105469,$$

$$p_3 = \left(0.25 + \frac{0.25}{3}\right) (0.105469) \approx 0.035156.$$

La suma de las primeras cuatro probabilidades es:

$$\sum_{k=0}^3 p_k = 0.562500 + 0.281250 + 0.105469 + 0.035156 = 0.984375.$$

Por tanto, los valores:

$$k \geq 4$$

retienen conjuntamente:

$$1 - 0.984375 = 0.015625 = 1.5625\%$$

de la masa de probabilidad. La recurrencia no termina porque el soporte es infinito.

Si:

$$r = 1,$$

la Binomial Negativa se reduce a la distribución **Geométrica**. En ese caso:

$$b = q(r - 1) = 0,$$

y:

$$p_k = q p_{k-1}.$$

Relaciones entre las familias

La Poisson también aparece como límite de otras familias de la clase.

Para una Binomial:

$$m \rightarrow \infty, \quad q \rightarrow 0, \quad mq = \lambda,$$

la distribución converge hacia:

$$Poisson(\lambda).$$

De manera análoga, para una Binomial Negativa:

$$r \rightarrow \infty, \quad q \rightarrow 0,$$

manteniendo:

$$\frac{rq}{1-q} = \lambda,$$

la dispersión adicional desaparece en el límite y se obtiene nuevamente una Poisson con media λ .

Desafío al lector. Considere los tres pares recursivos ya utilizados:

$$(a, b) = (0, 0.060),$$

$$(a, b) = (-0.25, 1.25),$$

$$(a, b) = (0.25, 0.25).$$

¿Cuál corresponde a Poisson, cuál a Binomial y cuál a Binomial Negativa? La identificación no debe apoyarse únicamente en el signo de a : debe reconciliarse también con la forma de la recurrencia y el soporte correspondiente.

2.4.4 La clase $(a, b, 1)$ flexibiliza el origen para modelar ceros modificados o truncados

En la clase $(a, b, 0)$, la recurrencia empieza en $k = 1$ y conecta directamente:

$$p_1$$

con:

$$p_0.$$

Pero algunas estructuras de datos requieren conservar una relación recursiva entre conteos positivos mientras el comportamiento en cero se modifica o mientras los ceros quedan excluidos del dataset.

La **clase** $(a, b, 1)$ utiliza la misma forma recursiva, pero comienza en:

$$k = 2.$$

Es decir:

$$p_k = \left(a + \frac{b}{k}\right) p_{k-1}, \quad k = 2, 3, \dots$$

Esto desacopla la relación entre p_0 y p_1 sin destruir la recurrencia entre los conteos positivos.

También aquí existe una aclaración notacional obligatoria:

El “1” de $(a, b, 1)$ no significa que el soporte de la distribución tenga que comenzar obligatoriamente en 1.

Una distribución modificada en cero puede conservar:

$$p_0 > 0.$$

El “1” señala el cambio en el punto desde el cual se impone la recurrencia de las probabilidades positivas.

Una versión modificada en cero de una distribución base con probabilidades p_k puede definirse escogiendo una nueva probabilidad:

$$p_0^M$$

y rescalando proporcionalmente las probabilidades positivas:

$$p_k^M = \frac{1 - p_0^M}{1 - p_0} p_k, \quad k \geq 1.$$

Para $k \geq 2$:

$$\frac{p_k^M}{p_{k-1}^M} = \frac{\frac{1-p_0^M}{1-p_0} p_k}{\frac{1-p_0^M}{1-p_0} p_{k-1}} = \frac{p_k}{p_{k-1}} = a + \frac{b}{k}.$$

La probability at zero cambia, pero la estructura recursiva entre positive counts permanece intacta.

Un caso especial es la **distribución truncada en cero**. Supongamos un mecanismo de recolección de datos que contiene únicamente policy-years en los que ocurrió al menos un claim. Entonces las unidades con:

$$N = 0$$

no aparecen en el archivo observado.

Eso no significa que el portfolio subyacente no pueda producir ceros. Significa que la variable observada está condicionada a:

$$N > 0.$$

Para una distribución base con probabilidades p_k :

$$p_0^T = 0,$$

y para:

$$k \geq 1,$$

$$p_k^T = \frac{p_k}{1 - p_0}.$$

Consideremos el caso local de una **distribución discreta de Poisson** con:

$$\lambda = 0.60.$$

La probabilidad base en cero es:

$$p_0 = e^{-0.60} \approx 0.548812.$$

La probabilidad base de un claim es:

$$p_1 = e^{-0.60}(0.60) \approx 0.329287.$$

Al condicionar a $N > 0$:

$$p_1^T = \frac{p_1}{1 - p_0} = \frac{0.329287}{0.451188} \approx 0.729822.$$

A partir de $k = 2$, la recurrencia positiva de Poisson permanece igual:

$$p_2^T = \frac{0.60}{2} p_1^T = 0.30(0.729822) \approx 0.218946,$$

$$p_3^T = \frac{0.60}{3}p_2^T = 0.20(0.218946) \approx 0.043789.$$

Desafío al lector. Si la versión truncada tiene:

$$p_0^T = 0,$$

¿por qué sigue siendo válida la recurrencia Poisson entre las probabilidades positivas?

Porque el truncamiento multiplica todas las probabilidades correspondientes a $k \geq 1$ por el mismo factor:

$$\frac{1}{1 - p_0}.$$

Ese factor se cancela en los cocientes entre probabilidades positivas consecutivas.

La diferencia entre ambas clases puede resumirse así:

Característica	$(a, b, 0)$	$(a, b, 1)$
Recurrencia comienza en	$k = 1$	$k = 2$
p_1 queda ligado directamente a p_0 por la recurrencia	Sí	No necesariamente
Probability at zero modificable independientemente	No dentro de la familia base	Sí
Zero-truncated version como estructura de la clase	No como familia base original	Sí
Recurrencia entre positive counts	Sí	Sí

Ninguna clase es universalmente superior. La diferencia responde a la estructura probabilís-

tica y al mecanismo con el que los datos fueron observados.

2.4.5 La selección del modelo de frecuencia exige interrogar la naturaleza del proceso

Reconocer una fórmula no basta para seleccionar una distribución. El actuario debe examinar qué estructura del fenómeno hace plausible cada modelo.

1. ¿Existe un límite superior natural para el número de claims?

Si existe un número finito real de oportunidades de generar un claim dentro de cada unidad de exposición, una Binomial puede ser apropiada.

Pero Meridiano observó en 2024 un máximo de tres claims por policy-year. Eso no implica que:

$$m = 3.$$

Desafío al lector. Si ningún policy-year observado superó tres claims, ¿podemos concluir que cuatro claims son imposibles?

No. Un maximum observed en una muestra finita no es un maximum estructural del soporte. Para justificar una Binomial debe existir una razón real que limite el número posible de eventos, no simplemente ausencia histórica de observaciones mayores.

2. ¿Cómo se comporta la dispersión?

La relación entre media y varianza sirve como diagnóstico:

- Si $Var(N) \approx E[N]$, una Poisson puede ser un baseline plausible.
- Si $Var(N) < E[N]$, una Binomial puede resultar coherente si existe además una estructura de oportunidades finitas.
- Si $Var(N) > E[N]$, una Binomial Negativa puede ser candidata cuando existe dispersión adicional compatible con heterogeneidad o clustering.

Pero la comparación de momentos no constituye un clasificador automático.

Para Meridiano:

$$E_{\text{emp}}[N] = 0.060,$$

$$Var_{\text{emp}}(N) = 0.0647333,$$

$$\frac{Var_{\text{emp}}(N)}{E_{\text{emp}}[N]} = 1.07889.$$

La Poisson con $\lambda = 0.060$ sigue siendo un baseline razonable porque la dispersión empírica está relativamente cerca de la equidispersión y la frecuencia media es baja.

La Binomial Negativa puede ser una candidata si existe heterogeneidad o clustering persistente que explique dispersión adicional.

La Binomial no queda motivada únicamente por estos momentos porque la varianza empírica no está por debajo de la media y tampoco existe un límite finito declarado para el número de claims por policy-year.

Una versión $(a, b, 1)$ no es necesaria para el dataset completo mientras los policy-years con cero claims sean observables. Podría ser relevante si el mecanismo de datos modifica la probability at zero o excluye los policy-years sin claims.

3. ¿Qué ocurre cuando cambia la unidad de observación?

La tabla anterior trabajó con:

$$N = \text{ground-up claims por policy-year.}$$

Podemos realizar un diagnóstico distinto utilizando ahora el **count agregado mensual de toda la cartera**:

Mes	Claims
Ene	48
Feb	70
Mar	52
Abr	76
May	59
Jun	46
Jul	68
Ago	61
Sep	50
Oct	75
Nov	55
Dic	60
Total	720

La media es:

$$\bar{N}_{\text{mensual}} = \frac{720}{12} = 60 \text{ claims por mes.}$$

La **sample variance** de las doce observaciones mensuales es:

$$s_{\text{mensual}}^2 = 106.91.$$

Por tanto:

$$\frac{s_{\text{mensual}}^2}{\bar{N}_{\text{mensual}}} = \frac{106.91}{60} \approx 1.782.$$

La varianza muestral mensual es aproximadamente **78.2 % mayor** que la media mensual.

Desafío al lector. ¿Demuestra este ratio que los monthly claim counts deben seguir una

Binomial Negativa?

No. Los meses pueden diferir en exposición, estacionalidad, condiciones meteorológicas u otros factores temporales. Una colección de meses que no sean unidades homogéneas puede mostrar una varianza empírica superior a la media sin demostrar que una única estructura Binomial Negativa sea la explicación correcta.

El contraste solo indica que la sobre-dispersión aparente es mucho mayor en la serie mensual agregada que en la distribución anual por policy-year. Antes de atribuir la diferencia a una familia concreta, debemos preguntar si estamos comparando observaciones suficientemente homogéneas.

4. ¿Qué ocurre con los ceros?

Antes de utilizar una clase $(a, b, 1)$, la pregunta esencial es:

¿Los zeros fueron realmente observables?

Si el dataset completo contiene todas las unidades expuestas, incluidas las que no registraron claims, entonces los ceros forman parte natural de la distribución observada.

Si, en cambio, el archivo contiene exclusivamente policy-years con:

$$N > 0,$$

el cero ha sido truncado por el mecanismo de observación.

Si la probability at zero se modifica respecto de una distribución base mientras se conserva la estructura recursiva de los positive counts, puede resultar apropiada una versión zero-modified de la clase $(a, b, 1)$.

No debe confundirse este problema con la severidad contractual de Section 2.3. El hecho de que un claim produzca o no un insurer payment después de un deductible es una transformación distinta de la pregunta de frequency sobre cuántos ground-up claims ocurrieron.

Desafío al lector. Seleccione una familia candidata para cada una de estas tres estructuras:

1. número finito real de oportunidades de producir claims;
2. count no acotado de eventos raros bajo una tasa ampliamente homogénea;
3. count no acotado con dispersión adicional compatible con heterogeneidad o clustering.

Las candidatas naturales son, respectivamente:

1. Binomial;
2. Poisson;
3. Binomial Negativa.

La selección sigue siendo una decisión de modelado basada en soporte, dispersión, zeros y mecanismo, no una consecuencia automática de conocer la media.

Cierre y Puente Final

Al inicio de la sección, Meridiano tenía una cifra aparentemente sencilla:

0.060 claims por policy-year.

Ahora sabemos que ese promedio no determina por sí solo la frecuencia completa.

La experiencia empírica también contiene:

$$Var_{\text{emp}}(N) = 0.0647333,$$

una probability at zero observada de:

$$\frac{11,325}{12,000} = 0.94375,$$

un soporte observado que llega hasta tres claims sin demostrar que tres sea un maximum posible, y más policy-years con múltiples claims que los asignados por una Poisson baseline con:

$$\lambda = 0.060.$$

Esa Poisson reproduce la media por construcción, pero proyecta aproximadamente:

$$20.3$$

policy-years con exactamente dos claims frente a 35 observados, y:

$$0.4$$

con exactamente tres claims frente a 5 observados.

Esto no prueba que otra familia sea correcta. Sí demuestra que:

modelar frecuencia exige más que igualar un promedio.

Las clases $(a, b, 0)$ y $(a, b, 1)$ proporcionan una estructura común para reconocer y calcular distribuciones de frecuencia, mientras que el soporte, la dispersión, la probability at zero y el mecanismo generador determinan qué familias pueden ser plausibles en una aplicación concreta.

Section 2.3 dejó construida la severidad individual. Section 2.4 ha construido ahora:

$$N,$$

el número aleatorio de claims.

El siguiente problema consiste en combinarlos. Si:

$$X_1, X_2, \dots$$

representan las severities de los claims y ocurren N claims, el costo agregado ground-up de la cartera se representará como:

$$S_X = \sum_{i=1}^N X_i.$$

Todavía no calcularemos su media ni su varianza.

La pregunta que abre Section 2.5 es:

¿Cómo se combinan la incertidumbre sobre cuántos claims ocurren y la incertidumbre sobre cuánto cuesta cada uno?

Ejercicios

Ejercicio 1 - Propiedades y recurrencia en la clase $(a, b, 0)$

Considere los siguientes tres modelos locales:

Modelo A

$$N \sim \text{Poisson}(\lambda = 0.060).$$

Modelo B

$$N \sim \text{Binomial}(m = 4, q = 0.20).$$

Modelo C

$$N \sim \text{NB}(r = 2, q = 0.25).$$

Para cada modelo:

1. identifique la familia;
2. obtenga los parámetros recursivos a y b ;
3. calcule p_0, p_1, p_2, p_3 utilizando la recurrencia de la clase $(a, b, 0)$;
4. identifique el soporte;
5. calcule la media y la varianza y clasifique la relación de dispersión.

Criterio de éxito para la solución:

Modelo A - Poisson

$$a = 0, \quad b = 0.060.$$

$$p_0 = e^{-0.06} \approx 0.941765.$$

$$p_1 = 0.06p_0 \approx 0.056506.$$

$$p_2 = \frac{0.06}{2}p_1 \approx 0.001695.$$

$$p_3 = \frac{0.06}{3}p_2 \approx 0.000034.$$

Soporte:

$$\{0, 1, 2, \dots\}.$$

Momentos:

$$E[N] = 0.060,$$

$$Var(N) = 0.060.$$

Existe equidispersión.

Modelo B - Binomial

$$a = -\frac{0.20}{0.80} = -0.25,$$

$$b = \frac{5(0.20)}{0.80} = 1.25.$$

$$p_0 = 0.80^4 = 0.4096.$$

$$p_1 = (-0.25 + 1.25)p_0 = 0.4096.$$

$$p_2 = \left(-0.25 + \frac{1.25}{2}\right)p_1 = 0.1536.$$

$$p_3 = \left(-0.25 + \frac{1.25}{3}\right)p_2 = 0.0256.$$

Soporte:

$$\{0, 1, 2, 3, 4\}.$$

Momentos:

$$E[N] = 4(0.20) = 0.80,$$

$$Var(N) = 4(0.20)(0.80) = 0.64.$$

Existe subdispersión.

Modelo C - Binomial Negativa

$$a = q = 0.25,$$

$$b = q(r - 1) = 0.25.$$

$$p_0 = 0.75^2 = 0.5625.$$

$$p_1 = \left(0.25 + \frac{0.25}{1}\right) p_0 = 0.281250.$$

$$p_2 = \left(0.25 + \frac{0.25}{2}\right) p_1 = 0.105469.$$

$$p_3 = \left(0.25 + \frac{0.25}{3}\right) p_2 \approx 0.035156.$$

Soporte:

$$\{0, 1, 2, \dots\}.$$

Momentos:

$$E[N] = \frac{2(0.25)}{0.75} \approx 0.666667,$$

$$Var(N) = \frac{2(0.25)}{0.75^2} \approx 0.888889.$$

Existe sobre-dispersión.

Ejercicio 2 - Diagnóstico de frecuencia y selección de modelo en Meridiano

Utilice la distribución canónica de Meridiano Seguros:

Claims por policy-year	Policy-years
0	11,325
1	635
2	35
3	5
Total	12,000

Responda:

1. calcule la media empírica;
2. calcule la varianza poblacional empírica;
3. calcule el variance-to-mean ratio;
4. bajo una Poisson con $\lambda = 0.060$, calcule los expected policy-years para $k = 0, 1, 2, 3$;
5. identifique dónde se concentran las diferencias entre observed y expected;
6. proponga una familia alternativa candidata sin afirmar que ha quedado demostrada;
7. explique qué información adicional necesitaría para elegir mejor entre las familias.

Criterio de éxito para la solución:

La media es:

$$E_{\text{emp}}[N] = \frac{720}{12,000} = 0.060.$$

El segundo momento es:

$$E_{\text{emp}}[N^2] = \frac{820}{12,000} = 0.0683333.$$

La varianza es:

$$\text{Var}_{\text{emp}}(N) = 0.0683333 - (0.060)^2 = 0.0647333.$$

El ratio de dispersión es:

$$\frac{0.0647333}{0.060} = 1.07889.$$

Para la Poisson baseline:

$$p_0 \approx 0.941765,$$

$$p_1 \approx 0.056506,$$

$$p_2 \approx 0.001695,$$

$$p_3 \approx 0.000034.$$

Los expected policy-years son aproximadamente:

k	Observed	Poisson expected
0	11,325	11,301.2
1	635	678.1
2	35	20.3
3	5	0.4

La muestra contiene menos one-claim policy-years y más multiple-claim policy-years que esta Poisson baseline.

Una **Binomial Negativa** puede proponerse como candidata porque permite sobre-dispersión y soporte no acotado. Sin embargo, esta observación no demuestra que sea el modelo correcto.

Para elegir mejor sería necesario examinar, entre otros aspectos ya planteados en la sección, si la dispersión adicional persiste al trabajar con unidades comparables, si existe evidencia de heterogeneidad o clustering, cuál es la estructura de zeros y si existe alguna razón estructural para imponer un soporte finito.

La conclusión correcta es diagnóstica:

Los datos sugieren investigar modelos capaces de representar mayor dispersión que Poisson, pero no prueban por sí solos cuál debe elegirse.

Ejercicio 3 - Condicionamiento y recurrencia en la clase $(a, b, 1)$

Se dispone de un sistema de registro construido exclusivamente a partir de las unidades de exposición que registraron al menos un claim. El conteo base sigue:

$$N \sim \text{Poisson}(\lambda = 0.80).$$

Responda:

1. calcule las probabilidades positivas de la distribución truncada en cero hasta p_3^T ;

2. demuestre que la recurrencia Poisson se conserva para $k \geq 2$;
3. identifique si la distribución observada pertenece a la clase $(a, b, 0)$ o $(a, b, 1)$;
4. explique por qué zero recibe un tratamiento diferente en este dataset.

Criterio de éxito para la solución:

Para la Poisson original:

$$p_0 = e^{-0.80} \approx 0.449329.$$

$$p_1 = e^{-0.80}(0.80) \approx 0.359463.$$

Como el dataset excluye por diseño los policy-years con cero claims:

$$p_0^T = 0.$$

La primera probabilidad positiva observada es:

$$p_1^T = \frac{p_1}{1 - p_0} = \frac{0.359463}{1 - 0.449329}$$

$$= \frac{0.359463}{0.550671} \approx 0.652773.$$

La recurrencia positiva conserva:

$$a = 0, \quad b = 0.80.$$

Por tanto:

$$p_2^T = \frac{0.80}{2} p_1^T = 0.40(0.652773) \approx 0.261109,$$

$$p_3^T = \frac{0.80}{3} p_2^T \approx 0.266667(0.261109) \approx 0.069629.$$

El cociente entre las dos primeras probabilidades positivas es:

$$\frac{p_2^T}{p_1^T} = 0.40.$$

En la Poisson base:

$$\frac{p_2}{p_1} = \frac{0.80}{2} = 0.40.$$

El mismo argumento se extiende a los demás $k \geq 2$ porque el factor de truncamiento:

$$\frac{1}{1 - p_0}$$

es común a todas las probabilidades positivas y se cancela al formar cocientes consecutivos.

La distribución observada pertenece a la clase:

$$(a, b, 1),$$

porque la recurrencia relevante empieza en $k = 2$ y el origen ha sido tratado independientemente.

El tratamiento diferente de zero no significa que el portfolio subyacente sea incapaz de producir policy-years sin claims. Los zeros existen en la población original, pero el mecanismo de observación los excluye del archivo. La diferencia entre $(a, b, 0)$ y $(a, b, 1)$ no consiste simplemente en “tener o no tener zero claims”, sino en cómo queda conectado el origen con la recurrencia de los conteos positivos.

2.5 - Aggregate Models

La cartera combina dos incertidumbres: cuántas veces paga y cuánto paga cada vez

2.5.1 La cartera no paga el presupuesto esperado: el costo anual es una suma aleatoria

Al estructurar la tarificación y la solvencia de una compañía de seguros como **Meridiano Seguros**, el análisis individual de reclamaciones resulta insuficiente para estimar la exposición financiera anual del portafolio. Consideremos primero la experiencia histórica completamente desarrollada de la cartera de propiedad comercial durante el **Accident Year 2024**. El sistema registra **12,000 policy-years**, **720 reclamaciones ground-up** y una pérdida ground-up agregada observada de **12,960,000 USD**. La frecuencia empírica es:

$$\frac{720}{12,000} = 0.060 \text{ claims por policy-year,}$$

mientras que la severidad promedio observada de las 720 reclamaciones es:

$$\frac{12,960,000}{720} = 18,000 \text{ USD.}$$

Estas son cantidades **empíricas** del dataset sintético completamente desarrollado de 2024.

Para construir el modelo agregado canónico reutilizaremos esos anchors como parámetros de primer momento:

$$E[N] = 720$$

claims por portfolio-year y:

$$E[X] = 18,000 \text{ USD.}$$

Lucía realiza entonces el cálculo directo:

$$E[N]E[X] = 720(18,000) = \mathbf{12,960,000 \text{ USD}}.$$

La aritmética es correcta. Bajo los supuestos que desarrollaremos a continuación, **12.960 millones de USD es la pérdida agregada esperada del modelo**. Pero no es la cantidad que Meridiano necesariamente pagará en un año futuro.

Irene plantea la pregunta que falta:

Si Meridiano presupuestara exactamente 12.960 millones de USD para losses, ¿qué probabilidad tendría de exceder ese presupuesto?

Conocer únicamente $E[N]$ y $E[X]$ no permite responderla. Tampoco permite determinar la volatilidad agregada, el percentil 95 %, el percentil 99 % ni cómo cambiaría la incertidumbre si la distribución de severidad tuviera una cola distinta.

Además, la coincidencia entre:

$$12.960M \text{ USD}$$

de pérdida ground-up agregada **observada** en 2024 y:

$$E[S_X] = 12.960M \text{ USD}$$

bajo el baseline **no valida el modelo agregado**. Los valores canónicos de frecuencia y severidad media fueron contruidos para reconciliar con esos totales empíricos. Igualar el primer momento no demuestra que la varianza ni la forma de la distribución sean correctas. ¿Qué dos cantidades siguen siendo inciertas antes de conocer el costo total de un nuevo año?

1. cuántos claims ocurrirán;
2. cuánto costará cada claim.

El modelo de riesgo colectivo traduce directamente esas dos fuentes de incertidumbre mediante:

$$S_X = \sum_{i=1}^N X_i,$$

donde:

- N es la variable aleatoria discreta que representa el número total de reclamaciones ground-up durante el portfolio-year;
- X_i es la variable aleatoria que representa la severidad ground-up de la reclamación i ;
- S_X es la pérdida ground-up agregada de la cartera, medida en USD.

El número de términos de la suma es aleatorio y el valor de cada término también lo es. Por tanto, el producto $720(18,000)$ fija únicamente el centro del modelo agregado. El resultado anual real sigue siendo la variable aleatoria S_X .

2.5.2 Dos fuentes de incertidumbre componen la volatilidad agregada de la cartera

Para derivar los momentos estándar del modelo de riesgo colectivo debemos declarar las condiciones bajo las cuales las fórmulas son válidas. En el baseline utilizaremos los siguientes supuestos:

1. Las severidades $X_1, X_2, \dots$ son independientes e idénticamente distribuidas bajo una distribución de severidad común.
2. La variable de conteo N es independiente de las severidades X_i .
3. Los momentos necesarios para cada cálculo existen y son finitos.
4. Cuando utilicemos el baseline Poisson, su tasa de ocurrencia se considera estacionaria dentro del periodo anual modelado.

Estos supuestos describen el **mundo del modelo**. No son afirmaciones universales sobre todas las carteras de seguros.

La herramienta central para comprender la suma aleatoria consiste en condicionar primero sobre el número de claims. Si conocemos que exactamente $N = n$, entonces:

$$S_X \mid N = n = X_1 + \cdots + X_n.$$

Bajo independencia e idéntica distribución de las severidades:

$$E[S_X \mid N = n] = nE[X],$$

y:

$$Var(S_X \mid N = n) = nVar(X).$$

Como estas relaciones son válidas para cualquier n , podemos escribir:

$$E[S_X \mid N] = NE[X]$$

y:

$$Var(S_X \mid N) = NVar(X).$$

Aplicando la **ley de la esperanza total**:

$$E[S_X] = E[E[S_X \mid N]].$$

Sustituyendo la esperanza condicional:

$$E[S_X] = E[NE[X]] = E[N]E[X].$$

Por tanto:

$$\boxed{E[S_X] = E[N]E[X]}.$$

La interpretación económica es directa:

La pérdida agregada esperada es el número esperado de claims multiplicado por el costo esperado por claim.

En el baseline canónico:

$$E[S_X] = 720(18,000) = \boxed{12,960,000 \text{ USD}}.$$

La varianza requiere un paso adicional porque el número de términos de la suma también fluctúa. Utilizamos la **ley de la varianza total**:

$$\text{Var}(S_X) = E[\text{Var}(S_X | N)] + \text{Var}(E[S_X | N]).$$

El primer término es:

$$E[\text{Var}(S_X | N)] = E[N\text{Var}(X)] = E[N]\text{Var}(X).$$

El segundo es:

$$\text{Var}(E[S_X | N]) = \text{Var}(NE[X]) = \text{Var}(N)(E[X])^2.$$

Así obtenemos:

$$\boxed{\text{Var}(S_X) = E[N]\text{Var}(X) + \text{Var}(N)(E[X])^2}.$$

La fórmula muestra dos fuentes separadas de incertidumbre.

El componente:

$$E[N]Var(X)$$

representa la incertidumbre producida por **no saber cuánto costará cada claim**.

El componente:

$$Var(N)(E[X])^2$$

representa la incertidumbre producida por **no saber cuántos claims ocurrirán**, es decir, por la fluctuación del count alrededor de su valor esperado.

Antes de sustituir números, conviene aislar cada fuente.

Si la severidad fuera completamente fija en:

$$18,000 \text{ USD},$$

entonces:

$$Var(X) = 0.$$

¿Sería cero la varianza agregada?

No necesariamente. Si N continuara siendo aleatorio:

$$Var(S_X) = Var(N)(18,000)^2 > 0.$$

Ahora invirtamos el escenario. Si el claim count fuera fijo exactamente en:

$$N = 720,$$

pero las severidades continuaran siendo aleatorias, la frecuencia dejaría de aportar varianza, pero permanecería:

$$Var(S_X) = 720Var(X).$$

Por tanto, **aggregate variance no es simplemente severity variance multiplicada por expected claim count**. La incertidumbre de frecuencia aporta un segundo término.

Para un modelo Poisson con parámetro λ :

$$N \sim Poisson(\lambda),$$

se cumple:

$$E[N] = Var(N) = \lambda.$$

En ese caso particular:

$$Var(S_X) = \lambda Var(X) + \lambda(E[X])^2.$$

Factorizando:

$$Var(S_X) = \lambda (Var(X) + (E[X])^2).$$

Como:

$$E[X^2] = Var(X) + (E[X])^2,$$

obtenemos la simplificación:

$$\boxed{Var(S_X) = \lambda E[X^2]}.$$

Esta expresión **no es la fórmula general de cualquier modelo agregado**. Surge específicamente porque, bajo Poisson:

$$Var(N) = E[N] = \lambda.$$

2.5.3 Una misma media agregada puede esconder perfiles de riesgo y volatilidades incompatibles

Consideremos ahora el **modelo agregado de referencia** de Meridiano:

$$N \sim Poisson(720).$$

Por tanto:

$$E[N] = Var(N) = 720.$$

Comenzamos con el Modelo A de severidad desarrollado en Section 2.2:

$$X_i \sim Lognormal(\mu, \sigma^2),$$

con parámetros canónicos:

$$\mu = \ln(9,000),$$

$$\sigma = \sqrt{2 \ln 2}.$$

Este es un **modelo candidato** de severidad, no una afirmación de que la distribución empírica verdadera de Meridiano sea exactamente Lognormal.

Bajo el Modelo A:

$$E[X] = 18,000 \text{ USD},$$

y:

$$Var(X) = 972,000,000 \text{ USD}^2.$$

El segundo momento ordinario es:

$$E[X^2] = Var(X) + (E[X])^2.$$

Entonces:

$$E[X^2] = 972,000,000 + 18,000^2$$

$$= 972,000,000 + 324,000,000$$

$$= \boxed{1,296,000,000 \text{ USD}^2}.$$

La pérdida agregada esperada derivada del modelo es:

$$E[S_X] = 720(18,000) = \boxed{12,960,000 \text{ USD}}.$$

Para la varianza, el componente de severidad es:

$$E[N]Var(X) = 720(972,000,000)$$

$$= \boxed{699,840,000,000 \text{ USD}^2}.$$

El componente de frecuencia es:

$$\begin{aligned} Var(N)(E[X])^2 &= 720(18,000)^2 \\ &= \boxed{233,280,000,000 \text{ USD}^2}. \end{aligned}$$

La reconciliación es:

$$699,840,000,000 + 233,280,000,000 = \boxed{933,120,000,000 \text{ USD}^2}.$$

En este baseline, el componente de severidad representa exactamente:

$$\frac{699,840,000,000}{933,120,000,000} = \boxed{75.00 \%}$$

de la varianza agregada, mientras que el componente de frecuencia representa:

$$\frac{233,280,000,000}{933,120,000,000} = \boxed{25.00 \%}.$$

La desviación estándar agregada derivada del modelo es:

$$\begin{aligned} SD(S_X) &= \sqrt{933,120,000,000} \\ &\approx \boxed{965,981.37 \text{ USD}}. \end{aligned}$$

Editorialmente:

$$SD(S_X) \approx \boxed{0.966M \text{ USD}}.$$

El coeficiente de variación agregado es:

$$CV(S_X) = \frac{965,981.37}{12,960,000} \approx \boxed{7.45\%}.$$

La mayor contribución a la varianza procede de la severidad **en este baseline particular**. Esa proporción no es una propiedad universal: cambiaría si cambiaran $Var(N)$, $E[X]$ o $Var(X)$.

Ahora mantengamos exactamente:

$$E[N] = 720$$

y:

$$E[X] = 18,000 \text{ USD},$$

pero sustituyamos la severidad Lognormal por el Modelo B canónico de Section 2.2, una Lomax / Pareto Tipo II con:

$$\alpha = 2.2$$

y:

$$\theta = 21,600 \text{ USD}.$$

Antes de calcular, la pregunta es:

Si la frecuencia esperada y la severidad media no cambian, ¿debería cambiar el riesgo agregado?

La media agregada no cambia:

$$E[S_X] = 720(18,000) = \boxed{12.960M \text{ USD}}.$$

Sin embargo, bajo la severidad Lomax:

$$Var(X) = 3,564,000,000 \text{ USD}^2.$$

Por tanto:

$$E[X^2] = 3,564,000,000 + 324,000,000$$

$$= \boxed{3,888,000,000 \text{ USD}^2}.$$

Como la frecuencia sigue siendo Poisson:

$$Var(S_X) = 720(3,888,000,000)$$

$$= \boxed{2,799,360,000,000 \text{ USD}^2}.$$

Y:

$$SD(S_X) = \sqrt{2,799,360,000,000}$$

$$\approx \boxed{1,673,128.81 \text{ USD}}.$$

Editorialmente:

$$SD(S_X) \approx \boxed{1.673M \text{ USD}}.$$

La desviación estándar agregada aumenta desde aproximadamente:

0.966M USD

hasta:

1.673M USD,

un incremento aproximado de:

73.21 %.

La comparación puede resumirse así:

Quantity	Severidad Lognormal	Severidad Lomax
$E[X]$	18,000 USD	18,000 USD
$E[N]$	720	720
$E[S_X]$	12.960M USD	12.960M USD
$SD(S_X)$	$\approx 0.966M$ USD	$\approx 1.673M$ USD

La conclusión es fundamental:

La misma pérdida agregada esperada no implica el mismo riesgo agregado.

El cambio procede de la mayor varianza y del mayor segundo momento de la severidad bajo el Modelo B. La media anual permanece fija mientras cambia sustancialmente la dispersión del costo total.

La frecuencia también podría alterar esta conclusión por otra vía. Si $E[N]$ permaneciera en 720 pero $Var(N)$ aumentara, entonces:

$$E[S_X] = E[N]E[X]$$

permanecería igual, pero:

$$Var(N)(E[X])^2$$

aumentaría. Esta es la consecuencia agregada directa de la dispersión de frecuencia estudiada en Section 2.4.

2.5.4 El modelo de riesgo individual expone el aporte específico de cada exposición

El modelo colectivo organiza la incertidumbre empezando por una variable aleatoria de claim count N . No siempre esa es la representación más natural.

Cuando el número de unidades de exposición es conocido de antemano, podemos modelar directamente la contribución aleatoria de cada una mediante el **modelo de riesgo individual**.

Para n exposiciones conocidas definimos:

$$S^{\text{ind}} = \sum_{i=1}^n Z_i,$$

donde Z_i representa la pérdida total de la exposición i durante el periodo. A diferencia de X_i en el modelo colectivo, Z_i puede ser igual a cero.

Siempre que existan las esperanzas:

$$E[S^{\text{ind}}] = \sum_{i=1}^n E[Z_i].$$

No es necesario que las exposiciones tengan distribuciones idénticas.

Si además $Z_1, \dots, Z_n$ son mutuamente independientes:

$$\boxed{Var(S^{\text{ind}}) = \sum_{i=1}^n Var(Z_i)}.$$

La representación Bernoulli que utilizaremos a continuación **no define el modelo individual en general**. Es únicamente una simplificación del mini-caso pedagógico local.

Consideremos tres exposiciones independientes A, B y C. Para este ejemplo definimos:

$$Z_i = B_i I_i,$$

donde I_i es un indicador Bernoulli de ocurrencia de claim con probabilidad q_i y B_i es una pérdida fija si ocurre el claim.

Este es un **ejemplo pedagógico local; no pertenece al canon de Meridiano**.

Para la Póliza A:

$$q_A = 10\%,$$

$$B_A = 10,000 \text{ USD}.$$

Entonces:

$$E[Z_A] = 0.10(10,000) = \mathbf{1,000 \text{ USD}},$$

y:

$$Var(Z_A) = 0.10(0.90)(10,000)^2 = \mathbf{9,000,000 \text{ USD}^2}.$$

Para la Póliza B:

$$q_B = 5\%,$$

$$B_B = 20,000 \text{ USD.}$$

Entonces:

$$E[Z_B] = 0.05(20,000) = \mathbf{1,000 \text{ USD}},$$

y:

$$Var(Z_B) = 0.05(0.95)(20,000)^2 = \mathbf{19,000,000 \text{ USD}^2}.$$

Para la Póliza C:

$$q_C = 20 \%,$$

$$B_C = 5,000 \text{ USD.}$$

Entonces:

$$E[Z_C] = 0.20(5,000) = \mathbf{1,000 \text{ USD}},$$

y:

$$Var(Z_C) = 0.20(0.80)(5,000)^2 = \mathbf{4,000,000 \text{ USD}^2}.$$

La pérdida esperada agregada es:

$$E[S^{\text{ind}}] = 1,000 + 1,000 + 1,000 = \boxed{3,000 \text{ USD}}.$$

Por independencia:

$$Var(S^{\text{ind}}) = 9,000,000 + 19,000,000 + 4,000,000$$

$$= \boxed{32,000,000 \text{ USD}^2}.$$

La desviación estándar es:

$$SD(S^{\text{ind}}) = \sqrt{32,000,000} \approx \boxed{5,656.85 \text{ USD}}.$$

Las tres pólizas tienen exactamente el mismo expected loss individual:

$$1,000 \text{ USD}.$$

Sin embargo, no aportan la misma varianza.

La Póliza C aporta:

$$\frac{4,000,000}{32,000,000} = \boxed{12.50 \%},$$

mientras que la Póliza B aporta:

$$\frac{19,000,000}{32,000,000} = \boxed{59.38 \%}.$$

Por tanto, igual expected loss individual no implica igual contribución a la volatilidad agregada.

2.5.5 La aproximación Normal impone simetría pero simplifica el cálculo del centro

Conocer:

$$E[S_X]$$

y:

$$Var(S_X)$$

no determina por sí solo la distribución completa de S_X . Para el baseline compuesto, la distribución exacta puede ser más difícil de obtener que sus dos primeros momentos. El syllabus introduce aquí dos aproximaciones: Normal y Lognormal.

La primera pregunta es si una distribución simétrica puede representar razonablemente el centro y la dispersión del agregado.

Antes de utilizar la aproximación Normal en el baseline de Meridiano observamos que:

- hay un número esperado elevado de contribuciones, $E[N] = 720$;
- la media agregada, 12.960M USD, es superior a trece desviaciones estándar;
- la varianza de la severidad Lognormal es finita;
- aun así, la severidad individual es asimétrica y la representación de la parte superior de la distribución puede ser relevante;
- los percentiles superiores que calcularemos dependen de la forma que la aproximación imponga.

Estas condiciones pueden hacer útil una aproximación Normal, pero no convierten la pérdida agregada en exactamente Normal.

Aproximamos S_X mediante una distribución Normal con:

$$m = E[S_X]$$

y:

$$v = \text{Var}(S_X).$$

Escribimos:

$$S_X \approx \text{Normal}(m, v).$$

La aproximación conserva exactamente los dos primeros momentos utilizados en la calibración:

$$E[S] \approx m$$

y:

$$\text{Var}(S) \approx v,$$

pero impone además simetría, soporte sobre toda la recta real y el comportamiento de cola propio de una Normal.

Para un percentil de nivel p :

$$s_p \approx m + z_p \sqrt{v},$$

donde z_p es el percentil correspondiente de la Normal estándar.

En el baseline:

$$m = 12,960,000 \text{ USD},$$

$$v = 933,120,000,000 \text{ USD}^2,$$

y:

$$\sqrt{v} = 965,981.3663 \text{ USD.}$$

Para el percentil 95 %, utilizando:

$$z_{0.95} \approx 1.6448536,$$

obtenemos:

$$s_{0.95}^N \approx 12,960,000 + 1.6448536(965,981.3663)$$

$$\approx \boxed{14,548,898 \text{ USD}}.$$

Editorialmente:

$$\boxed{s_{0.95}^N \approx 14.549M \text{ USD}}.$$

Para el percentil 99 %, con:

$$z_{0.99} \approx 2.3263479,$$

obtenemos:

$$s_{0.99}^N \approx 12,960,000 + 2.3263479(965,981.3663)$$

$$\approx \boxed{15,207,209 \text{ USD}}.$$

Editorialmente:

$$s_{0.99}^N \approx 15.207M \text{ USD}.$$

La Normal asigna alguna probabilidad a:

$$S_X < 0,$$

lo que es incompatible con una pérdida ground-up no negativa. En este caso esa probabilidad es despreciable porque:

$$\frac{E[S_X]}{SD(S_X)} > 13.$$

Por tanto, la principal cuestión práctica del baseline no es el pequeño defecto de soporte en la región negativa, sino qué tan bien una distribución simétrica puede representar la asimetría y la parte superior de la distribución agregada.

No podemos concluir únicamente a partir de los dos primeros momentos que la Normal subestime o sobreestime sistemáticamente la cola verdadera. Lo que sí sabemos es que **impone asimetría nula**, y por ello puede representar de forma imperfecta una distribución agregada cuya forma real no conocemos únicamente a partir de m y v .

Tampoco debemos razonar:

“Con 720 expected claims, la pérdida agregada es Normal.”

Muchos claims pueden favorecer una aproximación de este tipo bajo condiciones apropiadas, pero su calidad depende también de la asimetría, la cola, la existencia de momentos, la concentración y la estructura de frecuencia.

2.5.6 La aproximación Lognormal respeta la naturaleza no negativa y asimétrica de las pérdidas

Podemos construir una segunda aproximación que conserve la misma media y varianza, evite valores negativos y permita asimetría positiva.

Antes de utilizarla debemos hacer explícito qué estamos imponiendo:

- queremos una aproximación que no asigne pérdidas negativas;
- permitimos right skewness;
- equipararemos exactamente mean y variance;
- al hacerlo imponemos también la forma de cola Lognormal, que no queda determinada por esos dos momentos.

Por tanto, la elección tampoco demuestra que la pérdida agregada verdadera sea Lognormal.

Definimos una variable aproximante:

$$S^{LN} \sim \text{Lognormal}(\mu_S, \sigma_S^2),$$

tal que:

$$E[S^{LN}] = m$$

y:

$$\text{Var}(S^{LN}) = v.$$

Para una Lognormal:

$$\sigma_S^2 = \ln \left(1 + \frac{v}{m^2} \right)$$

y:

$$\mu_S = \ln(m) - \frac{\sigma_S^2}{2}.$$

La notación requiere cuidado. Los parámetros:

$$\mu_S, \sigma_S$$

pertenecen a la **aproximación Lognormal de la pérdida agregada**. No son los mismos parámetros:

$$\mu, \sigma$$

de la severidad Lognormal individual de Section 2.2.

Que cada X_i del Modelo A sea Lognormal **no implica** que:

$$S_X = \sum_{i=1}^N X_i$$

sea exactamente Lognormal. Incluso una suma fija de variables Lognormales independientes no es, en general, exactamente Lognormal; aquí utilizamos una **aproximación moment-matched**.

Para el baseline:

$$m = 12,960,000 \text{ USD},$$

$$v = 933,120,000,000 \text{ USD}^2.$$

Entonces:

$$\frac{v}{m^2} = \frac{933,120,000,000}{12,960,000^2} \approx 0.00555556.$$

Por tanto:

$$\sigma_S^2 = \ln(1 + 0.00555556) \approx \boxed{0.00554018}.$$

Manteniendo precisión completa durante los cálculos:

$$\sigma_S \approx \boxed{0.0744324}.$$

Además:

$$\mu_S = \ln(12,960,000) - \frac{0.00554018}{2}$$

$$\approx \boxed{16.37461},$$

cuando S se expresa en USD.

Los percentiles aproximados se calculan mediante:

$$s_p^{LN} = \exp(\mu_S + \sigma_S z_p).$$

Utilizando los parámetros con precisión completa, el percentil 95 % es:

$$s_{0.95}^{LN} \approx \boxed{14,607,396 \text{ USD}}.$$

Editorialmente:

$$\boxed{s_{0.95}^{LN} \approx 14.607M \text{ USD}}.$$

El percentil 99 % es:

$$s_{0.99}^{LN} \approx \boxed{15,367,474 \text{ USD}}.$$

Editorialmente:

$$\boxed{s_{0.99}^{LN} \approx 15.367M \text{ USD}}.$$

Esta aproximación evita valores negativos y permite right skewness. Sin embargo, no reproduce exactamente todas las características del compound Poisson subyacente. En particular, una Lognormal tiene soporte estrictamente positivo, mientras que el modelo compuesto con un count Poisson conserva formalmente la posibilidad de pérdida agregada igual a cero cuando no ocurre ningún claim. Con $\lambda = 720$, esa diferencia de soporte no es material para los percentiles analizados, pero impide afirmar que la aproximación reproduzca rigurosamente toda la distribución exacta.

Tampoco podemos afirmar que la aproximación Lognormal “preserve” la asimetría verdadera de S_X . Lo que hace es **imponer una forma asimétrica positiva** compatible con los dos momentos equiparados.

2.5.7 Dos momentos idénticos no determinan la cola de la distribución agregada

Antes de comparar resultados, planteemos una última intuición:

Si las aproximaciones Normal y Lognormal comparten exactamente la misma media y la misma varianza, ¿deben producir los mismos percentiles?

No.

Ambas aproximaciones utilizan:

$$E[S] = 12.960M \text{ USD}$$

y:

$$Var(S) = 933,120,000,000 \text{ USD}^2,$$

pero imponen formas diferentes.

Percentil	Aproximación Normal	Aproximación Lognormal	Diferencia entre aproximaciones
95 %	14,548,898 USD	14,607,396 USD	+58,498 USD
99 %	15,207,209 USD	15,367,474 USD	+160,266 USD

Al 95 %, la diferencia es aproximadamente:

58,498 USD.

Al 99 % aumenta aproximadamente a:

160,266 USD.

La diferencia no surge de la media ni de la varianza: ambas son iguales por construcción. Surge de las **assumptions adicionales de forma**.

La Normal impone:

- simetría;
- soporte sobre toda la recta real;
- comportamiento de cola Normal.

La Lognormal impone:

- soporte estrictamente positivo;
- asimetría positiva;
- comportamiento de cola Lognormal.

En este caso concreto, la aproximación Lognormal produce percentiles superiores a la Normal. Eso **no demuestra** que sea necesariamente más cercana a la cola exacta del modelo compuesto, ni que una Normal vaya a subestimar sistemáticamente el riesgo verdadero.

La enseñanza que sí podemos defender es:

Los dos primeros momentos no determinan la distribución completa.

Por tanto, una aproximación no debe juzgarse únicamente porque conserve mean y variance. También debemos preguntar qué soporte, asimetría y forma de cola introduce, y qué región de la distribución importa para la decisión que estamos estudiando.

Ejercicios

Ejercicio 1 - Descomposición de la varianza en el modelo colectivo

Se modela la pérdida agregada anual S_X de una cartera de seguros de transporte mediante un modelo de riesgo colectivo. La frecuencia de las reclamaciones anuales sigue una distribución Poisson con media:

$$E[N] = 500.$$

Por la propiedad Poisson:

$$Var(N) = 500.$$

La severidad ground-up individual X_i se modela mediante una distribución Exponencial con:

$$E[X] = 8,000 \text{ USD}.$$

1. Calcule $E[S_X]$.
2. Calcule $Var(X)$ y $SD(X)$.
3. Calcule $Var(S_X)$ y separe el resultado en el componente de severidad y el componente de frecuencia.
4. Explique qué incertidumbre representa cada componente.
5. Explique qué ocurriría con la desviación estándar agregada si el número esperado de reclamaciones se duplicara de 500 a 1,000 manteniendo la severidad constante.

Criterio de éxito para la solución:

Para una Exponencial parametrizada por su media:

$$Var(X) = 8,000^2 = \boxed{64,000,000 \text{ USD}^2},$$

y:

$$SD(X) = \boxed{8,000 \text{ USD}}.$$

La pérdida agregada esperada es:

$$E[S_X] = 500(8,000) = \boxed{4,000,000 \text{ USD}}.$$

El componente de severidad es:

$$E[N]Var(X) = 500(64,000,000) = \boxed{32,000,000,000 \text{ USD}^2}.$$

El componente de frecuencia es:

$$Var(N)(E[X])^2 = 500(8,000)^2 = \boxed{32,000,000,000 \text{ USD}^2}.$$

Cada componente representa el 50 % de la varianza total:

$$Var(S_X) = 32,000,000,000 + 32,000,000,000$$

$$= \boxed{64,000,000,000 \text{ USD}^2}.$$

La desviación estándar agregada es:

$$SD(S_X) = \sqrt{64,000,000,000} \approx \boxed{252,982.21 \text{ USD}}.$$

Si:

$$\lambda = 1,000,$$

entonces:

$$Var(S_X) = 1,000(128,000,000) = 128,000,000,000 \text{ USD}^2,$$

y:

$$SD(S_X) = \sqrt{128,000,000,000} \approx \boxed{357,770.88 \text{ USD}}.$$

La varianza se duplica, pero la desviación estándar aumenta en un factor:

$$\sqrt{2},$$

es decir, aproximadamente:

$$41.42 \, \%.$$

Ejercicio 2 - Volatilidad en el modelo de riesgo individual heterogéneo

Un portafolio local e independiente de seguros comerciales está compuesto por exactamente tres asegurados. Para este ejercicio se utiliza el caso simplificado:

$$Z_i = B_i I_i,$$

donde I_i es un indicador Bernoulli independiente de ocurrencia de reclamación con probabilidad q_i , y B_i representa una pérdida fija si ocurre el siniestro.

Probabilidad de ocurrencia		
Asegurado i	q_i	Siniestro condicional B_i
Asegurado 1	2 %	500,000 USD
Asegurado 2	1 %	1,000,000 USD
Asegurado 3	4 %	250,000 USD

1. Calcule $E[Z_i]$ para cada asegurado y el expected loss agregado.
2. Calcule $Var(Z_i)$ para cada asegurado.
3. Calcule $Var(S^{\text{ind}})$ y $SD(S^{\text{ind}})$.
4. Identifique cuantitativamente qué exposición aporta el mayor porcentaje de la varianza agregada y justifique cómo podría reducirse esa concentración mediante un deducible individual o reaseguro proporcional.

Criterio de éxito para la solución:

Los expected losses individuales son:

$$E[Z_1] = 0.02(500,000) = \boxed{10,000 \text{ USD}},$$

$$E[Z_2] = 0.01(1,000,000) = \boxed{10,000 \text{ USD}},$$

y:

$$E[Z_3] = 0.04(250,000) = \boxed{10,000 \text{ USD}}.$$

Por tanto:

$$E[S^{\text{ind}}] = 10,000 + 10,000 + 10,000 = \boxed{30,000 \text{ USD}}.$$

Las varianzas individuales son:

$$\text{Var}(Z_1) = 0.02(0.98)(500,000)^2 = \boxed{4,900,000,000 \text{ USD}^2},$$

$$\text{Var}(Z_2) = 0.01(0.99)(1,000,000)^2 = \boxed{9,900,000,000 \text{ USD}^2},$$

y:

$$\text{Var}(Z_3) = 0.04(0.96)(250,000)^2 = \boxed{2,400,000,000 \text{ USD}^2}.$$

Por independencia:

$$\text{Var}(S^{\text{ind}}) = 4,900,000,000 + 9,900,000,000 + 2,400,000,000$$

$$= \boxed{17,200,000,000 \text{ USD}^2}.$$

La desviación estándar es:

$$SD(S^{\text{ind}}) = \sqrt{17,200,000,000} \approx \boxed{131,148.77 \text{ USD}}.$$

El Asegurado 2 aporta:

$$\frac{9,900,000,000}{17,200,000,000} \approx \boxed{57.56 \%}$$

de la varianza agregada, aunque los tres asegurados tengan el mismo expected loss de 10,000 USD.

Ejercicio 3 - Calibración y percentiles bajo aproximaciones Normal y Lognormal

Se modela el costo de reclamaciones de una cartera mediante un modelo de riesgo colectivo con:

$$E[S_X] = 1,000,000 \text{ USD}$$

y:

$$Var(S_X) = 25,000,000,000 \text{ USD}^2.$$

1. Bajo una aproximación Normal equiparada en momentos, calcule la desviación estándar y los percentiles 95 % y 99 %, utilizando $z_{0.95} \approx 1.6448536$ y $z_{0.99} \approx 2.3263479$.
2. Calibre los parámetros μ_S y σ_S^2 de una aproximación Lognormal moment-matched.
3. Calcule los percentiles aproximados 95 % y 99 % bajo la Lognormal. Mantenga full precision en los cálculos intermedios y redondee únicamente al reportar los resultados.
4. Compare las diferencias absolutas y porcentuales entre ambos métodos. Explique por qué pueden producir resultados distintos aunque compartan mean y variance, e identifique qué assumption adicional de forma introduce cada aproximación.

Criterio de éxito para la solución:

La desviación estándar agregada es:

$$SD(S_X) = \sqrt{25,000,000,000}$$

$$\approx \boxed{158,113.88 \text{ USD}}.$$

Bajo la aproximación Normal, el percentil 95 % es:

$$s_{0.95}^N = 1,000,000 + 1.6448536(158,113.8830)$$

$$\approx \boxed{1,260,074.19 \text{ USD}}.$$

El percentil 99 % es:

$$s_{0.99}^N = 1,000,000 + 2.3263479(158,113.8830)$$

$$\approx \boxed{1,367,827.90 \text{ USD}}.$$

Para la aproximación Lognormal:

$$\sigma_S^2 = \ln \left(1 + \frac{25,000,000,000}{1,000,000^2} \right)$$

$$= \ln(1.025) \approx \boxed{0.02469261}.$$

Entonces:

$$\sigma_S = \sqrt{0.02469261259} \approx \boxed{0.15713883}.$$

Además:

$$\mu_S = \ln(1,000,000) - \frac{0.02469261259}{2}$$

$$\approx \boxed{13.80316425}.$$

Utilizando los parámetros con precisión completa, para el percentil 95 %:

$$\mu_S + \sigma_S z_{0.95} \approx 14.06163463,$$

por lo que:

$$s_{0.95}^{LN} = \exp(14.06163463) \approx \boxed{1,279,058.25 \text{ USD}}.$$

Para el percentil 99 %:

$$\mu_S + \sigma_S z_{0.99} \approx 14.16872384,$$

y:

$$s_{0.99}^{LN} = \exp(14.16872384) \approx \boxed{1,423,634.75 \text{ USD}}.$$

Al 95 %, la diferencia absoluta es:

$$1,279,058.25 - 1,260,074.19 = \boxed{18,984.06 \text{ USD}}.$$

Respecto del percentil Normal:

$$\frac{18,984.06}{1,260,074.19} \approx \boxed{1.51 \%}.$$

Al 99 %, la diferencia absoluta es:

$$1,423,634.75 - 1,367,827.90 = \boxed{55,806.85 \text{ USD}}.$$

Respecto del percentil Normal:

$$\frac{55,806.85}{1,367,827.90} \approx \boxed{4.08 \%}.$$

En este ejemplo la Lognormal produce percentiles superiores porque impone una distribución positivamente sesgada, mientras que la Normal impone simetría. Esa diferencia **no prueba** que la Lognormal reproduzca mejor la cola exacta del modelo subyacente. Demuestra únicamente que dos aproximaciones con la misma mean y variance pueden generar percentiles distintos cuando introducen assumptions diferentes sobre la forma de la distribución.

Cierre y Puente Final

Al comienzo de la sección:

$$720(18,000) = 12.960M \text{ USD}$$

parecía responder cuánto costaría la cartera.

Ahora sabemos que esa cantidad representa únicamente:

$$E[S_X].$$

Bajo el baseline Poisson con severidad Lognormal canónica:

$$SD(S_X) \approx \boxed{0.966M \text{ USD}}.$$

Al mantener la misma frecuencia esperada y la misma severidad media, pero sustituir la severidad por la Lomax canónica:

$$SD(S_X) \approx \boxed{1.673M \text{ USD}}.$$

Por tanto, la misma expected aggregate loss puede coexistir con volatilidades muy diferentes.

Incluso cuando fijamos el mismo:

$$E[S]$$

y el mismo:

$$Var(S),$$

las aproximaciones Normal y Lognormal producen percentiles superiores distintos:

$$14.549M \quad \text{vs.} \quad 14.607M$$

al 95 %, y:

$$15.207M \quad \text{vs.} \quad 15.367M$$

al 99 %.

La conclusión es:

Expected loss nos dice dónde está el centro de la cartera. Frequency variance, severity variance y distribution shape nos dicen cuánto puede alejarse de él.

Ahora que tenemos un modelo de pérdida agregada y podemos aproximar su distribución, queda una pregunta distinta: **¿cómo resumimos esa distribución para una decisión de riesgo?**

Podemos observar mean, standard deviation o percentiles, pero cada resumen conserva información diferente y descarta otra.

¿Qué cifra representa mejor una preocupación de cola: un umbral o la pérdida promedio una vez superado ese umbral?

2.6 - Risk Measures

Un solo número decide qué parte de la cola dejamos de mirar

2.6.1 El percentil define la frontera de la cola pero ignora lo que ocurre dentro de ella

En la Section 2.5 construimos distribuciones aproximadas para la pérdida agregada anual de Meridiano Seguros. Bajo el baseline Poisson-Lognormal, la aproximación Normal produjo el siguiente resultado:

RESULTADO APROXIMADO DE SECTION 2.5.

$$P_{95}(S_X) \approx 14.549 \text{ millones USD.}$$

Allí lo llamamos simplemente percentil 95 de la distribución agregada aproximada. Si ahora el comité de riesgo pide una cifra que solo debería ser superada aproximadamente en el 5 % de los outcomes del modelo, ese mismo percentil adquiere una función de decisión. Lo llamamos **Valor en Riesgo** (*Value at Risk*, VaR):

$$VaR_{0.95}(S_X) \approx 14.549 \text{ millones USD.}$$

El cambio de nombre no convierte el percentil en una pérdida máxima ni en una garantía de solvencia. Solo identifica un threshold de la distribución utilizada.

Para una variable aleatoria de pérdida X con función de distribución acumulada $F_X(x)$, el Valor en Riesgo a nivel $p \in (0, 1)$ se define como

$$VaR_p(X) = \inf\{x : F_X(x) \geq p\}.$$

Cuando X es continua y F_X es invertible,

$$VaR_p(X) = F_X^{-1}(p).$$

El nivel p es adimensional; $VaR_p(X)$ tiene las mismas unidades que X . Por tanto, no tiene sentido decir que “el VaR es 95 %”. La forma correcta es, por ejemplo,

$$VaR_{0.95}(X) = 62,420 \text{ USD}.$$

Para $p = 0.95$, VaR responde: **¿qué loss threshold deja aproximadamente el 95 % de los outcomes en o debajo de él?** No responde cuánto vale, en promedio, el 5 % que queda por encima. Irene resume la limitación con una pregunta: si dos modelos colocan el inicio del peor 5 % casi en el mismo punto, ¿sabemos también que las pérdidas dentro de ese 5 % son parecidas?

En una distribución continua, el hecho de que $VaR_{0.95}(X) = q$ implica que queda aproximadamente un 5 % de probability por encima de q . Por eso, llamar a q “la pérdida máxima con 95 % de confianza” confunde un cuantil con un límite superior. El modelo admite outcomes mayores que q ; VaR simplemente no describe su magnitud. Esa omisión es precisamente la información que necesitaremos recuperar a continuación.

2.6.2 El Valor en Riesgo de Cola integra la severidad promedio de los escenarios extremos

La pregunta que VaR deja abierta crea la necesidad de una segunda medida. El **Valor en Riesgo de Cola** (*Tail Value at Risk*, $TVaR$) resume los cuantiles contenidos en la cola situada por encima del nivel p :

$$TVaR_p(X) = \frac{1}{1-p} \int_p^1 VaR_u(X) du,$$

cuando la cantidad está bien definida.

Esta definición mediante integral de cuantiles es la base general y permite trabajar también con distribuciones discretas o mixtas. Para una distribución continua, bajo las condiciones apropiadas,

$$TVaR_p(X) = E[X \mid X > VaR_p(X)].$$

Así, $VaR_{0.95}$ pregunta dónde comienza aproximadamente el peor 5%, mientras que $TVaR_{0.95}$ pregunta cuál es la pérdida promedio dentro de esa cola.

La equivalencia con una esperanza condicional requiere cuidado cuando existe probabilidad concentrada exactamente en $VaR_p(X)$. En una distribución discreta puede ser necesario tomar solo una fracción de la masa situada en el threshold para completar exactamente el peor $1-p$ de probabilidad. Por eso, en esos casos utilizaremos directamente la definición integral de cuantiles.

$TVaR$ tampoco es simplemente “un VaR más conservador”. Es una funcional distinta de la distribución: conserva información sobre la magnitud de los outcomes dentro de la cola que VaR descarta.

Pregunta de cola	Medida	Información que no responde por sí sola
¿Dónde comienza aproximadamente el peor 5 %?	$VaR_{0.95}$	Qué tan grandes son los outcomes posteriores
¿Cuál es la pérdida promedio dentro de ese peor 5 %?	$TVaR_{0.95}$	La forma completa de la cola
¿Dónde comienza aproximadamente el peor 1 %?	$VaR_{0.99}$	Qué tan grandes son los outcomes posteriores
¿Cuál es la pérdida promedio dentro de ese peor 1 %?	$TVaR_{0.99}$	La forma completa de la cola

Ninguna de las dos cantidades reconstruye por sí sola la distribución completa. La elección entre ellas depende de qué pregunta de riesgo queremos responder.

2.6.3 Lognormal y Lomax revelan por qué el umbral de entrada no determina el costo de la cola

CANON DE MODELO. Recuperemos los dos candidate severity models de la Section 2.2. No son estadísticas históricas observadas ni modelos ya estimados desde data; son implicaciones de parámetros canónicos tratados como conocidos en Part 2.

- **Modelo A - Lognormal:** $E[X] = 18,000$ USD, $SD(X) \approx 31,177$ USD, $\mu = \ln(9,000)$ y $\sigma = \sqrt{2 \ln 2} \approx 1.177410$.
- **Modelo B - Lomax / Pareto Tipo II:** $E[X] = 18,000$ USD, $SD(X) \approx 59,699$ USD, $\alpha = 2.2$ y $\theta = 21,600$ USD.

Ambos tienen la misma media y un $VaR_{0.95}$ casi idéntico. La cuestión es qué ocurre después de ese threshold.

Cálculo al 95 %

Para la Lognormal, si $z_p = \Phi^{-1}(p)$,

$$VaR_p(X) = \exp(\mu + \sigma z_p).$$

Con $z_{0.95} \approx 1.6448536$,

$$VaR_{0.95}(X) = \exp(\ln(9,000) + 1.177410 \times 1.6448536) \approx 62,420 \text{ USD.}$$

Su $TVaR$ puede calcularse mediante

$$TVaR_p(X) = E[X] \frac{\Phi(\sigma - z_p)}{1 - p}.$$

Por tanto,

$$TVaR_{0.95}(X) = 18,000 \frac{\Phi(1.177410 - 1.6448536)}{0.05} \approx 115,233 \text{ USD.}$$

Para la Lomax,

$$VaR_p(X) = \theta [(1 - p)^{-1/\alpha} - 1].$$

Entonces,

$$VaR_{0.95}(X) = 21,600 [0.05^{-1/2.2} - 1] \approx 62,701 \text{ USD.}$$

Como $\alpha > 1$, su media de cola es finita y

$$TVaR_p(X) = VaR_p(X) + \frac{\theta + VaR_p(X)}{\alpha - 1}.$$

Así,

$$TVaR_{0.95}(X) \approx 62,701 + \frac{21,600 + 62,701}{1.2} \approx 132,951 \text{ USD.}$$

Los $VaR_{0.95}$ difieren en aproximadamente 281 USD, pero los $TVaR_{0.95}$ difieren en aproximadamente

$$132,951 - 115,233 = 17,718 \text{ USD.}$$

Bajo estos candidate models, el Lomax asigna una severidad promedio mayor a los outcomes de una cola que comienza prácticamente en el mismo punto.

Cálculo al 99%

Al mover el nivel desde $p = 0.95$ hasta $p = 0.99$, usamos $z_{0.99} \approx 2.3263479$. Para la Lognormal:

$$VaR_{0.99}(X) = \exp(\ln(9,000) + 1.177410 \times 2.3263479) \approx 139,253 \text{ USD,}$$

$$TVaR_{0.99}(X) = 18,000 \frac{\Phi(1.177410 - 2.3263479)}{0.01} \approx 225,523 \text{ USD.}$$

Para la Lomax:

$$VaR_{0.99}(X) = 21,600 [0.01^{-1/2.2} - 1] \approx 153,604 \text{ USD,}$$

$$TVaR_{0.99}(X) \approx 153,604 + \frac{21,600 + 153,604}{1.2} \approx 299,608 \text{ USD.}$$

Los mismos resultados pueden organizarse en una sola tabla:

Medida	Lognormal	Lomax	Diferencia absoluta
$E[X]$	18,000 USD	18,000 USD	0 USD
$VaR_{0.95}$	62,420 USD	62,701 USD	281 USD
$TVaR_{0.95}$	115,233 USD	132,951 USD	17,718 USD
$VaR_{0.99}$	139,253 USD	153,604 USD	14,351 USD
$TVaR_{0.99}$	225,523 USD	299,608 USD	74,085 USD

En estos modelos, cuanto más nos desplazamos hacia la cola, mayor importancia adquieren las assumptions sobre tail behavior. Incluso VaR empieza a separarse con mayor claridad al 99 %, y la diferencia de $TVaR$ se amplía aún más.

La ratio $TVaR_p/VaR_p$ es adimensional. Para la Lognormal vale aproximadamente 1.846 al 95 % y 1.620 al 99 %; para la Lomax, aproximadamente 2.120 y 1.951. Estos valores no seleccionan un modelo como “correcto”. Solo muestran que las dos distribuciones conservan perfiles distintos una vez cruzados sus thresholds.

2.6.4 Las propiedades deseables exigen un comportamiento lógico de la medida de riesgo

Después de calcular una medida conviene preguntar no solo qué número produce, sino cómo se comporta cuando una pérdida aumenta, se desplaza, se escala o se combina con otra. Utilizaremos cuatro propiedades deseables. Si una medida satisface simultáneamente estas cuatro propiedades en su dominio, la llamaremos **coherente**. Coherencia es una propiedad matemática; no demuestra que el modelo de pérdidas sea correcto ni que el nivel p sea apropiado para una decisión concreta.

Monotonicidad

La pregunta económica es: **si Y nunca produce una pérdida menor que X , ¿podría asignársele menos riesgo?** Si

$$X \leq Y \quad \text{casi seguramente,}$$

queremos

$$\rho(X) \leq \rho(Y).$$

Por ejemplo, si $Y = X + Z$ con $Z \geq 0$ casi seguramente, la monotonicidad exige que $\rho(Y) \geq \rho(X)$. Tanto VaR_p como $TVaR_p$ satisfacen esta propiedad bajo sus condiciones estándar.

Invariancia por traslación

La pregunta es: **si añadimos una pérdida cierta c , cuánto debería cambiar la medida?** Queremos

$$\rho(X + c) = \rho(X) + c.$$

En particular,

$$VaR_p(X + c) = VaR_p(X) + c,$$

$$TVaR_p(X + c) = TVaR_p(X) + c.$$

La transformación añade exactamente la misma cantidad monetaria a todos los outcomes y, por tanto, desplaza ambos resúmenes en c unidades monetarias.

Homogeneidad positiva

La pregunta es: **si multiplicamos toda posible pérdida por $a \geq 0$, debería escalarse del mismo modo el measured risk?** Queremos

$$\rho(aX) = a\rho(X).$$

Y, en efecto,

$$VaR_p(aX) = aVaR_p(X),$$

$$TVaR_p(aX) = aTVaR_p(X).$$

Esta propiedad describe un escalamiento lineal de la posición; no incorpora por sí sola efectos no lineales de mercado o contrato.

Subaditividad

La pregunta es: **¿debería la combinación de dos riesgos poder producir artificialmente una medida mayor que la suma de medirlos por separado?** Queremos

$$\rho(X + Y) \leq \rho(X) + \rho(Y).$$

La propiedad no requiere que X y Y sean independientes. La independencia será únicamente un supuesto del contraejemplo que sigue. $TVaR$ satisface subaditividad en el dominio estándar de pérdidas integrables donde la medida es finita. VaR no la garantiza en general.

Estas cuatro propiedades no dicen que una medida sea “precisa”. Dicen cómo debe comportarse algebraicamente. Una medida puede ser coherente y, aun así, estar aplicada a un modelo mal especificado; del mismo modo, una medida que no sea subaditiva en general puede seguir siendo útil para una pregunta concreta si se conoce esa limitación.

2.6.5 El Valor en Riesgo puede fallar la subaditividad

EJEMPLO PEDAGÓGICO LOCAL. Consideremos dos pérdidas discretas independientes X y Y con

$$P(X = 100) = 0.04, \quad P(X = 0) = 0.96,$$

$$P(Y = 100) = 0.04, \quad P(Y = 0) = 0.96.$$

Como

$$F_X(0) = 0.96 \geq 0.95,$$

se obtiene

$$VaR_{0.95}(X) = VaR_{0.95}(Y) = 0 \text{ USD}.$$

Bajo independencia, la suma tiene distribución

$$P(X + Y = 0) = 0.96^2 = 0.9216,$$

$$P(X + Y = 100) = 2(0.04)(0.96) = 0.0768,$$

$$P(X + Y = 200) = 0.04^2 = 0.0016.$$

Por tanto,

$$F_{X+Y}(0) = 0.9216 < 0.95,$$

$$F_{X+Y}(100) = 0.9984 \geq 0.95,$$

y

$$VaR_{0.95}(X + Y) = 100 \text{ USD.}$$

Así,

$$VaR_{0.95}(X + Y) = 100 > VaR_{0.95}(X) + VaR_{0.95}(Y) = 0.$$

VaR falla la subaditividad en este caso.

Para $TVaR$ debemos utilizar la integral de cuantiles porque la distribución es discreta. Para cada riesgo individual,

$$TVaR_{0.95}(X) = \frac{1}{0.05} \left[\int_{0.95}^{0.96} 0 \, du + \int_{0.96}^1 100 \, du \right] = 80 \text{ USD.}$$

Análogamente, $TVaR_{0.95}(Y) = 80 \text{ USD}$. Para la suma,

$$TVaR_{0.95}(X + Y) = \frac{1}{0.05} \left[\int_{0.95}^{0.9984} 100 \, du + \int_{0.9984}^1 200 \, du \right] = 103.2 \text{ USD.}$$

Entonces,

$$TVaR_{0.95}(X + Y) = 103.2 \text{ USD} \leq 160 \text{ USD} = TVaR_{0.95}(X) + TVaR_{0.95}(Y).$$

En este ejemplo, $TVaR$ respeta la subaditividad y VaR no. El resultado no significa que $TVaR$ sea universalmente la mejor medida para cualquier decisión; significa que ambas medidas conservan información diferente y que sus propiedades matemáticas también difieren.

La independencia intervino únicamente para construir las probabilidades 0.9216, 0.0768 y 0.0016 de la suma. La definición de subaditividad, en cambio, no exige independencia: es

una propiedad de la medida para los pares de riesgos de su dominio.

2.6.6 El parámetro de cola determina qué momentos existen y qué cálculos siguen siendo válidos

Antes de utilizar una quantity basada en $E[X^k]$, debemos comprobar que ese momento exista bajo la distribución teórica. Para una pérdida no negativa continua con density f_X ,

$$E[X^k] = \int_0^\infty x^k f_X(x) dx,$$

y el momento ordinario de orden k existe de forma finita solo si esa integral converge.

CANON DE MODELO. Para la Lognormal,

$$E[X^k] = \exp\left(k\mu + \frac{k^2\sigma^2}{2}\right) < \infty$$

para todo $k > 0$. Por tanto, sus momentos positivos de cualquier orden son finitos.

Para una Lomax con parámetro de forma α ,

$$E[X^k] < \infty \iff k < \alpha.$$

Con el Lomax canónico $\alpha = 2.2$:

- el primer momento ordinario existe porque $1 < 2.2$;
- el segundo momento ordinario existe porque $2 < 2.2$, y por ello la varianza es finita;
- el tercer momento ordinario no existe porque $3 > 2.2$.

En particular,

$$E[X] = 18,000 \text{ USD},$$

$$E[X^2] = 3,888,000,000 \text{ USD}^2,$$

$$\text{Var}(X) = 3,564,000,000 \text{ USD}^2,$$

pero

$$E[X^3] = \infty.$$

Por tanto, una skewness teórica basada en el tercer momento central no queda definida como una quantity finita bajo este modelo. La consecuencia depende del cálculo que queramos realizar:

Quantity o método	Momento necesario
Mean severity	primer momento
Variance y standard deviation	segundo momento
Aggregate variance de Section 2.5	segundo momento
Skewness basada en moments	tercer momento
<i>TVaR</i> finito en estos casos de cola pesada no negativa	media finita dentro de la cola

Una muestra finita siempre contiene observations finitas, pero eso no obliga a la theoretical distribution a tener todos sus moments finitos. La pregunta de existencia pertenece al modelo, no al tamaño máximo observado en una muestra concreta.

La lección no es que una distribución con un momento infinito sea automáticamente inútil. Es que un método que exige ese momento deja de estar justificado bajo ese modelo. En particular, si el segundo momento no existe, la variance de severity y las approximations de Section 2.5 que se construían mediante mean y variance dejan de disponer de los inputs teóricos requeridos. Si el tercer momento no existe, una skewness basada en moments tampoco es una quantity finita disponible para el análisis.

2.6.7 Un percentil finito puede convivir con un TVaR infinito

EJEMPLO PEDAGÓGICO LOCAL. Consideremos una Lomax con

$$\alpha = 0.8, \quad \theta = 3,600 \text{ USD.}$$

Como $\alpha < 1$, el primer momento no existe:

$$E[X] = \infty.$$

Sin embargo, para cualquier $p < 1$, el cuantil Lomax sigue siendo finito. Al 95 %,

$$VaR_{0.95}(X) = 3,600 [0.05^{-1.25} - 1] \approx 148,661.46 \text{ USD.}$$

El $VaR_{0.95}$ es, por tanto, un threshold monetario finito aunque la media del modelo no exista.

Para $TVaR$, partimos de la definición por cuantiles:

$$TVaR_p(X) = \frac{\theta}{1-p} \int_p^1 [(1-u)^{-1/\alpha} - 1] du.$$

Con el cambio $t = 1 - u$, la parte relevante para la convergencia es

$$\int_0^{1-p} t^{-1/\alpha} dt.$$

Esta integral converge únicamente si $\alpha > 1$. Para $\alpha = 0.8$,

$$-\frac{1}{\alpha} = -1.25,$$

de modo que la integral diverge y

$$TVaR_{0.95}(X) = \infty.$$

Así, un VaR finito no garantiza un $TVaR$ finito. El percentil identifica dónde comienza una cola; no garantiza que el promedio dentro de esa cola exista.

Este ejemplo también muestra por qué la existencia de moments no es un tema separado de las medidas de riesgo. VaR_p puede existir para todo $p < 1$ aunque la cola sea tan persistente que su first-tail mean diverja. Antes de calcular una summary basada en una esperanza, debemos comprobar que la esperanza requerida sea finita bajo el modelo.

Cierre y Puente Final

Al comienzo de Part 2, el producto

$$720(18,000) = 12.960 \text{ millones USD}$$

parecía una descripción natural del costo anual. Ahora sabemos que esa cifra es solo un centro:

$$E[S_X].$$

Para entender el riesgo tuvimos que separar la severity X , la frequency N , construir la aggregate loss S_X y estudiar su distribución. Finalmente, al resumir esa distribución mediante VaR o $TVaR$, volvemos a perder información: VaR conserva un threshold; $TVaR$ conserva información sobre la magnitud promedio dentro de la cola. Incluso antes de utilizar moments debemos verificar que existan bajo el modelo elegido.

Los dos candidate severity models centrales muestran el punto. Al 95 %,

$$VaR_{0.95}^{LN} \approx 62,420 \text{ USD}, \quad VaR_{0.95}^{Lomax} \approx 62,701 \text{ USD},$$

pero

$$TVaR_{0.95}^{LN} \approx 115,233 \text{ USD}, \quad TVaR_{0.95}^{Lomax} \approx 132,951 \text{ USD}.$$

Dos distribuciones pueden coincidir aproximadamente en un threshold y diferir profundamente en lo que ocurre después de él. Una cartera no tiene “un riesgo” expresado por una sola cifra; tiene una distribución, y cada cifra extraída de ella responde una pregunta distinta.

Hasta ahora hemos utilizado λ , μ , σ , α y θ como si fueran conocidos. Gracias a ellos pudimos calcular expected values, aggregate variance, VaR y $TVaR$. Una aseguradora real, sin embargo, observa data: a veces completos, agrupados, truncados o censurados. La siguiente pregunta es, por tanto: **¿cómo pasamos de los datos que realmente observamos a los parameter values que alimentan estos cálculos?** Esa pregunta abre la Part 3 - Parametric Estimation y la Section 3.1 - Maximum Likelihood Estimators.

Ejercicios

Ejercicio 1 - Cálculo de VaR y TVaR en distribuciones continuas de igual media

EJEMPLO PEDAGÓGICO LOCAL. Una severidad ground-up individual X se modela mediante dos candidate distributions con media de 10,000 USD:

- Lognormal con $\mu = \ln(5,000)$ y $\sigma = \sqrt{2 \ln 2} \approx 1.177410$.
- Lomax con $\alpha = 2.5$ y $\theta = 15,000$ USD.

1. Verifique que ambas distribuciones tienen media de 10,000 USD.
2. Calcule $VaR_{0.95}$ y $VaR_{0.99}$ para ambas, utilizando $z_{0.95} \approx 1.6448536$ y $z_{0.99} \approx 2.3263479$.
3. Calcule $TVaR_{0.95}$ y $TVaR_{0.99}$.
4. Calcule $TVaR_p/VaR_p$ e interprete qué información adicional aporta $TVaR$.

Criterio de éxito:

Las medias deben reconciliar primero:

$$E[X]_{LN} = \exp\left(\ln(5,000) + \frac{2\ln 2}{2}\right) = 10,000 \text{ USD},$$

$$E[X]_{Lomax} = \frac{15,000}{2.5 - 1} = 10,000 \text{ USD}.$$

- Lognormal: $VaR_{0.95} \approx 34,677.98 \text{ USD}$, $TVaR_{0.95} \approx 64,018.25 \text{ USD}$, $VaR_{0.99} \approx 77,362.58 \text{ USD}$ y $TVaR_{0.99} \approx 125,290.80 \text{ USD}$.
- Lomax: $VaR_{0.95} \approx 34,716.81 \text{ USD}$, $TVaR_{0.95} \approx 67,861.35 \text{ USD}$, $VaR_{0.99} \approx 79,643.60 \text{ USD}$ y $TVaR_{0.99} \approx 142,739.34 \text{ USD}$.
- Ratios: Lognormal ≈ 1.846 y 1.620 ; Lomax ≈ 1.955 y 1.792 para 95 % y 99 %, respectivamente.

Ejercicio 2 - Propiedades de VaR y TVaR

EJEMPLO PEDAGÓGICO LOCAL. Considere las medidas $\rho_1(X) = VaR_{0.95}(X)$ y $\rho_2(X) = TVaR_{0.95}(X)$.

1. Demuestre simbólicamente que ambas satisfacen invariancia por traslación y homogeneidad positiva.
2. Explique por qué ambas satisfacen monotonidad cuando $X \leq Y$ casi seguramente.
3. Para dos pérdidas independientes con

$$P(X = 100) = P(Y = 100) = 0.04,$$

$$P(X = 0) = P(Y = 0) = 0.96,$$

calcule $VaR_{0.95}$ y $TVaR_{0.95}$ de X , Y y $X + Y$.

4. Determine qué medida falla la subaditividad y justifique la respuesta mediante una inequality explícita.

Criterio de éxito:

La distribución de $X + Y$ debe reconciliar:

$$P(X + Y = 0) = 0.9216, \quad P(X + Y = 100) = 0.0768, \quad P(X + Y = 200) = 0.0016.$$

Además, las equalities simbólicas de traslación y homogeneidad deben aparecer expresamente para ambas medidas, y la monotonicidad debe justificarse a partir del orden de los quantiles. Para subaditividad:

$$VaR_{0.95}(X) = VaR_{0.95}(Y) = 0 \text{ USD},$$

$$VaR_{0.95}(X + Y) = 100 \text{ USD},$$

por lo que

$$100 > 0 + 0.$$

En cambio,

$$TVaR_{0.95}(X) = TVaR_{0.95}(Y) = 80 \text{ USD},$$

$$TVaR_{0.95}(X + Y) = 103.2 \text{ USD},$$

y

$$103.2 \leq 80 + 80.$$

La respuesta debe evaluar las cuatro propiedades, no limitarse a marcar “sí” o “no”.

Ejercicio 3 - Existencia de momentos y TVaR

EJEMPLO PEDAGÓGICO LOCAL. Considere cuatro distribuciones Lomax con la misma escala $\theta = 5,000$ USD y parámetros de forma

$$\alpha \in \{0.8, 1.5, 2.2, 3.5\}.$$

1. Para cada valor de α , determine si existen de forma finita la media, la varianza y el tercer momento ordinario.
2. Determine para cada modelo si $TVaR_p$ puede ser finito para $p < 1$.
3. Explique qué cálculos de Section 2.5 dejan de estar justificados cuando no existe el segundo momento, y qué summary basado en moments deja de estar definido cuando no existe el tercero.
4. Para $\alpha = 0.8$, calcule $VaR_{0.99}$ y explique por qué $TVaR_{0.99}$ es infinito.

Criterio de éxito:

α	Mean	Variance	Third moment	Finite $TVaR_p$
0.8	No	No	No	No
1.5	Sí	No	No	Sí
2.2	Sí	Sí	No	Sí
3.5	Sí	Sí	Sí	Sí

Para $\alpha = 0.8$,

$$VaR_{0.99}(X) = 5,000 [0.01^{-1.25} - 1] \approx 1,576,138.83 \text{ USD},$$

mientras que

$$TVaR_{0.99}(X) = \infty.$$

La explicación debe indicar que $k < \alpha$ gobierna la existencia del momento ordinario de orden k , mientras que la finitud de $TVaR_p$ para estos modelos Lomax exige $\alpha > 1$. Cuando $\alpha \leq 2$, no existe la variance teórica requerida por las approximations Normal y moment-matched Lognormal de Section 2.5; cuando $\alpha \leq 3$, no existe un third moment ordinario finito para construir summaries de skewness basadas en moments.

3 - Parametric Estimation

Section 3.1 - Maximum Likelihood Estimators

La verosimilitud describe lo que observamos, no lo que ocurrió fuera de nuestra vista

3.1.1 La verosimilitud mide la compatibilidad de los parámetros con los datos que alcanzamos a observar

En la práctica de la modelación actuarial de seguros de daños, disponer de una familia paramétrica candidata -como la Lognormal o la Lomax estudiadas en la Part 2 para representar severidades- es solo el primer paso del modelado de pérdidas. El verdadero desafío analítico consiste en calibrar los parámetros específicos, como λ , μ , σ , α o θ , que gobiernan la distribución. En los capítulos previos, estos parámetros eran tratados como cantidades conocidas para poder estudiar las consecuencias de cada modelo. Sin embargo, una aseguradora real observa datos, no parámetros.

Para ilustrar este conflicto de estimación, consideremos la experiencia de severidad de Meridiano Seguros. Si la actuario de Pricing, **Lucía**, decide ajustar un modelo para las pérdidas individuales, de inmediato se enfrenta a una pregunta fundamental de control formulada por la actuario jefa, **Irene**:

«¿Con qué datos vas a calibrar el modelo, Lucía? ¿Dispones de los importes ground-up completos, de payments, de buckets o de claims cuyo importe quedó capped en el sistema?»

La pregunta es más importante de lo que parece. Una condición contractual puede transformar el payment, pero que esa transformación produzca truncation o censoring en el dataset depende de lo que el sistema de observación conserve. Un deductible no elimina por sí solo la existencia de una ground-up loss del archivo si la compañía sigue registrándola; un policy limit tampoco censura automáticamente el ground-up amount si ese importe continúa disponible. La inferencia debe construirse desde la información que efectivamente llegó al archivo utilizado por el actuario.

Para un modelo continuo, una observación exacta $X = x$ aporta una density $f_X(x; \theta)$. Para observaciones independientes $x_1, \dots, x_n$, la función de verosimilitud es

$$\mathcal{L}(\theta; \mathbf{x}) = \prod_{i=1}^n f_X(x_i; \theta).$$

Para un modelo discreto, la contribución correspondiente es una probability mass. Si $N_i = n_i$ y su PMF es $p_N(n; \theta)$,

$$\mathcal{L}(\theta; \mathbf{n}) = \prod_{i=1}^n p_N(n_i; \theta).$$

En ambos casos, los datos permanecen fijos y la función se estudia como función del parámetro.

La verosimilitud $\mathcal{L}(\theta; \mathbf{x})$ **no representa la probabilidad de que θ sea el verdadero parámetro**. En el marco frecuentista utilizado aquí, θ es una constante fija pero desconocida. La verosimilitud permite comparar qué valores del parámetro hacen más compatible el registro observado con el modelo especificado.

Esto conduce a la pregunta que gobernará toda la sección:

¿Qué valores de los parámetros hacen que los datos que realmente observamos sean más compatibles con el modelo elegido?

Antes de construir cualquier likelihood, el actuario debe poder responder cuatro preguntas:

1. ¿Qué variable estamos modelando?

2. ¿Qué se observa exactamente?
3. ¿Qué observaciones pueden faltar por diseño?
4. ¿Qué valores pueden estar solo parcialmente observados?

Si alguna de esas respuestas cambia, la likelihood puede cambiar aunque las cifras visibles parezcan las mismas.

3.1.2 El logaritmo convierte la acumulación multiplicativa en una suma analíticamente manejable

La función de verosimilitud suele construirse como un producto de muchas contribuciones. Para muestras grandes, ese producto puede alcanzar magnitudes numéricamente extremas y resultar poco cómodo tanto para el cálculo analítico como para la optimización computacional. La transformación logarítmica resuelve ambos problemas sin cambiar el parámetro que maximiza la función.

Como el logaritmo natural es estrictamente creciente,

$$\arg \max_{\theta} \mathcal{L}(\theta; \mathbf{x}) = \arg \max_{\theta} \ell(\theta),$$

donde

$$\ell(\theta) = \ln \mathcal{L}(\theta; \mathbf{x}).$$

Para observaciones continuas independientes,

$$\ell(\theta) = \ln \left(\prod_{i=1}^n f_X(x_i; \theta) \right) = \sum_{i=1}^n \ln f_X(x_i; \theta).$$

La transformación cambia productos por sumas, pero no crea un estimador diferente.

Consideremos ahora la muestra pedagógica completa de severidad de Meridiano, expresada en miles de USD:

$$\mathbf{x} = \{4, 6, 8, 10, 12, 14, 18, 24, 36, 48\}.$$

Tenemos

$$n = 10,$$

$$\sum_{i=1}^{10} x_i = 180,$$

y por tanto

$$\bar{x} = 18 \text{ mil USD.}$$

Supongamos que, para este ejercicio de estimación, se ha elegido un modelo Exponencial parametrizado por su media:

$$X \sim \text{Exponential}(\theta), \quad \theta > 0,$$

con density

$$f_X(x; \theta) = \frac{1}{\theta} e^{-x/\theta}, \quad x > 0.$$

Aquí

$$E[X] = \theta.$$

Desafío al lector: la muestra tiene media empírica de 18 mil USD. ¿Debe coincidir necesariamente con la MLE de θ , o hay que demostrarlo desde la likelihood?

Bajo independencia,

$$\mathcal{L}(\theta; \mathbf{x}) = \prod_{i=1}^{10} \frac{1}{\theta} e^{-x_i/\theta} = \theta^{-10} \exp \left(-\frac{\sum_{i=1}^{10} x_i}{\theta} \right).$$

La log-verosimilitud es

$$\ell(\theta) = -10 \ln \theta - \frac{180}{\theta}.$$

La ecuación de score es

$$\ell'(\theta) = -\frac{10}{\theta} + \frac{180}{\theta^2}.$$

Igualando a cero,

$$-\frac{10}{\theta} + \frac{180}{\theta^2} = 0,$$

$$10\theta = 180,$$

y por tanto

$$\hat{\theta}_{MLE} = 18 \text{ mil USD}.$$

Es decir,

$$\hat{\theta}_{MLE} = 18,000 \text{ USD}.$$

Sin embargo, resolver $\ell'(\theta) = 0$ solo produce un candidato. Hay que comprobar que realmente maximiza la función sobre el espacio $\theta > 0$.

Podemos escribir

$$\ell'(\theta) = \frac{180 - 10\theta}{\theta^2}.$$

Como $\theta^2 > 0$ para todo $\theta > 0$,

$$\ell'(\theta) > 0 \quad \text{si } 0 < \theta < 18,$$

y

$$\ell'(\theta) < 0 \quad \text{si } \theta > 18.$$

Por tanto, la log-verosimilitud aumenta hasta $\theta = 18$ y disminuye después de ese punto. Esto demuestra que $\hat{\theta} = 18$ es el máximo global único en el espacio de parámetros.

La segunda derivada es

$$\ell''(\theta) = \frac{10}{\theta^2} - \frac{360}{\theta^3}.$$

Evaluada en el punto crítico,

$$\ell''(18) = \frac{10}{18^2} - \frac{360}{18^3} = -\frac{10}{324} \approx -0.03086 < 0.$$

Esta comprobación confirma que el punto crítico es localmente un máximo; la unicidad global proviene del cambio de signo del score sobre $\theta > 0$, no de afirmar que $\ell''(\theta)$ sea negativa para todos los valores posibles de θ .

La interpretación también debe mantenerse disciplinada. No hemos descubierto que la verdadera media poblacional sea 18,000 USD. Hemos demostrado que, **bajo el modelo Exponencial y para esta muestra individual completa**, la máxima verosimilitud se alcanza en

$$\hat{\theta} = 18,000 \text{ USD}.$$

Tampoco hemos demostrado que la Exponencial sea una buena representación de la severidad de Meridiano. La máxima verosimilitud responde a una pregunta condicional:

dentro de esta familia, ¿qué parámetro hace más compatibles los datos observados?

La adecuación de la familia es otra pregunta.

3.1.3 El volumen de exposición define la escala de la verosimilitud de frecuencia

El mismo principio se aplica a variables discretas. Consideremos ahora la frecuencia de Meridiano Seguros durante 2024:

12,000 policy-years,

con

720 ground-up claims.

Sea N_i el número de claims correspondiente al policy-year i . Bajo el modelo simplificado

$$N_i \sim \text{Poisson}(\lambda),$$

con observaciones independientes y una misma tasa λ por policy-year,

$$P(N_i = n_i) = e^{-\lambda} \frac{\lambda^{n_i}}{n_i!}.$$

La verosimilitud completa es

$$\mathcal{L}(\lambda; \mathbf{n}) = \prod_{i=1}^{12,000} e^{-\lambda} \frac{\lambda^{n_i}}{n_i!}.$$

Por tanto,

$$\mathcal{L}(\lambda; \mathbf{n}) = e^{-12,000\lambda} \frac{\lambda^{\sum_i n_i}}{\prod_i n_i!}.$$

La log-verosimilitud es

$$\ell(\lambda) = -12,000\lambda + \left(\sum_i n_i \right) \ln \lambda - \sum_i \ln(n_i!).$$

El último término depende de los datos, pero no de λ . Su derivada respecto del parámetro es cero.

Como

$$\sum_i n_i = 720,$$

la ecuación de score es

$$\ell'(\lambda) = -12,000 + \frac{720}{\lambda} = 0.$$

Así,

$$\boxed{\hat{\lambda}_{MLE} = \frac{720}{12,000} = 0.060 \text{ claims por policy-year}}.$$

La MLE coincide con la frecuencia media empírica.

Existe aquí una diferencia importante entre **agrupar valores discretos exactos** y agrupar una variable continua en intervalos. La tabla canónica de frequency de Meridiano es

Claims por policy-year k	Policy-years m_k
0	11,325
1	635

Claims por policy-year k	Policy-years m_k
2	35
3	5
Total	12,000

Desafío al lector: si el archivo contiene esta tabla en lugar de los 12,000 registros individuales, ¿hemos perdido la información necesaria para estimar λ por máxima verosimilitud?

No, porque cada categoría identifica todavía el valor discreto exacto de N . La likelihood puede escribirse, salvo un coeficiente combinatorio independiente de λ , como

$$\mathcal{L}(\lambda) \propto \prod_{k=0}^3 \left[e^{-\lambda} \frac{\lambda^k}{k!} \right]^{m_k}.$$

El exponente total de $e^{-\lambda}$ es

$$11,325 + 635 + 35 + 5 = 12,000,$$

mientras que el exponente total de λ es

$$0(11,325) + 1(635) + 2(35) + 3(5) = 720.$$

Por tanto, la parte de la log-verosimilitud que depende de λ vuelve a ser

$$\ell(\lambda) = -12,000\lambda + 720 \ln \lambda + \text{constante},$$

y produce nuevamente

$$\hat{\lambda} = 0.060.$$

Aquí la tabla de frecuencias conserva los counts de cada valor discreto exacto. Esto es distinto

de observar únicamente que una severidad cayó dentro de un intervalo amplio, donde el importe exacto sí desaparece.

La distribución observada de N tiene media empírica

$$0.060$$

y varianza poblacional empírica aproximadamente

$$0.06473.$$

Su ratio es

$$\frac{0.06473}{0.060} \approx 1.0789.$$

La pequeña discrepancia respecto de la igualdad teórica $E[N] = Var(N) = \lambda$ genera una pregunta sobre el modelo, pero no un veredicto automático. La muestra no tiene por qué reproducir exactamente los momentos teóricos. Poisson puede mantenerse como modelo candidato para este ejercicio de estimación, pero una MLE correctamente calculada no demuestra por sí sola que el modelo sea adecuado.

3.1.4 Las carteras agregadas exigen distinguir entre observar componentes y observar únicamente el total

En la Part 2 construimos una pérdida agregada S a partir de frequency y severity. Al estimar parámetros, la primera pregunta vuelve a ser: **¿qué información observamos?**

Supongamos primero que la aseguradora conserva tanto el count N como las severidades individuales $X_1, \dots, X_N$. Bajo los supuestos de independencia utilizados en el modelo, la información permite construir separadamente las likelihoods de frequency y severity:

$$\mathcal{L}(\theta_N, \theta_X) = \mathcal{L}_N(\theta_N) \mathcal{L}_X(\theta_X).$$

Esto permite estimar directamente parámetros de ambos componentes.

Pero puede ocurrir que el actuario reciba únicamente totales agregados anuales

$$S_1, S_2, \dots, S_m,$$

sin conservar el detalle de cuántos claims formaron cada total ni sus severidades individuales.

Entonces la likelihood debe construirse desde la distribución marginal de S :

$$\mathcal{L}(\vartheta; \mathbf{s}) = \prod_{j=1}^m g_S(s_j; \vartheta),$$

cuando S se modela como continua con density g_S .

Desafío al lector: si solo observamos S , ¿podemos tratar ese total como si también hubiéramos observado los valores de N y de cada X_i que lo produjeron?

No. Un mismo aggregate total puede surgir de diferentes combinaciones de frecuencia y severidad. Observar solo S contiene menos información sobre los componentes que observar simultáneamente N y los X_i .

Para ilustrar la estimación directa de una aggregate distribution, utilizamos el caso pedagógico local de cinco totales anuales, expresados en millones de USD:

$$\mathbf{s} = \{11.8, 12.4, 13.0, 13.2, 14.4\}.$$

Supongamos

$$S_j \sim \text{Normal}(\mu_S, \sigma_S^2),$$

independientemente, con

$$\sigma_S^2 > 0.$$

La log-verosimilitud, omitiendo constantes que no dependen de los parámetros, es

$$\ell(\mu_S, \sigma_S^2) = -\frac{5}{2} \ln(\sigma_S^2) - \frac{1}{2\sigma_S^2} \sum_{j=1}^5 (s_j - \mu_S)^2 + \text{constante}.$$

La MLE de la media es

$$\hat{\mu}_S = \bar{S} = \frac{11.8 + 12.4 + 13.0 + 13.2 + 14.4}{5} = \boxed{12.96 \text{ millones USD}}.$$

Para la varianza,

$$\hat{\sigma}_S^2 = \frac{1}{5} \sum_{j=1}^5 (s_j - \bar{S})^2.$$

Los residuos respecto de 12.96 son

$$-1.16, \quad -0.56, \quad 0.04, \quad 0.24, \quad 1.44.$$

Por tanto,

$$\sum_{j=1}^5 (s_j - \bar{S})^2 = 1.3456 + 0.3136 + 0.0016 + 0.0576 + 2.0736 = 3.792.$$

Entonces

$$\hat{\sigma}_S^2 = \frac{3.792}{5} = 0.7584 \text{ (millones USD)}^2.$$

Y

$$\hat{\sigma}_S = \sqrt{0.7584} \approx 0.8709 \text{ millones USD}.$$

La MLE utiliza divisor $m = 5$, no $m - 1 = 4$. La varianza muestral corregida sería

$$\frac{3.792}{4} = 0.9480 \text{ (millones USD)}^2.$$

No existe contradicción: los dos estimadores responden a criterios diferentes. La MLE maximiza la likelihood bajo el modelo Normal especificado; no está definida por exigir insesgadez en muestra finita.

3.1.5 Agrupar datos destruye la precisión individual pero conserva la estructura del intervalo

Supongamos ahora que el Claims System no conserva los importes exactos de cada severity y solo informa cuántas observaciones pertenecen a cada banda. En ese caso tenemos **grouped data**.

Para la cartera canónica de Meridiano, los counts son

Intervalo de ground-up severity, miles de USD	Claims
(0, 2.5]	96
(2.5, 10]	288
(10, 25]	196
(25, 50]	87
(50, 77.5]	28
(77.5, ∞)	25
Total	720

En el segundo intervalo sabemos que existen 288 claims con

$$2.5 < X \leq 10,$$

pero no conocemos sus 288 valores exactos.

Desafío al lector: ¿por qué no sustituir simplemente las 288 observaciones por el midpoint

$$\frac{2.5 + 10}{2} = 6.25 \text{ mil USD?}$$

Porque hacerlo introduciría una afirmación que el archivo nunca proporcionó: que cada uno de esos claims vale exactamente 6.25 mil USD. Además, bajo un modelo no uniforme, la distribución de probabilidad dentro del intervalo no tiene por qué estar centrada en el midpoint. Por ejemplo, una Exponencial asignaría diferente densidad a distintas zonas de la banda. Eso es una implicación del modelo; no sabemos cuál fue la suma real de las 288 observaciones porque precisamente sus valores exactos no están disponibles.

La información observada es el evento

$$a_j < X \leq b_j.$$

Por tanto, cada claim de ese grupo contribuye mediante

$$P(a_j < X \leq b_j; \theta) = F_X(b_j; \theta) - F_X(a_j; \theta).$$

Si el grupo contiene n_j observaciones,

$$\mathcal{L}(\theta; \mathbf{n}) \propto \prod_{j=1}^M [F_X(b_j; \theta) - F_X(a_j; \theta)]^{n_j},$$

donde el coeficiente multinomial puede omitirse al maximizar respecto de θ porque no depende del parámetro.

Para

$$X \sim \text{Exponential}(\theta),$$

con θ expresado en miles de USD, las probabilidades de los seis grupos son

$$\pi_1(\theta) = 1 - e^{-2.5/\theta},$$

$$\pi_2(\theta) = e^{-2.5/\theta} - e^{-10/\theta},$$

$$\pi_3(\theta) = e^{-10/\theta} - e^{-25/\theta},$$

$$\pi_4(\theta) = e^{-25/\theta} - e^{-50/\theta},$$

$$\pi_5(\theta) = e^{-50/\theta} - e^{-77.5/\theta},$$

y para el grupo abierto superior,

$$\pi_6(\theta) = P(X > 77.5) = e^{-77.5/\theta}.$$

La likelihood agrupada es

$$\begin{aligned} \mathcal{L}(\theta) \propto & \left[1 - e^{-2.5/\theta}\right]^{96} \left[e^{-2.5/\theta} - e^{-10/\theta}\right]^{288} \left[e^{-10/\theta} - e^{-25/\theta}\right]^{196} \\ & \times \left[e^{-25/\theta} - e^{-50/\theta}\right]^{87} \left[e^{-50/\theta} - e^{-77.5/\theta}\right]^{28} \left[e^{-77.5/\theta}\right]^{25}. \end{aligned}$$

La correspondiente ecuación de score no produce aquí una solución cerrada conveniente, por lo que se maximiza numéricamente.

El resultado es

$$\boxed{\hat{\theta}_{\text{grouped}} \approx 16.7987 \text{ mil USD}}.$$

Equivalentemente,

$$\hat{\theta}_{\text{grouped}} \approx 16,799 \text{ USD}.$$

La muestra individual completa utilizada como control tiene media empírica de

$$18,000 \text{ USD}.$$

La diferencia entre ambas estimates es aproximadamente

$$18,000 - 16,799 = 1,201 \text{ USD}.$$

Esta diferencia **no debe interpretarse como una medida numérica universal de la cantidad de información perdida**, ni como evidencia de que grouping necesariamente reduce la MLE. Lo que sí podemos afirmar es que el grouping eliminó los importes exactos dentro de cada banda y obligó a construir la likelihood con probabilidades de intervalo. Para este dataset y este modelo concreto, ese cambio de información produce una MLE de aproximadamente 16,799 USD en lugar de 18,000 USD.

3.1.6 El truncamiento condicional cambia la distribución de las observaciones que alcanzan la muestra

El truncamiento por la izquierda ocurre cuando las unidades con valores inferiores o iguales a un threshold no aparecen en el dataset utilizado para la estimación. Lo decisivo no es que exista un deductible, sino que el **mecanismo de observación** excluya esos records.

Esta distinción importa especialmente en Meridiano. El dataset ground-up canónico de 2024 conserva 720 claims, incluidos claims por debajo del deductible contractual de 2,500 USD. Por tanto, el mero hecho de que el contrato contenga ese deductible no convierte automáticamente ese archivo ground-up en una muestra truncada.

Para aislar el efecto estadístico, consideremos un escenario alternativo de extracción: el sistema de datos entregado al actuario conserva únicamente losses exactas cuando

$$X > d,$$

con

$$d = 2.5 \text{ mil USD.}$$

Los valores con $X \leq d$ no aparecen en esa extracción. Entonces la muestra observada debe modelarse condicionalmente a haber superado el threshold.

Para una variable continua,

$$f_{X|X>d}(x; \theta) = \frac{f_X(x; \theta)}{P(X > d; \theta)} = \frac{f_X(x; \theta)}{\bar{F}_X(d; \theta)}, \quad x > d.$$

Utilicemos nuevamente las mismas diez cifras visibles:

$$\mathbf{x} = \{4, 6, 8, 10, 12, 14, 18, 24, 36, 48\} \text{ mil USD.}$$

Desafío al lector: si las diez cifras visibles son exactamente las mismas que en la muestra completa, ¿debe permanecer necesariamente igual la MLE?

No. Cambió el statement de información.

En el primer caso sabemos:

estas son observaciones de una muestra completa.

En el segundo sabemos:

estas son observaciones exactas tomadas condicionalmente a $X > 2.5$.

Bajo

$$X \sim \text{Exponential}(\theta),$$

la survival function es

$$\bar{F}_X(d; \theta) = e^{-d/\theta}.$$

Por tanto,

$$f_{X|X>d}(x; \theta) = \frac{\theta^{-1}e^{-x/\theta}}{e^{-d/\theta}} = \frac{1}{\theta}e^{-(x-d)/\theta}.$$

Para las diez observaciones,

$$\mathcal{L}_{tr}(\theta) = \prod_{i=1}^{10} \frac{1}{\theta} e^{-(x_i - 2.5)/\theta}.$$

Así,

$$\mathcal{L}_{tr}(\theta) = \theta^{-10} \exp \left(-\frac{\sum_{i=1}^{10} (x_i - 2.5)}{\theta} \right).$$

La log-verosimilitud es

$$\ell_{tr}(\theta) = -10 \ln \theta - \frac{\sum_{i=1}^{10} (x_i - 2.5)}{\theta}.$$

Como

$$\sum_{i=1}^{10} x_i = 180,$$

tenemos

$$\sum_{i=1}^{10} (x_i - 2.5) = 180 - 10(2.5) = 155.$$

La ecuación de score es

$$\ell'_{tr}(\theta) = -\frac{10}{\theta} + \frac{155}{\theta^2} = 0.$$

De aquí,

$$\hat{\theta}_{tr} = \frac{155}{10} = 15.5 \text{ mil USD}.$$

Equivalentemente,

$$\hat{\theta}_{tr} = 15,500 \text{ USD}.$$

La comparación es

$$\hat{\theta}_{complete} = 18 \text{ mil USD},$$

frente a

$$\hat{\theta}_{tr} = 15.5 \text{ mil USD}.$$

Las cifras visibles son idénticas. La likelihood no lo es.

En una Exponencial, el memoryless property hace que el conditional excess $X - d \mid X > d$ vuelva a tener media θ , razón por la cual aparece analíticamente

$$\hat{\theta}_{tr} = \bar{X} - d.$$

Este resultado es una **estimación bajo el modelo Exponencial y el mecanismo de**

truncamiento especificado. No garantiza que la estimate sea exactamente igual al parámetro verdadero ni demuestra que la Exponencial sea adecuada. Tampoco autoriza a describir el archivo ground-up canónico de Meridiano como truncado: el truncamiento existe únicamente en el escenario donde el proceso de registro realmente elimina las unidades bajo el threshold.

3.1.7 La censura preserva la existencia de la observación pero limita el conocimiento de su magnitud

El right-censoring representa una situación diferente. La observación permanece en la muestra, pero el sistema deja de revelar su magnitud exacta por encima de un threshold.

Desafío al lector: ¿truncation y censoring son dos nombres para el mismo problema de datos incompletos?

No.

En left truncation, una unidad que no supera el threshold no aparece en la muestra. En right censoring, la unidad sí aparece, pero parte de la información sobre su valor se pierde.

Un policy limit puede motivar un threshold relevante, pero tampoco produce por sí mismo censoring del ground-up amount. Si Meridiano conserva el valor original X , el actuario sigue teniendo una observación completa de X aunque el payment contractual esté capped. Existe censoring de ground-up severity únicamente si la base utilizada para estimación conserva, por encima de cierto punto, solo la información de que

$$X > u$$

y ya no mantiene el valor exacto.

Para el caso canónico utilizaremos

$$u = 77.5 \text{ mil USD.}$$

Este threshold coincide con

$$d + \ell = 2.5 + 75 = 77.5 \text{ mil USD}$$

bajo el contrato base, pero la inferencia censurada que sigue supone expresamente que el archivo entregado al actuario ha perdido los ground-up amounts exactos por encima de ese umbral.

Sea

$$z_i = \min(X_i, u)$$

el valor almacenado y sea δ_i un indicador:

$$\delta_i = \begin{cases} 1, & \text{si el valor de } X_i \text{ se observa exactamente,} \\ 0, & \text{si solo sabemos que } X_i > u. \end{cases}$$

Entonces una observación exacta contribuye mediante

$$f_X(z_i; \theta),$$

mientras que una observación censurada contribuye mediante

$$P(X_i > u; \theta) = \bar{F}_X(u; \theta).$$

La likelihood es

$$\mathcal{L}(\theta) = \prod_{i=1}^n [f_X(z_i; \theta)]^{\delta_i} [\bar{F}_X(u; \theta)]^{1-\delta_i}.$$

Consideremos la muestra canónica, expresada en miles de USD:

$$\{10, 20, 30, 50, 70, > 77.5, > 77.5\}.$$

Hay cinco observaciones exactas:

$$10, \quad 20, \quad 30, \quad 50, \quad 70,$$

cuya suma es

$$10 + 20 + 30 + 50 + 70 = 180.$$

Además existen dos observaciones censuradas en

$$u = 77.5.$$

Bajo

$$X \sim \text{Exponential}(\theta),$$

las cinco observaciones exactas contribuyen

$$\theta^{-5} e^{-180/\theta}.$$

Cada observación censurada contribuye

$$\bar{F}_X(77.5; \theta) = e^{-77.5/\theta}.$$

Las dos juntas aportan

$$e^{-155/\theta}.$$

Por tanto,

$$\mathcal{L}(\theta) = \theta^{-5} \exp\left(-\frac{335}{\theta}\right),$$

porque

$$180 + 155 = 335.$$

La log-verosimilitud es

$$\ell(\theta) = -5 \ln \theta - \frac{335}{\theta}.$$

La ecuación de score produce

$$-\frac{5}{\theta} + \frac{335}{\theta^2} = 0,$$

y por tanto

$$\hat{\theta}_{cens} = \frac{335}{5} = 67 \text{ mil USD}.$$

Equivalentemente,

$$\hat{\theta}_{cens} = 67,000 \text{ USD}.$$

Este valor estima, bajo el modelo Exponencial, el parámetro de media de la **distribución ground-up incondicional**. No es la «media de la cola».

Ahora comparemos con un procedimiento naive que sustituye los dos records censurados por valores exactos de 77.5:

$$\hat{\theta}_{naive} = \frac{10 + 20 + 30 + 50 + 70 + 77.5 + 77.5}{7}.$$

Así,

$$\hat{\theta}_{naive} = \frac{335}{7} \approx 47.86 \text{ mil USD}.$$

Desafío al lector: ¿qué afirmación adicional ha introducido el procedimiento naive?

Ha sustituido la información

$$X > 77.5$$

por la afirmación mucho más fuerte

$$X = 77.5.$$

En este caso particular,

$$\frac{67 - 47.8571}{67} \approx 28.57 \%.$$

Es decir, el naive estimate queda aproximadamente 28.57 % por debajo de la MLE que utiliza correctamente la censura.

Esto demuestra que ignorar el mecanismo de observación puede alterar materialmente una parameter estimate y, por extensión, las decisiones que utilicen después ese parámetro. No demuestra que censoring siempre eleve la MLE: la dirección y magnitud del cambio dependen del modelo, del threshold y de la muestra.

Existe además una distinción conceptual útil. Un grupo abierto

$$X > 77.5$$

en grouped data y una observación individual right-censored en 77.5 pueden aportar matemáticamente la misma survival probability

$$\bar{F}_X(77.5; \theta).$$

Pero la estructura de la información no es la misma. En grouped data, el sistema almacena pertenencia a una categoría. En censoring, sabemos que existe una observación individual, pero no conocemos su valor exacto después del threshold.

3.1.8 La contribución a la likelihood depende del evento que realmente quedó registrado

Los casos anteriores pueden condensarse en una sola disciplina:

cada observación debe contribuir exactamente con la probability o density correspondiente a la información que contiene, ni más ni menos.

Tipo de observación	Información disponible	Contribución
Exacta continua	$W = w$ exactamente	$f_W(w; \theta)$
Exacta discreta	$W = w$ exactamente	$p_W(w; \theta)$
Agrupada	$a < W \leq b$	$P(a < W \leq b)$
Left-truncated	$W = w$ y sabemos que solo entran unidades con $W > d$	$f_W(w)/P(W > d)$ o su versión discreta
Right-censored	Sabemos únicamente que $W > u$	$P(W > u)$

Para una variable continua,

$$P(a < W \leq b) = F_W(b) - F_W(a).$$

Para una variable discreta,

$$P(a < W \leq b) = \sum_{\substack{k: \\ a < k \leq b}} p_W(k).$$

Y para una muestra truncada discreta,

$$P(W = w \mid W > d) = \frac{p_W(w)}{P(W > d)}.$$

Estas reglas no pertenecen exclusivamente a severity. El mismo principio se aplica a las tres clases de objetos que aparecen en el learning objective de esta sección:

Modelo	Datos completos	Datos agrupados	Datos truncados o censurados
Severity X	$f_X(x)$ para exact continuous severity	$F_X(b) - F_X(a)$	$f_X(x)/\bar{F}_X(d)$ si left-truncated; $\bar{F}_X(u)$ si right-censored
Frequency N	$p_N(n)$ para exact count	$\sum_{k \in B} p_N(k)$ para un count group B	$p_N(n)/P(N > d)$ si truncated; $P(N > u)$ si censored
Aggregate S	$g_S(s)$ o PMF, según el aggregate model	$G_S(b) - G_S(a)$ o suma de masses	conditional contribution si truncated; survival contribution si censored

No necesitamos un ejemplo numérico distinto en cada celda. La regla es la misma: primero identificar qué evento observó el sistema y después escribir la probabilidad de ese evento bajo el modelo.

La comparación fundamental entre los cuatro mecanismos queda así:

Pregunta	Complete	Grouped	Left truncation	Right censoring
¿La unidad aparece?	Sí	Sí	Solo si supera el threshold	Sí
¿Sabemos que existió?	Sí	Sí	No para unidades excluidas	Sí
¿Conocemos el valor exacto?	Sí	No; solo intervalo	Sí, una vez observada	No por encima del threshold
¿Hay conditioning denominator?	No	No	Sí	No
¿Hay survival contribution?	No, salvo que ese sea el evento exacto registrado	Puede existir en un grupo superior abierto	En el denominador	Sí para cada observación censurada

Desafío al lector: ¿pueden dos archivos mostrar exactamente las mismas cifras visibles y aun así producir likelihoods distintas?

Sí. Las diez severidades

$$\{4, 6, 8, 10, 12, 14, 18, 24, 36, 48\}$$

producen

$$\hat{\theta} = 18 \text{ mil USD}$$

cuando representan una muestra completa, pero

$$\hat{\theta} = 15.5 \text{ mil USD}$$

cuando representan una muestra observada condicionalmente a $X > 2.5$.

No cambiaron las cifras.

Cambió la afirmación estadística acerca de cómo llegaron a la muestra.

Ese principio también explica por qué observar solo aggregate totals no equivale a observar counts y severities individuales, por qué los grouped severity data requieren interval probabilities y por qué un censored value no puede sustituirse silenciosamente por el cap.

Ejercicios

Ejercicio 1 - Datos completos de severity y frequency

A. Severity completa

Se modela una severidad ground-up mediante

$$X \sim \text{Exponential}(\theta), \quad \theta > 0.$$

El actuario dispone de la muestra individual completa, en miles de USD:

$$\mathbf{x} = \{6, 12, 18, 30, 54\}.$$

1. Construya $\mathcal{L}(\theta; \mathbf{x})$.
2. Obtenga $\ell(\theta)$.
3. Derive la ecuación de score y calcule $\hat{\theta}_{MLE}$.
4. Verifique el espacio de parámetros.
5. Compruebe el máximo global mediante el comportamiento del score antes y después del candidato; utilice $\ell''(\hat{\theta}) < 0$ solo como comprobación local adicional.

6. Interprete el resultado sin denominarlo «true parameter».

La suma es

$$6 + 12 + 18 + 30 + 54 = 120 \text{ mil USD.}$$

Por tanto,

$$\ell(\theta) = -5 \ln \theta - \frac{120}{\theta},$$

y

$$\hat{\theta}_{MLE} = \frac{120}{5} = 24 \text{ mil USD}.$$

El score puede escribirse como

$$\ell'(\theta) = \frac{120 - 5\theta}{\theta^2}.$$

Es positivo para

$$0 < \theta < 24,$$

y negativo para

$$\theta > 24.$$

Así, 24 mil USD es el máximo global único. Además,

$$\ell''(24) = -\frac{5}{24^2} = -\frac{5}{576} < 0.$$

La interpretación correcta es que 24 mil USD maximiza la likelihood dentro del modelo Exponencial para esta muestra completa.

B. Frequency completa

Utilice ahora la experiencia canónica de Meridiano:

12,000 policy-years

y la tabla

$N = k$	Policy-years
0	11,325
1	635
2	35
3	5

Suponga

$$N \sim \text{Poisson}(\lambda).$$

1. Construya la likelihood a partir de las cuatro exact count categories.
2. Muestre que el total observado de claims es

$$635 + 2(35) + 3(5) = 720.$$

3. Derive la MLE.
4. Explique por qué esta forma de resumir los datos conserva la información necesaria para la MLE de λ .

El resultado debe ser

$$\hat{\lambda} = \frac{720}{12,000} = 0.060 \text{ claims por policy-year}.$$

El estudiante debe distinguir una tabla de frecuencias que conserva cada count exacto de un grouped continuous dataset que solo conserva interval membership.

Ejercicio 2 - Datos agrupados de severity

Meridiano conserva únicamente la siguiente información de 720 ground-up claims:

Intervalo, miles de USD	Claims
(0, 2.5]	96
(2.5, 10]	288
(10, 25]	196
(25, 50]	87
(50, 77.5]	28
(77.5, ∞)	25

Suponga

$$X \sim \text{Exponential}(\theta), \quad \theta > 0.$$

1. Escriba la probability correspondiente a cada intervalo.
2. Construya la grouped likelihood.
3. Explique qué información se inventaría al sustituir cada intervalo por un midpoint.
4. Señale por qué el open upper group $(77.5, \infty)$ ni siquiera posee un midpoint finito sin introducir una assumption adicional.

5. Maximice numéricamente la grouped likelihood y compare la estimate con la MLE de la muestra individual completa.
6. Explique por qué la diferencia entre las dos estimates no debe interpretarse como una cantidad universal de «sesgo por grouping».

Las probabilidades correctas son

$$1 - e^{-2.5/\theta},$$

$$e^{-2.5/\theta} - e^{-10/\theta},$$

$$e^{-10/\theta} - e^{-25/\theta},$$

$$e^{-25/\theta} - e^{-50/\theta},$$

$$e^{-50/\theta} - e^{-77.5/\theta},$$

y

$$e^{-77.5/\theta}.$$

La maximización numérica debe producir aproximadamente

$$\boxed{\hat{\theta}_{grouped} = 16.7987 \text{ mil USD} \approx 16,799 \text{ USD}}.$$

La complete-data reference es

18,000 USD.

El grouped estimate es menor en este caso concreto, pero la dirección no constituye una propiedad universal del grouping.

Ejercicio 3 - Truncation y censoring

Considere dos datasets diferentes bajo un modelo Exponencial de media $\theta > 0$.

Dataset A - Left truncation

Las cifras visibles, en miles de USD, son

$$\{4, 6, 8, 10, 12, 14, 18, 24, 36, 48\},$$

pero el sistema que produjo este archivo incluye una observación únicamente si

$$X > 2.5.$$

Dataset B - Right censoring

El archivo contiene

$$\{10, 20, 30, 50, 70, > 77.5, > 77.5\} \text{ mil USD.}$$

En este segundo archivo, las cinco primeras severities son exactas y las dos últimas permanecen en la muestra, pero solo sabemos que exceden 77.5 mil USD.

Para ambos datasets:

1. Identifique cuál es truncated y cuál censored.

2. Explique en palabras qué información contiene cada record antes de escribir la likelihood.
3. Construya las dos likelihoods.
4. Calcule las dos MLE correctas.
5. Calcule la MLE naive que surgiría al ignorar cada observation mechanism.
6. Explique por qué cambian las estimates sin afirmar que la dirección del cambio sea universal.

Para el Dataset A,

$$\mathcal{L}_{tr}(\theta) = \prod_{i=1}^{10} \frac{\theta^{-1} e^{-x_i/\theta}}{e^{-2.5/\theta}},$$

y

$$\boxed{\hat{\theta}_{tr} = 18 - 2.5 = 15.5 \text{ mil USD}}.$$

Si se ignorara el truncamiento,

$$\boxed{\hat{\theta}_{naive} = 18 \text{ mil USD}}.$$

Para el Dataset B,

$$\mathcal{L}_{cens}(\theta) = \theta^{-5} \exp\left(-\frac{335}{\theta}\right),$$

por lo que

$$\boxed{\hat{\theta}_{cens} = \frac{335}{5} = 67 \text{ mil USD}}.$$

Si las dos observaciones censuradas fueran tratadas erróneamente como exactas en 77.5,

$$\hat{\theta}_{naive} = \frac{335}{7} \approx 47.86 \text{ mil USD}.$$

El criterio de éxito es que el estudiante pueda explicar la diferencia antes de calcular:

- en truncation, ciertas unidades nunca aparecen en la muestra y la distribución observada debe condicionarse;
- en censoring, la unidad permanece observada, pero su valor exacto después del threshold se desconoce.

Cierre y puente final

La pregunta inicial de Irene era aparentemente sencilla:

«¿De dónde salen los parámetros?»

Ya no podemos responder únicamente:

«del histórico».

Depende de qué histórico llegó realmente al actuuario.

Un exact continuous claim aporta

$$f_X(x; \theta).$$

Un exact discrete count aporta

$$p_N(n; \theta).$$

Un intervalo aporta

$$F_X(b; \theta) - F_X(a; \theta).$$

Una observación tomada bajo left truncation aporta

$$\frac{f_X(x; \theta)}{\bar{F}_X(d; \theta)}.$$

Una observación right-censored aporta

$$\bar{F}_X(u; \theta).$$

Y si observamos únicamente aggregate totals, la likelihood debe construirse desde la distribución de S , no desde counts y severities individuales que el archivo no contiene.

Part 3 ha respondido así una pregunta concreta:

¿Qué estimate producen los datos que realmente observamos bajo el modelo especificado?

Pero esa respuesta abre inmediatamente otra.

Consideremos el subportfolio canónico de restaurantes de Meridiano. Tiene

400 policy-years

y

34 claims.

Bajo un modelo Poisson,

$$\hat{\lambda}_{restaurants} = \frac{34}{400} = 0.085 \text{ claims por policy-year}.$$

La frecuencia general de Meridiano es

0.060 claims por policy-year.

Por tanto, la estimate específica de restaurantes es superior en

$$\frac{0.085}{0.060} - 1 = 0.4167 \approx 41.7 \ %.$$

No hay nada incorrecto en la MLE de 0.085 dentro del modelo y de la muestra especificados.

Irene formula entonces una pregunta que máxima verosimilitud no puede responder por sí sola:

«¿Treinta y cuatro claims son suficientes para dejar que 0.085 domine nuestra decisión frente a una experiencia mucho mayor?»

Maximum likelihood nos ha enseñado a preguntar:

¿Qué estimate producen los datos?

La siguiente parte preguntará:

¿Cuánto peso merece esa estimate?

Si una clase pequeña produce una estimate específica distinta de la experiencia general, **¿cuánta experiencia necesitamos antes de permitir que esa cifra domine?**

Esa es la pregunta que abre la **Part 4 - Introduction to Credibility**, comenzando con la **Section 4.1 - Classical Credibility**.

4 - Introduction to Credibility

Section 4.1 - Classical Credibility

Tener datos propios no significa que debamos creerles por completo

4.1.1 La especificidad del dato propio no garantiza la estabilidad de su promedio

En el diseño tarifario de seguros de daños, el actuario se enfrenta de forma continua a la tensión entre la relevancia de la información y su confiabilidad estadística. Para ilustrar este dilema fundamental, consideremos la experiencia de frecuencia de siniestros registrada por **Meridiano Seguros** en su cartera comercial de daños. Al revisar los resultados del Accident Year 2024, la actuario de Pricing, **Lucía**, decide analizar de forma aislada un subportafolio específico: el segmento de **restaurantes**.

Los registros de Meridiano Seguros muestran dos realidades cuantitativas claras en su base de datos:

- **La cartera general:** Consta de exactamente 12,000 pólizas expuestas (*policy-years*) que han generado un total de 720 reclamaciones *ground-up*, lo que arroja una frecuencia empírica media de $\lambda_{\text{general}} = 0.060$ siniestros por unidad de exposición.
- **El segmento de restaurantes:** Registra una exposición más modesta de exactamente 400 *policy-years* y un conteo de 34 siniestros *ground-up*. Esto equivale a una frecuencia observada de $\hat{\lambda}_{\text{specific}} = 34/400 = 0.085$ siniestros por exposición.

Al comparar ambas cifras, Lucía observa que la tasa de siniestralidad de los restaurantes supera a la de la cartera general en un:

$$\frac{0.085}{0.060} - 1 = 41.67 \% \quad (\text{redondeado a } 41.7 \% \text{ en el análisis comercial}).$$

Ante esta marcada discrepancia, Lucía propone incrementar de inmediato la tarifa técnica de los restaurantes utilizando la frecuencia específica del 8.5 %, argumentando que esta cifra describe con total precisión la naturaleza de ese segmento.

Sin embargo, la actuaria jefa, **Irene**, frena el análisis con una advertencia metodológica rigurosa: *«Tu cálculo de frecuencia específica del 8.5 % es matemáticamente correcto bajo máxima verosimilitud, Lucía, pero es metodológicamente peligroso si ignoras el volumen de evidencia que lo sostiene. Dispones únicamente de 34 reclamaciones en restaurantes. Si el próximo año un solo restaurante evita sufrir un siniestro por azar, tu frecuencia observada caerá a un 8.25 %. ¿Tiene derecho un promedio tan inestable a guiar por sí solo nuestra política de suscripción y a ignorar la estabilidad de los 12,000 policy-years de la compañía?»*.

Este intercambio resume la esencia de la **Teoría de Credibilidad**. El actuario no puede limitarse a calcular un estimador puntual; debe medir cuánta información contiene realmente la muestra observada. La especificidad del dato propio (relevancia) no garantiza la estabilidad de su promedio (confiabilidad). Credibilidad es la disciplina actuarial que resuelve este conflicto de forma cuantitativa, determinando qué peso merece la experiencia específica frente al respaldo colectivo de la cartera.

4.1.2 El factor de credibilidad es una ponderación de evidencia, no una probabilidad de certeza

Para balancear de manera disciplinada la especificidad de los datos propios y la estabilidad de la experiencia general, introducimos el **factor de credibilidad**, denotado canónicamente por la variable Z . El factor Z es un ponderador aditivo acotado en el intervalo cerrado:

$$0 \leq Z \leq 1.$$

La estimación ajustada por credibilidad para la frecuencia de la cartera, denotada por $\hat{\lambda}_{\text{cred}}$ (o en términos genéricos por $\hat{\mu}$), se define como la combinación lineal ponderada de ambos estimadores:

$$\hat{\lambda}_{\text{cred}} = Z\hat{\lambda}_{\text{specific}} + (1 - Z)\lambda_{\text{general}}.$$

Es una exigencia de control de calidad desarmar de inmediato un error conceptual sumamente común en la interpretación de este factor: **el valor de Z no representa la probabilidad de que la estimación específica sea la “verdadera” tasa del mundo real.** En el marco estadístico frecuentista, el parámetro es una constante fija pero desconocida; Z describe el peso que se asigna a la experiencia específica dentro del estimador definido bajo un criterio de credibilidad.

La interacción de los límites del factor Z define la estructura de decisión actuarial:

- **Credibilidad Completa ($Z = 1$):** La experiencia específica recibe todo el peso dentro del estimador de credibilidad utilizado:

$$\hat{\lambda}_{\text{cred}} = \hat{\lambda}_{\text{specific}}.$$

Esto no significa que conozcamos la tasa verdadera ni que desaparezca la incertidumbre. Significa únicamente que el volumen alcanzó el umbral fijado por el criterio de fluctuación limitada seleccionado. El juicio actuarial sobre representatividad, calidad de datos, cobertura o cambios de underwriting sigue siendo necesario.

- **Credibilidad Parcial ($0 < Z < 1$):** La experiencia propia contiene información relevante pero insuficiente para recibir todo el peso, por lo que el estimador combina la experiencia específica con un complemento.

- **Credibilidad Nula ($Z = 0$):** El estimador depende completamente del complemento seleccionado:

$$\hat{\lambda}_{\text{cred}} = \lambda_{\text{general}}.$$

La cartera general tampoco debe interpretarse como “la verdad”. Es otra estimación basada en datos, más amplia pero menos específica para restaurantes.

4.1.3 El estándar de fluctuación limitada exige acotar el error de la cola con alta probabilidad

La formulación de la **Credibilidad de Fluctuación Limitada** (*Limited Fluctuation Credibility*) o credibilidad clásica se basa en una premisa de estabilidad probabilística: **queremos que la variable de conteo observada permanezca suficientemente cerca de su valor esperado con una probabilidad suficientemente alta**. El actuario debe definir explícitamente dos criterios de control para construir esta condición de estabilidad:

1. **La Tolerancia o Precisión Relativa (k):** El porcentaje máximo de desviación que estamos dispuestos a aceptar alrededor del valor esperado. Canónicamente fijamos este límite en $k = 0.05$ (tolerancia del 5 %).
2. **El Nivel de Probabilidad (p):** La probabilidad mínima de que la desviación del conteo no supere la tolerancia elegida. Canónicamente fijamos este nivel en $p = 0.90$.

Estos valores son un **criterio seleccionado para el caso pedagógico**, no una ley actuarial universal.

Matemáticamente, para una variable aleatoria de conteo N con media λ y varianza $\text{Var}(N)$, el estándar de credibilidad completa exige que:

$$P(|N - \lambda| \leq k\lambda) \geq p.$$

Para derivar de forma analítica el volumen necesario bajo este estándar, asumimos que el número de siniestros sigue una distribución de **Poisson**. Esta familia impone la restricción teórica de equidispersión:

$$E[N] = \text{Var}(N) = \lambda.$$

Aquí λ representa el **conteo esperado de siniestros en la unidad de volumen a la que se aplica el criterio**, no la frecuencia por policy-year 0.060 o 0.085 utilizada como estimación de tasa en otras partes del caso.

Asumiendo que el volumen esperado de siniestros es lo suficientemente grande como para justificar la aproximación Normal, estandarizamos la variable restando su media λ y dividiendo por su desviación estándar $\sqrt{\lambda}$:

$$P\left(\left|\frac{N - \lambda}{\sqrt{\lambda}}\right| \leq \frac{k\lambda}{\sqrt{\lambda}}\right) \geq p \quad \Rightarrow \quad P(|Z_0| \leq k\sqrt{\lambda}) \geq p,$$

donde $Z_0 \sim N(0, 1)$. Para una probabilidad central igual a p , el límite correspondiente es el cuantil Normal estándar $z_{(1+p)/2}$.

Para nuestro nivel canónico $p = 0.90$, el cuantil relevante es:

$$z_{(1+0.90)/2} = z_{0.95} = 1.6448536.$$

Sustituyendo el cuantil en la frontera del intervalo, la condición límite de estabilidad exige que:

$$k\sqrt{\lambda} \geq z_{(1+p)/2} \quad \Rightarrow \quad \sqrt{\lambda} \geq \frac{z_{(1+p)/2}}{k} \quad \Rightarrow \quad \lambda \geq \left(\frac{z_{(1+p)/2}}{k}\right)^2.$$

Definimos el estándar de credibilidad completa, denotado por N_0 , como el número esperado mínimo de siniestros necesario para cumplir esta condición:

$$N_0 = \left(\frac{z_{(1+p)/2}}{k} \right)^2.$$

Sustituyendo los parámetros canónicos de Meridiano Seguros ($p = 0.90$, $k = 0.05$ y $z_{0.95} = 1.6448536$), obtenemos:

$$N_0 = \left(\frac{1.6448536}{0.05} \right)^2 = (32.897072)^2 = 1,082.217346 \text{ expected claims.}$$

Este resultado, que redondeamos operacionalmente a aproximadamente 1,082 siniestros esperados, representa el estándar de credibilidad completa bajo **este** criterio Poisson/Normal. No significa que con 1,082 claims conozcamos la verdadera frecuencia; significa que se ha alcanzado el volumen exigido por el estándar elegido.

Es fundamental evaluar la **sensibilidad** de este estándar ante cambios en las exigencias de estabilidad, demostrando que N_0 no es una constante física inmutable:

- **Reducción de la tolerancia a la mitad ($k = 0.025$, precisión del 2.5 %):** Manteniendo $p = 0.90$,

$$N_0 = \left(\frac{1.6448536}{0.025} \right)^2 = (65.794144)^2 = 4,328.869385 \text{ expected claims.}$$

Debido a la relación $N_0 \propto 1/k^2$, reducir la tolerancia a la mitad exige aproximadamente cuadruplicar el volumen requerido. Para los mismos 34 claims observados de restaurantes, el factor de credibilidad parcial caería a:

$$Z = \sqrt{\frac{34}{4,328.869385}} \approx 0.088624.$$

- **Incremento de la probabilidad requerida ($p = 0.95$):** Manteniendo $k = 0.05$, el cuantil relevante pasa a ser $z_{0.975} = 1.959964$:

$$N_0 = \left(\frac{1.959964}{0.05} \right)^2 = (39.19928)^2 = 1,536.583553 \text{ expected claims.}$$

Para los mismos 34 claims observados:

$$Z = \sqrt{\frac{34}{1,536.583553}} \approx 0.148752.$$

Por tanto, para un volumen específico fijo, un estándar más exigente aumenta N_0 y reduce la credibilidad parcial asignada a esa experiencia.

4.1.4 La raíz cuadrada de la exposición rescata el valor informativo de las muestras pequeñas

Una vez establecido que el subportafolio de restaurantes de Meridiano registra apenas 34 reclamaciones observadas, resulta evidente que está muy por debajo del estándar de credibilidad completa de $N_0 = 1,082.217346$ expected claims. La comparación relevante es entre **claims y claims**: no debemos comparar directamente los 400 policy-years de exposición con un estándar expresado en expected claims.

Existe además una pequeña distinción conceptual importante. El estándar N_0 fue derivado en términos de **expected claim count**. En la aplicación práctica de esta regla de credibilidad parcial, utilizamos los 34 **observed claims** como proxy del volumen de información disponible. No son exactamente el mismo objeto teórico.

Para rescatar esta evidencia sin sobreestimar su estabilidad, aplicamos la regla de credibilidad parcial de raíz cuadrada con su límite superior:

$$Z = \min \left(1, \sqrt{\frac{N}{N_0}} \right).$$

Cuando $N < N_0$, esta expresión se reduce a:

$$Z = \sqrt{\frac{N}{N_0}}.$$

La justificación intuitiva de esta regla se apoya en que el error estándar relativo de un conteo Poisson disminuye en proporción a la inversa de la raíz cuadrada del volumen:

$$\text{Relative Standard Error} \propto \frac{1}{\sqrt{N}}.$$

Por ello, dentro de **este framework clásico de fluctuación limitada**, el peso parcial aumenta con $\sqrt{N}$ y no linealmente con N . La regla de raíz cuadrada no es una ley universal de toda teoría de credibilidad; es la regla utilizada en este setup clásico específico.

Para restaurantes:

$$Z = \min \left(1, \sqrt{\frac{34}{1,082.217346}} \right) = \sqrt{0.03141604} = 0.17724835.$$

Por tanto, bajo este estándar asignamos aproximadamente 17.7 % del peso a la experiencia específica de restaurantes. El restante 82.3 % corresponde al complemento seleccionado.

Este resultado demuestra que **duplicar el volumen observado de siniestros no duplica el factor de credibilidad**. Si el volumen se duplicara de 34 a 68 claims:

$$Z(68) = 0.177248\sqrt{2} = 0.250667 \quad (\text{aproximadamente } 25.1 \%).$$

Para duplicar aproximadamente la credibilidad desde 17.7 % hasta 35.5 %, Meridiano necesita cuadruplicar el número de reclamaciones observadas de 34 a 136 claims:

$$Z(136) = \sqrt{\frac{136}{1,082.217346}} = 0.354497 \quad (\text{aproximadamente } 35.5 \%).$$

Si el volumen superara N_0 , el cap evita que el peso exceda 1:

$$Z = 1.$$

4.1.5 La estimación ponderada devuelve el precio hacia el centro de gravedad de la cartera

Una vez calculado el factor de credibilidad $Z = 0.17724835$ para el subportafolio de restaurantes, procedemos a realizar la combinación ponderada para determinar la frecuencia ajustada por credibilidad, utilizando la tasa específica de restaurantes ($\hat{\lambda}_{\text{specific}} = 0.085$) y la tasa general de la cartera de Meridiano como complemento ($\lambda_{\text{general}} = 0.060$):

$$\hat{\lambda}_{\text{cred}} = Z\hat{\lambda}_{\text{specific}} + (1 - Z)\lambda_{\text{general}}.$$

$$\hat{\lambda}_{\text{cred}} = 0.17724835(0.085) + (1 - 0.17724835)(0.060).$$

$$\hat{\lambda}_{\text{cred}} = 0.01506611 + 0.04936510 = 0.06443121 \text{ claims por policy-year.}$$

Este estimador, que redondeamos a 0.0644 claims por policy-year o aproximadamente 6.44 %, es la cantidad ajustada por credibilidad bajo el criterio y el complemento seleccionados.

El resultado ilustra el efecto de contracción hacia el complemento: a pesar de que el segmento de restaurantes registró una frecuencia empírica 41.7 % superior a la de la compañía, la frecuencia ajustada por credibilidad se ubica aproximadamente un 7.39 % por encima de la frecuencia general:

$$\frac{0.06443121}{0.060} - 1 \approx 0.07385 = 7.39 \%.$$

La variación absoluta es:

$$\hat{\lambda}_{\text{cred}} - \lambda_{\text{general}} = 0.06443121 - 0.060 = 0.00443121.$$

Y coincide con la fracción Z de la desviación específica respecto del complemento:

$$\hat{\lambda}_{\text{cred}} - \lambda_{\text{general}} = Z \left(\hat{\lambda}_{\text{specific}} - \lambda_{\text{general}} \right),$$

$$0.17724835(0.085 - 0.060) = 0.17724835(0.025) = 0.00443121.$$

Esta identidad permite ver con precisión qué hace Z : conserva solo una fracción Z de la desviación específica respecto del complemento.

Sin embargo, el cálculo mezcla tres niveles que deben permanecer separados:

1. **Convención o criterio:** Meridiano selecciona $p = 90\%$ y tolerancia relativa $k = 5\%$.
2. **Matemática:** Ese criterio, bajo Poisson y aproximación Normal, produce $N_0 \approx 1,082.2$ expected claims y, para 34 observed claims, $Z \approx 0.177$.
3. **Juicio actuarial:** Se selecciona 0.060 como complemento porque la cartera general es mucho más amplia y se considera razonablemente comparable para este ejercicio.

La matemática de credibilidad no selecciona por sí sola el complemento. La cartera general sigue siendo una estimación basada en datos, no una verdad universal. Si los restaurantes fueran estructuralmente distintos del resto de la cartera por cobertura, underwriting, geografía o definición de exposición, la contracción hacia el portafolio general podría introducir un desajuste sistemático. Credibilidad modera fluctuación estadística; no elimina heterogeneidad estructural.

Asimismo, cambiar el complemento no cambia Z mientras permanezcan iguales el claim count y el estándar. Si utilizáramos otro complemento m :

$$\hat{\lambda}_{\text{cred}} = Z(0.085) + (1 - Z)m,$$

el resultado final cambiaría, pero Z seguiría determinado por el mismo volumen y el mismo estándar. De forma análoga, bajo esta regla basada en claim count, cambiar la estimación específica sin cambiar N ni N_0 modifica la cantidad ponderada, pero no necesariamente el factor Z .

Finalmente, credibilidad no es un mecanismo de limpieza de datos. Errores de clasificación, exposición o cobertura deben resolverse antes de ponderar la experiencia; asignar menos peso a una estimación defectuosa no la convierte en información correcta.

4.1.6 El estándar pertenece a la variable de riesgo y no se transfiere de forma automática

Es una exigencia de gran importancia metodológica advertir al lector que **el factor de credibilidad calculado para una variable de frecuencia no puede transferirse de forma mecánica a otra variable de riesgo de la misma cartera, como el Gross Loss Cost.**

Consideremos los **gross insurer payments** registrados por el subportafolio de restaurantes de Meridiano, que ascienden a 520,000 USD sobre los mismos 400 policy-years. El gross loss cost observado es:

$$LC_{\text{restaurants}} = \frac{520,000}{400} = 1,300 \text{ USD por exposición.}$$

Por su parte, los gross insurer payments de la cartera general ascienden a 9.360 millones de USD sobre 12,000 policy-years:

$$LC_{\text{general}} = \frac{9,360,000}{12,000} = 780 \text{ USD por exposición.}$$

La discrepancia observada es:

$$\frac{1,300}{780} - 1 = 66.67\% \quad (\text{redondeado a } 66.7\% \text{ en prosa}).$$

Ante esta desviación, un actuario junior podría verse tentado a aplicar directamente el factor de credibilidad de frecuencia $Z = 0.177$ para ponderar el loss cost de restaurantes. **No puede hacerse con la derivación disponible.**

El estándar:

$$N_0 = \left(\frac{z}{k}\right)^2$$

fue derivado específicamente para un **conteo Poisson**. El gross loss cost, en cambio, depende del número de siniestros y de los gross insurer payments individuales. Si representamos esos payments por $Y_1, Y_2, \dots$, la variabilidad del costo agregado depende de cantidades adicionales a la media del count, como la varianza o el segundo momento de Y y, según el modelo utilizado, la varianza de frecuencia y las relaciones asumidas entre count y payment severity.

Por tanto, los datos disponibles aquí no permiten afirmar numéricamente cuál sería el full-credibility standard para gross loss cost ni si su factor Z sería mayor o menor que 17.7%. Para construirlo necesitaríamos información adicional sobre la variabilidad de la cantidad económica que estamos intentando acreditar, además de especificar los supuestos del modelo correspondiente.

La separación vuelve a ser la misma:

- **Matemática:** una vez especificada la variable, su modelo, su variabilidad y el criterio de estabilidad, puede derivarse un estándar y un peso.
- **Juicio actuarial:** sigue siendo necesario decidir si la experiencia complementaria es relevante y comparable para esa misma cantidad económica.

La credibilidad pertenece a una **variable aleatoria y a un estándar determinados**, no al segmento de negocio en abstracto.

Cierre y Puente Final

Al concluir esta sección, hemos establecido que tener datos propios no significa que debamos creerles por completo. El análisis de credibilidad clásica de fluctuación limitada nos ha enseñado a equilibrar de forma matemática la especificidad del dato propio con la estabilidad de la experiencia colectiva. Las 34 reclamaciones de restaurantes quedan muy lejos del estándar canónico de aproximadamente 1,082.2 expected claims, por lo que reciben un peso de credibilidad de aproximadamente 17.7 %. Al combinarlas con el complemento general de 6.0 %, obtenemos una frecuencia ponderada de aproximadamente 6.44 %.

La diferencia entre restaurantes y la cartera general no desapareció. Se moderó en proporción al volumen de evidencia que puede sostener el criterio seleccionado. La experiencia específica decía algo importante, pero todavía no había acumulado suficiente evidencia para decirlo sola. La estimación 0.085 producida por los datos y la cantidad ajustada por credibilidad 0.0644 responden a preguntas distintas y no deben confundirse.

Hasta este punto de la serie, hemos construido variables, distribuciones, parámetros, estimaciones y pesos de credibilidad. La siguiente pregunta cambia de **cuánta información creemos a qué hacemos con esa información**.

Al 31 December 2025, Mateo observa accident years que todavía no han terminado de desarrollarse. La pregunta deja de ser “¿cuánto peso merece la experiencia?” y pasa a ser:

¿Cuánto falta por emerger de losses que ya ocurrieron?

Eso abre la **Section 5.1 - Loss Reserving: Expected Loss Ratio, Chain-Ladder y Bornhuetter-Ferguson**.

Ejercicios

Ejercicio 1 - Full credibility

Un actuario analiza una cartera comercial de Meridiano Seguros bajo un modelo Poisson. El estándar base exige que el claim count observado permanezca dentro de una tolerancia

relativa del 5 % de su expected value con probabilidad 90 %. Para una segunda evaluación, considere los dos estándares alternativos ya analizados: (A) mantener $p = 90\%$ y reducir la tolerancia a $k = 2.5\%$; (B) mantener $k = 5\%$ y elevar la probabilidad requerida a $p = 95\%$, con $z_{0.975} = 1.959964$.

1. Identifique el cuantil Normal bilateral correcto para el estándar base.
2. Derive el estándar de full credibility N_0 y explique sus unidades.
3. Recalcule N_0 para los escenarios A y B.
4. Explique por qué ninguno de estos estándares constituye una constante actuarial universal.

Criterio de éxito para la solución:

- Para $p = 90\%$, el cuantil bilateral es $z_{0.95} = 1.6448536$.
- Estándar base:

$$N_0 = \left(\frac{1.6448536}{0.05} \right)^2 = 1,082.217346 \text{ expected claims.}$$

- Escenario A:

$$N_{0,A} = \left(\frac{1.6448536}{0.025} \right)^2 = 4,328.869385 \text{ expected claims.}$$

- Escenario B:

$$N_{0,B} = \left(\frac{1.959964}{0.05} \right)^2 = 1,536.583553 \text{ expected claims.}$$

- El estándar depende de p , k y de los supuestos Poisson/Normal utilizados; por tanto, no es universal.

Ejercicio 2 - Partial credibility

La clase de **hoteles** registra 600 policy-years y 45 reclamaciones ground-up, por lo que su frecuencia observada es:

$$\hat{\lambda}_{\text{specific}} = \frac{45}{600} = 0.075 \text{ claims por policy-year.}$$

Utilice como complemento la frecuencia general de Meridiano, $m = 0.060$, y el estándar de full credibility $N_0 = 1,082.217346$ expected claims.

1. Calcule el factor de credibilidad utilizando:

$$Z = \min \left(1, \sqrt{\frac{N}{N_0}} \right),$$

identificando si el cap en 1 resulta vinculante.

2. Calcule la frecuencia ajustada por credibilidad.
3. Verifique la identidad:

$$\hat{\lambda}_{\text{cred}} - m = Z \left(\hat{\lambda}_{\text{specific}} - m \right).$$

4. Interprete correctamente Z sin describirlo como probabilidad ni nivel de confianza.

Criterio de éxito para la solución:

$$Z = \min \left(1, \sqrt{\frac{45}{1,082.217346}} \right) = 0.20391492.$$

El cap no es vinculante porque $Z < 1$.

$$\hat{\lambda}_{\text{cred}} = 0.20391492(0.075) + 0.79608508(0.060) = 0.06305872 \text{ claims por policy-year.}$$

Y:

$$0.06305872 - 0.060 = 0.00305872,$$

mientras que:

$$0.20391492(0.075 - 0.060) = 0.20391492(0.015) = 0.00305872.$$

El factor $Z \approx 20.39\%$ significa que, bajo este estándar y esta regla de credibilidad parcial, aproximadamente 20.39% del peso del estimador se asigna a la experiencia específica de hoteles; no significa que exista una probabilidad de 20.39% de que su frecuencia sea correcta.

Ejercicio 3 - Transferencia incorrecta del credibility factor

En restaurantes, el cálculo de frecuencia produjo $Z \approx 0.177$ utilizando 34 observed claims frente a $N_0 \approx 1,082.2$ expected claims. Para la misma clase, los gross insurer payments observados ascienden a 520,000 USD sobre 400 policy-years, por lo que:

$$LC_{\text{restaurants}} = 1,300 \text{ USD por exposición.}$$

La cartera general presenta:

$$LC_{\text{general}} = 780 \text{ USD por exposición.}$$

1. ¿Puede reutilizarse automáticamente $Z = 0.177$ para ponderar el gross loss cost de restaurantes?

2. Explique por qué o por qué no.
3. Identifique qué información adicional de variabilidad sería necesaria para construir un credibility standard apropiado para loss cost.
4. Distinga qué parte de la decisión sería matemática y qué parte seguiría requiriendo juicio actuarial.

Criterio de éxito para la solución:

- No puede reutilizarse automáticamente $Z = 0.177$ porque ese factor proviene de un estándar derivado específicamente para un claim count Poisson.
- Para gross loss cost se necesitaría información adicional sobre la variabilidad de los gross insurer payments, como su varianza o segundo momento, además de la estructura de variabilidad de frecuencia y los supuestos del modelo correspondiente.
- La matemática determina el estándar y el peso una vez definidos variable, modelo, criterio y inputs de variabilidad.
- El juicio actuarial sigue interviniendo en la selección de una experiencia complementaria suficientemente amplia, estable y razonablemente comparable.

5 - Pricing and Reserving for Short-Term Insurance Coverages

Section 5.1 - Loss Reserving: Expected Loss Ratio, Chain-Ladder y Bornhuetter-Ferguson

El costo final de un año de accidentes no está escrito en el triángulo de pérdidas actual

5.1.1 El costo último de un año de accidentes no es la cifra que hoy registra la diagonal

En la práctica de la contabilidad y la gestión actuarial de una compañía de seguros de daños como **Meridiano Seguros**, el cálculo de provisiones técnicas para siniestros pendientes de liquidación constituye la base de la solvencia institucional. Al situarnos en la fecha de valoración del **31 de diciembre de 2025**, el actuario jefe de Reservas, **Mateo**, se enfrenta a un desafío analítico central: determinar el costo último de los siniestros que ya comenzaron a ocurrir durante los periodos de cobertura pasados (Accident Years 2021 a 2025), pero que aún no han terminado de reportarse o de reflejarse plenamente en la base de pérdidas incurridas.

Para ilustrar este conflicto temporal, consideremos la siniestralidad acumulada del Accident Year 2025. Al cierre de este año, los registros contables de Meridiano Seguros muestran

pérdidas acumuladas incurridas -pagos acumulados más estimaciones de casos individuales- por un importe de exactamente **8.25 millones de USD** a la edad de desarrollo de 12 meses.

Desafío al lector 1. El AY 2021 registra 8.70M USD a los 60 meses y el AY 2025 registra 8.25M USD a los 12 meses. ¿Podemos concluir, solo por comparar esas dos cifras, que AY 2025 terminará siendo más barato?

La respuesta es no: pertenecen a edades de desarrollo distintas. Las reclamaciones de la cartera de seguros comerciales de daños pueden continuar reportándose y revisándose durante meses o años después del accidente.

Para modelar este proceso de maduración, los actuarios organizan la información en estructuras triangulares. El triángulo canónico de Meridiano Seguros registra las **pérdidas brutas acumuladas reportadas/incurridas**, expresadas en **millones de USD**:

$$\mathbf{C} = \begin{pmatrix} 7.30 & 8.20 & 8.53 & 8.66 & \mathbf{8.70} \\ 7.48 & 8.40 & 8.74 & \mathbf{8.87} & - \\ 7.68 & 8.62 & \mathbf{8.96} & - & - \\ 7.90 & \mathbf{8.86} & - & - & - \\ \mathbf{8.25} & - & - & - & - \end{pmatrix}.$$

Las filas representan los años de accidente, $i = 2021, \dots, 2025$, y las columnas las edades de desarrollo, $j = 12, 24, 36, 48, 60$ meses. En la fecha de valoración del 31 de diciembre de 2025, las últimas edades observadas son:

AY	Última edad observada	Pérdida acumulada observada
2021	60 meses	8.70M USD
2022	48 meses	8.87M USD
2023	36 meses	8.96M USD
2024	24 meses	8.86M USD
2025	12 meses	8.25M USD

La diagonal más reciente es, por tanto, $\{8.70, 8.87, 8.96, 8.86, 8.25\}$ millones de USD. Cada

cifra resume el desarrollo acumulado disponible para un año de accidente distinto.

Desafío al lector 2. En AY 2021, ¿el valor 8.20M USD a los 24 meses significa que durante el segundo año aparecieron 8.20M USD adicionales?

No. El triángulo es **acumulado**. El desarrollo incremental entre 12 y 24 meses para AY 2021 es:

$$8.20 - 7.30 = \mathbf{0.90M\ USD}.$$

No necesitamos transformar todo el triángulo a formato incremental, pero sí conservar esta distinción para no interpretar una celda acumulada como flujo adicional del intervalo.

El objetivo de reserving es estimar el **costo último** U_i de cada año inmaduro y, a partir de él, la **reserva de siniestros pendientes** R_i :

$$R_i = U_i - C_{i,\text{latest}}.$$

El ultimate y la reserve no son sinónimos. Si un año tiene 8.25M USD observados y un método estima un ultimate de aproximadamente 9.82M USD, la reserve es la diferencia, no el ultimate completo. La reserva global del portafolio será la suma de las reservas de los años correspondientes.

5.1.2 El método de Razón de Siniestralidad Esperada se aferra a la expectativa previa e ignora la inmadurez de la diagonal

El método de **Razón de Siniestralidad Esperada** (*Expected Loss Ratio*, **ELR**) parte de una expectativa técnica previa. Para Meridiano Seguros, la razón de siniestralidad esperada canónica es **75 %**. Para un año de accidente inmaduro, el método estima la pérdida última esperada aplicando ese priori a la prima ganada:

$$U_i^{ELR} = \Pi_i \times ELR.$$

Después obtiene la reserva como diferencia entre ese ultimate esperado y lo ya observado:

$$R_i^{ELR} = U_i^{ELR} - C_{i,\text{latest}}.$$

Desafío al lector 3. Si las pérdidas acumuladas de un año joven aumentaran mañana pero su prima ganada y el ELR de 75 % permanecieran fijos, ¿cambiaría el ultimate ELR o únicamente la reserva?

La estructura de la fórmula muestra que el ultimate permanece anclado al priori mientras la reserva absorbe la diferencia frente a lo observado.

Antes de aceptar esa estabilidad, el actuario debe defender los supuestos que la sostienen: que la prima ganada esté en una base comparable, que el 75 % continúe siendo una expectativa relevante para el año analizado, que no hayan cambiado de forma material el rate level, la cobertura o el business mix, y que el priori represente razonablemente el riesgo de ese Accident Year. La preparación formal de primas a una base tarifaria comparable pertenece a la Section 5.2; aquí basta reconocer que la calidad del ELR depende de la calidad de su priori y de la base de prima utilizada.

Compuerta canónica de AY 2024

La Biblia Numérica v1.0 contiene una incidencia de continuidad que no ha sido resuelta por una versión posterior: el dataset central de 2024 utiliza **12,000 policy-years**, mientras que la tabla histórica de Reserving/Ratemaking utiliza **12,500 exposures** para ese mismo año. Como esa diferencia afecta directamente la prima ganada de AY 2024, también afecta su ultimate y su reserve bajo ELR y BF.

Por tanto, esta sección **no adopta silenciosamente ninguna de las dos bases**. Los resultados de ELR y BF para AY 2024, así como los totales globales de esos dos métodos que dependan de AY 2024, permanecen sin cerrar hasta que el canon sea reconciliado. Esta incidencia no afecta el triángulo ni los cálculos de Chain-Ladder.

Los años no afectados por esa incidencia permiten aplicar ELR sin ambigüedad:

- **AY 2022:** prima ganada de 11.900M USD,

$$U_{2022}^{ELR} = 11.90(0.75) = \mathbf{8.925M} \text{ USD},$$

y

$$R_{2022}^{ELR} = 8.925 - 8.87 = \mathbf{0.055M} \text{ USD}.$$

- **AY 2023:** prima ganada de 12.360M USD,

$$U_{2023}^{ELR} = 12.36(0.75) = \mathbf{9.270M} \text{ USD},$$

y

$$R_{2023}^{ELR} = 9.270 - 8.96 = \mathbf{0.310M} \text{ USD}.$$

- **AY 2025:** prima ganada de 13.789125M USD,

$$U_{2025}^{ELR} = 13.789125(0.75) = \mathbf{10.341844M} \text{ USD},$$

y

$$R_{2025}^{ELR} = 10.341844 - 8.25 = \mathbf{2.091844M} \text{ USD}.$$

Es también esencial el tratamiento de **AY 2021**. Al 31 de diciembre de 2025, ese año ha alcanzado 60 meses y, bajo el supuesto operativo canónico, se considera completamente desarrollado: $F_{60} = 1$. Por tanto,

$$R_{2021} = 0,$$

y su ultimate es el valor observado:

$$U_{2021} = 8.70M \text{ USD},$$

no el priori inicial de 8.625M USD. Una expectativa previa no debe sobrescribir un resultado ya maduro.

ELR aporta estabilidad porque su ultimate no reacciona mecánicamente a cada movimiento temprano de la diagonal. Esa misma propiedad es también su vulnerabilidad: si la experiencia emergente contiene información que contradice el priori, el método no incorpora esa señal en el ultimate mientras el priori permanezca fijo.

5.1.3 El método Chain-Ladder cree en la inercia de la siniestralidad emergente para proyectar su escala final

En el extremo opuesto se sitúa **Chain-Ladder**. Este método no utiliza la prima ganada ni el ELR para construir su ultimate. Parte del patrón histórico observado en el propio triángulo y supone que ese patrón de desarrollo puede utilizarse para proyectar los años más jóvenes.

Desafío al lector 4. Para estimar cuánto crecen las pérdidas de 12 a 24 meses, ¿deberíamos utilizar únicamente el AY más reciente con ambas edades observadas, o combinar todos los años que contienen las dos celdas comparables?

Chain-Ladder utiliza aquí factores de desarrollo de edad a edad volumen-ponderados:

$$f_j = \frac{\sum_i C_{i,j+12}}{\sum_i C_{i,j}}.$$

Para Meridiano:

$$f_{12-24} = \frac{8.20 + 8.40 + 8.62 + 8.86}{7.30 + 7.48 + 7.68 + 7.90} = \frac{34.08}{30.36} = 1.1225296443.$$

$$f_{24-36} = \frac{8.53 + 8.74 + 8.96}{8.20 + 8.40 + 8.62} = \frac{26.23}{25.22} = 1.0400475813.$$

$$f_{36-48} = \frac{8.66 + 8.87}{8.53 + 8.74} = \frac{17.53}{17.27} = \mathbf{1.0150550087}.$$

$$f_{48-60} = \frac{8.70}{8.66} = \mathbf{1.0046189376}.$$

Los factores acumulados hasta 60 meses son:

$$F_{48} = 1.0046189376,$$

$$F_{36} = 1.0150550087(1.0046189376) = \mathbf{1.0197434845},$$

$$F_{24} = 1.0400475813(1.0197434845) = \mathbf{1.0605817446},$$

$$F_{12} = 1.1225296443(1.0605817446) = \mathbf{1.1905344484}.$$

La proporción desarrollada a cada edad es:

$$p_j = \frac{1}{F_j},$$

por lo que las proporciones desarrolladas y pendientes son aproximadamente:

Edad	Desarrollado p_j	Pendiente $1 - p_j$
12 meses	83.996 %	16.004 %
24 meses	94.288 %	5.712 %
36 meses	98.064 %	1.936 %
48 meses	99.540 %	0.460 %
60 meses	100.000 %	0.000 %

Con esos factores, Chain-Ladder estima:

$$U_i^{CL} = C_{i,\text{latest}} F_j,$$

y

$$R_i^{CL} = C_{i,\text{latest}}(F_j - 1).$$

Los resultados son:

AY	Edad	Ultimate CL	Reserve CL
2021	60	8.700000M USD	0
2022	48	8.910970M USD	0.040970M USD
2023	36	9.136902M USD	0.176902M USD
2024	24	9.396754M USD	0.536754M USD
2025	12	9.821909M USD	1.571909M USD

Así, la reserva pendiente total de Chain-Ladder es:

$$R_{\text{total}}^{CL} = 0 + 0.040970 + 0.176902 + 0.536754 + 1.571909 = \mathbf{2.326535M\ USD},$$

redondeada en los controles canónicos a **2.327 millones de USD**.

Desafío al lector 5. Si mañana AY 2025 aumenta en 0.50M USD de pérdidas incurridas pero el factor F_{12} permanece fijo, ¿deberíamos esperar que la reserve Chain-Ladder baje porque “ya apareció más pérdida”, o que suba porque la escala completa del año se proyectará desde una base mayor?

La respuesta se comprobará en la sensibilidad de la siguiente subsección: con un factor acumulado superior a uno, un aumento de la diagonal también eleva el ultimate proyectado.

Antes de aceptar Chain-Ladder, Mateo debe defender que el desarrollo histórico sea predictivo, que no hayan cambiado materialmente la velocidad de reporte o el claims handling,

que las celdas mantengan una base consistente, que no existan eventos excepcionales que distorsionen el patrón y que el historial maduro sea suficiente para sostener los factores. Un retraso administrativo importante podría reducir artificialmente la pérdida acumulada observada; si se aplicara el patrón sin cuestionar esa ruptura, Chain-Ladder podría interpretar la lentitud operativa como una reducción de la escala del año.

5.1.4 El método Bornhuetter-Ferguson aplica el priori únicamente a la porción de desarrollo pendiente

Entre un ultimate fijado por el priori y un ultimate proyectado directamente desde la diagonal, **Bornhuetter-Ferguson (BF)** combina dos fuentes de información de una forma específica: conserva las pérdidas ya observadas y utiliza el priori de pérdida última solamente para estimar la porción que, según el patrón de desarrollo, todavía no ha emergido.

Desafío al lector 6. ¿BF es simplemente el promedio de ELR y Chain-Ladder?

No. Su estructura no promedia dos ultimates. Si

$$p_j = \frac{1}{F_j},$$

entonces la proporción pendiente es:

$$1 - p_j = 1 - \frac{1}{F_j}.$$

Con un priori de pérdida última

$$U_i^{prior} = \Pi_i \times ELR,$$

la reserva BF es:

$$R_i^{BF} = U_i^{prior} (1 - p_j) = U_i^{prior} \left(1 - \frac{1}{F_j} \right),$$

y el ultimate estimado es:

$$U_i^{BF} = C_{i,\text{latest}} + R_i^{BF}.$$

Para los años no afectados por la incidencia canónica de AY 2024:

- **AY 2021 (60 meses):** $p_{60} = 1$, por lo que

$$R_{2021}^{BF} = 0, \quad U_{2021}^{BF} = \mathbf{8.700000M \text{ USD}}.$$

- **AY 2022 (48 meses):** el priori es $8.925M$ USD y la proporción pendiente es aproximadamente 0.45977% :

$$R_{2022}^{BF} = 8.925(0.00459770) = \mathbf{0.041034M \text{ USD}},$$

$$U_{2022}^{BF} = 8.87 + 0.041034 = \mathbf{8.911034M \text{ USD}}.$$

- **AY 2023 (36 meses):** el priori es $9.270M$ USD y la proporción pendiente es aproximadamente 1.93612% :

$$R_{2023}^{BF} = 9.270(0.01936123) = \mathbf{0.179479M \text{ USD}},$$

$$U_{2023}^{BF} = 8.96 + 0.179479 = \mathbf{9.139479M \text{ USD}}.$$

- **AY 2025 (12 meses):** el priori es $10.341844M$ USD y la proporción pendiente es aproximadamente 16.00411% :

$$R_{2025}^{BF} = 10.341844(0.16004110) = \mathbf{1.655120M \text{ USD}},$$

$$U_{2025}^{BF} = 8.25 + 1.655120 = \mathbf{9.905120M \text{ USD.}}$$

El cálculo de AY 2024 bajo BF no se presenta como definitivo porque depende del priori construido sobre una prima ganada cuya base de exposure continúa en disputa. Por la misma razón, tampoco se presenta un total BF global definitivo.

Desafío al lector 7. A 12 meses, 16.004 % permanece sin desarrollar. ¿Significa eso que BF asigna “la gran mayoría” del peso al priori?

No. Significa exactamente que el priori se aplica a la **porción pendiente del 16.004 %**. El 83.996 % desarrollado ya está representado por la pérdida acumulada observada dentro de la estructura aditiva de BF. A medida que el año madura, la fracción pendiente disminuye y, con ella, disminuye la parte de la reserva que depende del priori.

BF exige defender simultáneamente dos elementos: el patrón de desarrollo y el priori esperado. Combinar dos fuentes no garantiza por sí mismo un mejor resultado; si una de ellas deja de ser representativa, la estimación puede deteriorarse.

5.1.5 La asimetría de los métodos se revela ante perturbaciones en los datos o en el priori

Para consolidar el aprendizaje, Irene somete al Accident Year 2025 de Meridiano a dos pruebas de sensibilidad. Antes de calcular, la pregunta es siempre la misma: **¿qué información está creyendo este número?**

Experimento 1: shock de siniestralidad reportada

Las pérdidas acumuladas incurridas de AY 2025 aumentan en **0.50 millones de USD**, de $8.25M$ a $8.75M$ USD. Los link ratios históricos y el priori permanecen fijos.

Antes de mirar las operaciones, anticipe la dirección: ¿debería bajar la reserve de los tres métodos?

- **ELR:** el ultimate permanece en 10.341844M USD. La nueva reserve es

$$R_{2025}^{ELR} = 10.341844 - 8.75 = \mathbf{1.591844M} \text{ USD},$$

una disminución de 0.50M USD.

- **Chain-Ladder:** el nuevo ultimate es

$$8.75(1.19053445) = \mathbf{10.417176M} \text{ USD},$$

un aumento de aproximadamente 0.595267M USD. La nueva reserve es

$$10.417176 - 8.75 = \mathbf{1.667176M} \text{ USD},$$

un aumento de aproximadamente 0.095267M USD.

- **Bornhuetter-Ferguson:** como el priori y la proporción pendiente no cambian, la reserve permanece en

$$\mathbf{1.655120M} \text{ USD}.$$

El ultimate absorbe el aumento observado:

$$8.75 + 1.655120 = \mathbf{10.405120M} \text{ USD}.$$

La intuición de que “más pérdida observada siempre reduce la reserve” solo se cumple aquí para ELR. En CL, la nueva observación eleva la escala que se desarrolla; en BF, el cambio observado modifica el ultimate, pero no la reserve mientras el priori y el patrón permanezcan fijos.

Experimento 2: shock en el priori esperado

Ahora las pérdidas observadas vuelven a 8.25M USD y el priori de pérdida última de AY 2025 aumenta **5 %**, desde 10.341844M hasta 10.858936M USD. El incremento es:

$$10.858936 - 10.341844 = \mathbf{0.517092M \text{ USD.}}$$

Antes de calcular, anticipe qué método debería absorber todo el cambio, cuál debería ignorarlo y cuál debería absorber únicamente una fracción.

- **ELR:** ultimate y reserve aumentan en el 100 % del shock. La nueva reserve es

$$10.858936 - 8.25 = \mathbf{2.608936M \text{ USD.}}$$

- **Chain-Ladder:** no cambia, porque ni la diagonal ni los factores de desarrollo cambian:

$$U_{2025}^{CL} = \mathbf{9.821909M \text{ USD}}, \quad R_{2025}^{CL} = \mathbf{1.571909M \text{ USD.}}$$

- **Bornhuetter-Ferguson:** solo la porción pendiente del 16.00411 % absorbe el cambio del priori:

$$0.517092(0.1600411) = \mathbf{0.082756M \text{ USD.}}$$

La nueva reserve es aproximadamente

$$\mathbf{1.737876M \text{ USD,}}$$

y el nuevo ultimate es aproximadamente

$$\mathbf{9.987876M \text{ USD.}}$$

La comparación puede resumirse así:

Reacción ante shock (millones de USD)	ELR	Chain-Ladder	BF
Línea base AY 2025 ultimate	10.342	9.822	9.905
Shock incurrido +0.50M: ultimate	10.342	10.417	10.405
Shock incurrido +0.50M: reserve	1.592	1.667	1.655
Shock prior +5 %: ultimate	10.859	9.822	9.988
Shock prior +5 %: reserve	2.609	1.572	1.738

El método correcto no puede elegirse después de mirar el ultimate

Desafío al lector 8. La verdad sintética del autor para AY 2024 es 9.360M USD. ¿Puede Mateo utilizar esa cifra en la fecha de valoración del 31 de diciembre de 2025 para seleccionar factores, modificar el priori o escoger el método que “mejor” reserve?

No. Esa cifra es una **retrospectiva pedagógica no disponible al 31/12/2025**. Solo después de cerrar la decisión ex ante puede utilizarse para estudiar qué ocurrió.

Chain-Ladder, que no depende de la incidencia de prima de AY 2024, había estimado:

$$U_{2024}^{CL} = 9.396754M \text{ USD.}$$

Frente a la verdad sintética:

$$9.396754 - 9.360 = 0.036754M \text{ USD.}$$

Esa proximidad retrospectiva no demuestra que Chain-Ladder fuera universalmente superior. Una realización histórica puede favorecer o perjudicar un método por razones que solo se conocen después. La pregunta correcta sigue siendo qué información estaba disponible el 31 de diciembre de 2025 y qué supuestos eran defendibles entonces.

La comparación retrospectiva numérica de ELR y BF para AY 2024 permanece deliberadamente suspendida hasta resolver la base canónica de su prima ganada. No se utiliza la rama

legacy para declarar un ganador.

La lección central no es que un método “acierta” y otro “falle”, sino que cada uno responde de forma distinta porque utiliza información distinta: ELR se apoya en el priori, Chain-Ladder en la experiencia de desarrollo observada y BF conserva lo observado mientras aplica el priori únicamente a la fracción pendiente.

Ejercicios

Ejercicio 1 - Cálculo y derivación de Chain-Ladder sobre un portafolio de transportes

Un actuario analiza la siniestralidad acumulada reportada de un segmento independiente de transporte de mercancías. La base de datos, valorada al 31 de diciembre de 2025, registra el siguiente triángulo de pérdidas brutas acumuladas incurridas, expresadas en millones de USD:

$$\mathbf{C} = \begin{pmatrix} 4.00 & 4.80 & 5.00 \\ 4.20 & 5.04 & - \\ 4.50 & - & - \end{pmatrix}.$$

Se asume que el desarrollo está completamente terminado a 36 meses, por lo que $F_{36} = 1$.

1. Calcule los factores volumen-ponderados f_{12-24} y f_{24-36} , mostrando numeradores y denominadores.
2. Construya los factores acumulados F_{24} y F_{12} .
3. Calcule el porcentaje desarrollado $p_j = 1/F_j$ para 12, 24 y 36 meses.
4. Estime los ultimates U_i^{CL} de AY 2023, AY 2024 y AY 2025.
5. Calcule las reservas R_i^{CL} de cada año.
6. Determine la reserve total del portafolio.

7. Identifique al menos dos supuestos cuya ruptura podría hacer que el patrón histórico dejara de ser representativo.

Criterio de éxito para la solución:

- Factores age-to-age:

$$f_{12-24} = \frac{4.80 + 5.04}{4.00 + 4.20} = \frac{9.84}{8.20} = \mathbf{1.20000},$$

$$f_{24-36} = \frac{5.00}{4.80} = \mathbf{1.04167}.$$

- Factores acumulados:

$$F_{24} = \mathbf{1.04167}, \quad F_{12} = 1.04166667(1.20) = \mathbf{1.25000}.$$

- Porcentajes desarrollados:

$$p_{12} = \frac{1}{1.25} = \mathbf{80.00\%}, \quad p_{24} = \frac{1}{1.04166667} = \mathbf{96.00\%}, \quad p_{36} = \mathbf{100.00\%}.$$

- Ultimates:

$$U_{2023}^{CL} = \mathbf{5.00M\ USD},$$

$$U_{2024}^{CL} = 5.04(1.04166667) = \mathbf{5.25M\ USD},$$

$$U_{2025}^{CL} = 4.50(1.25) = \mathbf{5.625M\ USD}.$$

- Reserves:

$$R_{2023}^{CL} = 0, \quad R_{2024}^{CL} = \mathbf{0.21M \text{ USD}}, \quad R_{2025}^{CL} = \mathbf{1.125M \text{ USD}},$$

y

$$R_{\text{total}}^{CL} = 0 + 0.21 + 1.125 = \mathbf{1.335M \text{ USD}}.$$

- Entre los supuestos relevantes están la estabilidad de reporting/claims handling, la consistencia de la base del triángulo y la representatividad del historial de desarrollo. Un retraso operativo en 2025 podría reducir artificialmente el acumulado observado y producir una proyección demasiado baja si se aplicara el factor de forma mecánica.

Ejercicio 2 - ELR frente a Bornhuetter-Ferguson

Para el mismo portafolio de transportes, suponga primas ganadas de $\Pi_{2024} = 6.40M \text{ USD}$ y $\Pi_{2025} = 6.80M \text{ USD}$, con un ELR esperado de **80 %**. Las pérdidas acumuladas actuales son $5.04M \text{ USD}$ para AY 2024 y $4.50M \text{ USD}$ para AY 2025. Utilice $F_{24} = 1.04166667$ y $F_{12} = 1.25$.

1. Calcule el ultimate ELR de cada año.
2. Calcule la reserve ELR de cada año.
3. Calcule el porcentaje pendiente y la expected unreported loss de BF.
4. Calcule el ultimate BF de cada año.
5. Explique por qué BF no es el promedio entre ELR y Chain-Ladder.

Criterio de éxito para la solución:

- Ultimates ELR:

$$U_{2024}^{ELR} = 6.40(0.80) = \mathbf{5.12M} \text{ USD},$$

$$U_{2025}^{ELR} = 6.80(0.80) = \mathbf{5.44M} \text{ USD}.$$

- Reserves ELR:

$$R_{2024}^{ELR} = 5.12 - 5.04 = \mathbf{0.08M} \text{ USD},$$

$$R_{2025}^{ELR} = 5.44 - 4.50 = \mathbf{0.94M} \text{ USD}.$$

- Porciones pendientes:

$$1 - p_{24} = \mathbf{4.00\%}, \quad 1 - p_{12} = \mathbf{20.00\%}.$$

- Expected unreported BF:

$$R_{2024}^{BF} = 5.12(0.04) = \mathbf{0.2048M} \text{ USD},$$

$$R_{2025}^{BF} = 5.44(0.20) = \mathbf{1.088M} \text{ USD}.$$

- Ultimates BF:

$$U_{2024}^{BF} = 5.04 + 0.2048 = \mathbf{5.2448M} \text{ USD},$$

$$U_{2025}^{BF} = 4.50 + 1.088 = \mathbf{5.588M} \text{ USD}.$$

- BF no promedia dos ultimates: acepta la pérdida acumulada observada y aplica el priori solamente a la porción que el patrón identifica como todavía no desarrollada.

Ejercicio 3 - La información cambia

Considere AY 2025 del mismo segmento, con línea base $C_{2025} = 4.50M$ USD, $U_{2025}^{prior} = 5.44M$ USD y $F_{12} = 1.25$. Antes de hacer cada cálculo, anticipe si la reserve de ELR, Chain-Ladder y BF debería subir, bajar o permanecer sin cambio.

1. **Shock A - pérdidas incurridas:** las pérdidas acumuladas aumentan en $0.30M$ USD, de $4.50M$ a $4.80M$ USD, manteniendo fijos el priori y F_{12} . Calcule el nuevo ultimate y la nueva reserve bajo ELR, Chain-Ladder y BF.
2. **Shock B - priori:** las pérdidas observadas vuelven a $4.50M$ USD y el priori aumenta 10% , de $5.44M$ a $5.984M$ USD, manteniendo fijo F_{12} . Calcule el nuevo ultimate y la nueva reserve bajo los tres métodos.
3. Compare sus predicciones previas con los resultados y explique qué fuente de información hizo reaccionar a cada método.

Criterio de éxito para la solución:

- **Shock A:**

- ELR:

$$U^{ELR} = 5.44M \text{ USD}, \quad R^{ELR} = 5.44 - 4.80 = 0.64M \text{ USD}.$$

- Chain-Ladder:

$$U^{CL} = 4.80(1.25) = 6.00M \text{ USD},$$

$$R^{CL} = 4.80(0.25) = 1.20M \text{ USD}.$$

- BF:

$$R^{BF} = 5.44(0.20) = \mathbf{1.088M} \text{ USD},$$

$$U^{BF} = 4.80 + 1.088 = \mathbf{5.888M} \text{ USD}.$$

▪ **Shock B:**

- ELR:

$$U^{ELR} = \mathbf{5.984M} \text{ USD}, \quad R^{ELR} = 5.984 - 4.50 = \mathbf{1.484M} \text{ USD}.$$

- Chain-Ladder:

$$U^{CL} = \mathbf{5.625M} \text{ USD}, \quad R^{CL} = \mathbf{1.125M} \text{ USD}.$$

- BF:

$$R^{BF} = 5.984(0.20) = \mathbf{1.1968M} \text{ USD},$$

$$U^{BF} = 4.50 + 1.1968 = \mathbf{5.6968M} \text{ USD}.$$

El primer shock reduce la reserve ELR, eleva la reserve CL y deja fija la reserve BF. El segundo eleva por completo ELR, no afecta CL y modifica BF únicamente en la proporción pendiente del 20%.

Cierre y puente final

Regresemos al dato que abrió la sección. Al 31 de diciembre de 2025, AY 2025 tiene:

$$C_{2025,12} = \mathbf{8.25M} \text{ USD}.$$

Sin embargo, los tres métodos producen reservas distintas:

$$R_{2025}^{ELR} = 2.091844\text{M USD} \approx 2.092\text{M USD},$$

$$R_{2025}^{CL} = 1.571909\text{M USD} \approx 1.572\text{M USD},$$

$$R_{2025}^{BF} = 1.655120\text{M USD} \approx 1.655\text{M USD}.$$

No son tres respuestas aleatorias. ELR cree principalmente el priori de pérdida última; Chain-Ladder cree el patrón de desarrollo que emerge del triángulo; Bornhuetter-Ferguson conserva lo observado y utiliza el priori únicamente para la porción que todavía no se ha desarrollado. La diferencia entre reservas revela una diferencia sobre qué información consideramos más confiable, no únicamente una diferencia de fórmula.

Antes de aceptar una reserve, el actuario debería poder responder: ¿qué loss basis utiliza?, ¿cuál es la fecha de valoración?, ¿qué parte de la pérdida ya está observada?, ¿qué development assumption sostiene la proyección?, ¿qué prior interviene?, y ¿qué nueva información haría cambiar el resultado?

Una última distinción temporal prepara la siguiente sección. **Development** responde cuánto de la pérdida de un mismo Accident Year todavía no ha emergido; **trend** responde cómo cambia el nivel esperado de costo entre fechas económicas distintas. No son la misma transformación. Reserving ha mirado hacia atrás, hacia eventos que ya ocurrieron pero todavía no terminaron de desarrollarse. Ratemaking mirará hacia adelante, hacia un periodo futuro cuyo costo todavía no ocurrió.

Incluso después de estimar correctamente las pérdidas últimas históricas, esos importes no son automáticamente comparables con una tarifa futura. Antes de pricing habrá que preguntar si las pérdidas están en un cost level comparable y si las primas históricas están en una base tarifaria comparable, sin confundir esos ajustes con el development que acabamos de estudiar.

Esa necesidad abre directamente la **Section 5.2 - Data Preparation for Ratemaking**.

Section 5.2 - Data Preparation for Ratemaking

El mismo riesgo mira hacia atrás y hacia adelante

5.2.1 El ratio de siniestralidad crudo es una ilusión temporal y operativa

En el análisis de suficiencia tarifaria, el actuario busca determinar si las primas que se recaudarán en el futuro serán suficientes para financiar las pérdidas esperadas, los gastos operativos y la provisión de ganancia y contingencias de la compañía. Para iniciar este proceso en **Meridiano Seguros**, la actuaria de Pricing, **Lucía**, decide evaluar la experiencia del Accident Year 2025.

Al revisar los registros de la compañía al **31 de diciembre de 2025**, Lucía observa que el subportafolio de seguros comerciales de daños registra pérdidas acumuladas incurridas por un importe de **8.25 millones de USD**. Por su parte, la prima ganada contable acumulada durante ese mismo periodo asciende a **13.789125 millones de USD**. Al realizar una división directa entre ambas cifras contables, Lucía obtiene un ratio de siniestralidad bruto (*raw loss ratio*) de:

$$\text{Raw Loss Ratio}_{2025} = \frac{8.25 \text{ millones de USD}}{13.789125 \text{ millones de USD}} \approx 59.83 \%$$

Satisfecha con este resultado preliminar, Lucía comenta a la actuaria jefa, **Irene**: «*Una siniestralidad de 59.83 % parece, a primera vista, dejar un margen cómodo para competir en el mercado el próximo año*».

Irene, sin embargo, frena el entusiasmo con una advertencia de comparabilidad fundamental: «*Tu cálculo del 59.83 % es aritméticamente impecable, Lucía, pero todavía no es una base defendible para tomar decisiones de precios hacia el futuro. Ese número mezcla tres mundos*

*económicos incompatibles en el tiempo. Las pérdidas de 8.25 millones de USD corresponden a un año de accidentes inmaduro, valorado a apenas 12 meses de desarrollo. Las primas de 13.789125 millones de USD se ganaron bajo una tarifa promedio que ya no es la que cobramos hoy. Y la tarifa que pretendemos diseñar entrará en vigor el **1 de enero de 2027**, para una exposición cuya fecha media de pérdidas se situará a mediados de ese año. En este caso, decidir directamente con el ratio crudo sesgaría la lectura del costo que queremos financiar».*

Este intercambio ilustra el dilema central de la preparación de datos para tarifas (*ratemaking*): **el mismo riesgo que Reserving analiza hacia atrás para cuantificar obligaciones pendientes, Pricing debe proyectarlo hacia adelante para estimar el costo de la exposición futura.** Para que los datos históricos sirvan como una base defendible para el futuro, el actuario debe corregir incompatibilidades distintas mediante **desarrollo, tendencia y puesta a nivel de primas.**

El caso trabajado mantiene una **base gross del asegurador**. Las pérdidas utilizadas son pérdidas acumuladas incurridas gross y el costo de pérdida prospectivo se interpreta también sobre base gross. No se construye aquí una base neta de reaseguro porque no existe en el canon suministrado una serie congelada y reconciliada de primas cedidas y recuperaciones para este ejercicio. Asimismo, se mantiene la misma base contractual del producto; no se introduce un cambio de cobertura entre la experiencia histórica y el periodo prospectivo.

El mapa mínimo de datos deja visible qué representa cada cantidad antes de combinarla:

Cantidad	Fecha o periodo	Development /		
		cost-rate basis	Units	Naturaleza
$C_{2025,12} = 8.25$	AY 2025; valoración 31/12/2025	Incurrida acumulada a 12 meses; nivel histórico 2025	millones de USD	Observada, gross
$\Pi_{2025} =$ 13.789125	AY 2025; valoración 31/12/2025	Prima ganada bajo tarifa promedio 2025	millones de USD	Observada

Cantidad	Fecha o periodo	Development /	Units	Naturaleza
		cost-rate basis		
$U_{2025} = 9.821909$	AY 2025; valoración 31/12/2025	Estimada a último, 60 meses	millones de USD	Derivada del modelo de desarrollo, gross
$LC_{\text{base}} = 780$	Base económica seleccionada 1/7/2025	Costo último seleccionado al nivel económico de esa fecha	USD por exposición	Input canónico seleccionado, gross
$LC_{\text{projected}} = 894.02$	Fecha media prospectiva 1/7/2027	Nivel de costo prospectivo	USD por exposición	Derivada por tendencia, gross
$r_{\text{current}} = 1,124.76$	31/12/2025	Nivel tarifario vigente	USD por exposición	Tarifa actual
$FE = 60$	Periodo prospectivo	Gasto fijo	USD por exposición	Input seleccionado
$v = 18\%$, $q = 5\%$	Periodo prospectivo	Proporciones de prima	porcentaje de prima	Inputs seleccionados

Este mapa también muestra por qué **no todos los datos se ajustan de la misma manera**:

Ajuste	Cantidad transformada	Pregunta que resuelve
Development	Historical losses	¿Cuánto de la pérdida histórica todavía no ha emergido?
Trend	Loss cost	¿Cómo cambia el nivel esperado de costo entre dos fechas económicas?

Ajuste	Cantidad transformada	Pregunta que resuelve
Premium on-leveling	Historical earned premium	¿Qué prima habría generado esa exposición al nivel tarifario actual?

La selección de experiencia también exige juicio temporal. Los años recientes suelen ser más relevantes para el entorno económico actual, pero pueden estar más inmaduros; los años antiguos suelen estar más desarrollados, pero requieren más trend y más ajuste de rate level. Una serie larga no es automáticamente superior si mezcla bases incompatibles.

5.2.2 El ajuste por desarrollo traduce la inmadurez de la diagonal en escala última

El primer desajuste que debe corregirse en el numerador del ratio de siniestralidad es la inmadurez de las pérdidas históricas. Como se analizó en Section 5.1, los siniestros ocurridos durante un año de accidentes tardan meses o años en reportarse, liquidarse y registrarse por completo. Utilizar la siniestralidad observada en la última diagonal del triángulo de pérdidas -8.25 millones de USD para Accident Year 2025- ignoraría la parte del costo que todavía no ha emergido en la experiencia observada.

Para neutralizar ese problema, Lucía reutiliza el factor acumulado de desarrollo de Chain-Ladder ya seleccionado en Reserving. Para AY 2025, el factor acumulado de 12 a 60 meses es:

$$F_{12 \rightarrow 60} = 1.19053445.$$

El factor no cambia el nivel económico de los siniestros. Responde únicamente a una pregunta de **madurez**: dado lo observado a 12 meses, ¿qué ultimate implica el patrón de desarrollo seleccionado?

Aplicándolo al importe acumulado observado:

$$U_{2025} = C_{2025,12}F_{12 \rightarrow 60} = 8.25 \times 1.19053445 = 9.821909 \text{ millones de USD.}$$

La diferencia:

$$9.821909 - 8.25 = 1.571909 \text{ millones de USD}$$

es la parte adicional que el método de desarrollo estima que todavía falta por emerger hasta la edad terminal de 60 meses del caso canónico.

Si Lucía recalcula el ratio de 2025 corrigiendo únicamente la inmadurez del numerador, obtiene:

$$\text{Loss Ratio Desarrollado}_{2025} = \frac{9.821909}{13.789125} \approx 71.23 \%.$$

El 71.23 % no es una nueva observación ni una “siniestralidad real” conocida. Es un **ratio derivado del modelo**, construido con pérdidas últimas estimadas en el numerador y prima ganada histórica todavía no puesta a nivel en el denominador. Por eso sigue siendo insuficiente para una decisión prospectiva.

5.2.3 La tendencia de costo proyecta la severidad y frecuencia hacia el futuro económico

Una vez que las pérdidas históricas se expresan en una base de madurez adecuada, aparece un problema distinto: su **nivel económico** puede pertenecer al pasado. El desarrollo mueve una pérdida desde una edad de desarrollo hacia ultimate; la tendencia mueve un costo desde una fecha económica hacia otra.

Para el caso canónico, Meridiano selecciona una tendencia anual de severidad de:

$$t_s = 6 \%,$$

mientras que la tendencia anual de frecuencia es:

$$t_f = 1\%.$$

La combinación es multiplicativa porque el costo de pérdida esperado por exposición refleja simultáneamente frecuencia y severidad. Si cada componente cambia mediante su propio factor anual, el factor de cambio del producto es:

$$1 + t_{\text{combined}} = (1 + t_s)(1 + t_f) = 1.06(1.01) = 1.0706.$$

Por tanto:

$$t_{\text{combined}} = 1.0706 - 1 = 0.0706 = 7.06\% \text{ anual.}$$

La tendencia combinada no es exactamente $6\% + 1\% = 7\%$. El producto conserva el término cruzado:

$$0.06(0.01) = 0.0006 = 0.06\%.$$

Para el prospective ratemaking case, la nueva tarifa será efectiva el **1 de enero de 2027** y cubrirá un periodo de un año. Bajo el supuesto canónico de exposición uniforme, la fecha media prospectiva de pérdidas es el **1 de julio de 2027**.

El canon utiliza:

$$LC_{\text{base}} = 780 \text{ USD por exposición}$$

como **selected base loss cost ya expresado en una base económica cuya fecha media canónica es el 1 de julio de 2025**. En esta sección no se deriva ese 780 de la verdad sintética de AY 2024 ni se lo describe como un raw AY2024 loss cost. Esa separación

evita utilizar retrospectivamente un ultimate que no estaba disponible al 31 de diciembre de 2025 y evita mezclar una fecha media de 2024 con un periodo de tendencia de solo dos años.

La distancia entre el **1 de julio de 2025** y el **1 de julio de 2027** es:

$$n = 2 \text{ años.}$$

Por tanto, el factor acumulado de tendencia es:

$$(1.0706)^2 = 1.14618436.$$

Y el costo de pérdida prospectivo resulta:

$$LC_{\text{projected}} = LC_{\text{base}}(1.0706)^2 = 780(1.14618436) = 894.0238008 \approx 894.02 \text{ USD por exposición.}$$

Este resultado es una cantidad **model-derived**: depende del costo base seleccionado, de las fechas de origen y destino, y de los supuestos de tendencia. No es una observación histórica.

Sensibilidad - un punto adicional de tendencia de severidad cambia la base prospectiva

Para aislar el efecto de un solo supuesto, supongamos que la tendencia de severidad sube de 6 % a 7 %, mientras la tendencia de frecuencia permanece en 1 % y el periodo sigue siendo de dos años. El nuevo factor anual combinado es:

$$1.07(1.01) = 1.0807,$$

es decir, una tendencia combinada de:

$$8.07 \% \text{ anual.}$$

El nuevo factor de dos años es:

$$(1.0807)^2 = 1.16791249,$$

y el costo prospectivo pasa a:

$$780(1.16791249) = 910.9717422 \approx 910.97 \text{ USD por exposición.}$$

Manteniendo todo lo demás constante, una selección mayor de tendencia de severidad eleva el costo prospectivo de 894.02 a 910.97 USD por exposición. La sensitivity no cambia la observación histórica; cambia la cantidad prospectiva producida por el modelo.

5.2.4 La premium on-leveling reconstruye los ingresos bajo la estructura tarifaria actual

El tercer problema de comparabilidad aparece en el denominador. Si las tarifas cambiaron durante la historia, la prima ganada contable no es una medida neutral de exposición: dos periodos con la misma exposición pueden producir primas distintas únicamente porque se cobraron bajo rate levels diferentes.

El historial de cambios tarifarios de Meridiano parte de una tarifa de:

$$1,000 \text{ USD por exposición.}$$

Los cambios canónicos son:

- **1 de enero de 2023:** +3 %, llevando la tarifa a 1,030.00 USD por exposición.
- **1 de julio de 2024:** +5 %, llevando la tarifa a 1,081.50 USD por exposición.
- **1 de julio de 2025:** +4 %, llevando la tarifa a 1,124.76 USD por exposición.

La tarifa vigente al **31 de diciembre de 2025** es, por tanto:

$$r_{\text{current}} = 1,000(1.03)(1.05)(1.04) = 1,124.76 \text{ USD por exposición.}$$

Los cambios no se suman como $3\% + 5\% + 4\% = 12\%$; cada cambio se aplica al nivel tarifario que existe en ese momento.

Bajo el supuesto de ganancia uniforme dentro de cada año, un cambio efectivo a mitad de año produce una tarifa promedio ganada igual al promedio de los niveles anterior y posterior. Así:

		Factor on-level
AY	Tarifa promedio ganada $\bar{r}_i$	$OLF_i = r_{\text{current}}/\bar{r}_i$
2021	1,000.00 USD	1.12476
2022	1,000.00 USD	1.12476
2023	1,030.00 USD	1.09200
2024	1,055.75 USD	1.06536585
2025	1,103.13 USD	1.01960784

El factor on-level se define como:

$$OLF_i = \frac{r_{\text{current}}}{\bar{r}_i}.$$

Y la prima puesta al nivel actual es:

$$\Pi_i^{OL} = \Pi_i^{\text{earned}} OLF_i.$$

Para los años cuya base de exposición y prima está reconciliada en el canon disponible:

$$\Pi_{2021}^{OL} = 11.500(1.12476) = 12.934740 \text{ millones de USD,}$$

$$\Pi_{2022}^{OL} = 11.900(1.12476) = 13.384644 \text{ millones de USD},$$

$$\Pi_{2023}^{OL} = 12.360(1.09200) = 13.497120 \text{ millones de USD}.$$

Para AY 2024, la Biblia Numérica v1.0 mantiene una incidencia no resuelta: el core portfolio usa 12,000 policy-years, mientras la tabla histórica de Reserving/Ratemaking usa 12,500 exposures. El **rate level promedio de 1,055.75 USD y el $OLF_{2024} = 1.06536585$ no dependen de esa discrepancia**, pero el earned premium 2024, el on-level premium 2024 y cualquier loss ratio o experiencia multi-year que los utilice sí dependen de la rama elegida. Por tanto, **AY 2024 queda excluido de esos cálculos en esta sección y no se adopta silenciosamente ninguna base de exposición.**

El caso principal continúa con AY 2025, cuya base histórica está reconciliada en la tabla de Part 5. La tarifa promedio ganada es:

$$\bar{r}_{2025} = \frac{1,081.50 + 1,124.76}{2} = 1,103.13 \text{ USD por exposición.}$$

Por tanto:

$$OLF_{2025} = \frac{1,124.76}{1,103.13} = 1.01960784.$$

Y la prima puesta a nivel actual es:

$$\Pi_{2025}^{OL} = 13.789125(1.01960784) = 14.059500 \text{ millones de USD}.$$

La comprobación inmediata es:

$$12,500 \text{ exposures} \times 1,124.76 \text{ USD por exposure} = 14,059,500 \text{ USD}.$$

Así, la prima puesta a nivel equivale exactamente a lo que esa exposición habría generado al current rate level del 31 de diciembre de 2025.

El cambio de +4 % efectivo el 1 de julio de 2025 **no** implica un on-level factor de 1.04 para todo el año. La mitad de la exposición de 2025 se ganó antes del cambio y la otra mitad después bajo el supuesto uniforme; por eso el denominator correcto del factor es la tarifa promedio ganada de 1,103.13 USD, no la tarifa anterior de 1,081.50 USD.

Una vez desarrollado el numerador y puesto a nivel el denominador, puede construirse un ratio más comparable para AY 2025:

$$\text{Loss Ratio Desarrollado y Puesto a Nivel}_{2025} = \frac{U_{2025}}{\Pi_{2025}^{OL}} = \frac{9.821909}{14.059500} \approx 69.86 \%.$$

El 69.86 % es un **ratio ajustado**, no una “verdadera siniestralidad” observada. Su numerador es una pérdida última estimada mediante desarrollo y su denominador es una prima histórica reconstruida al current rate level. Bajo esas bases declaradas, muestra que la lectura de AY 2025 cambia materialmente frente al raw 59.83 %.

5.2.5 La estructura de gastos fijos y variables prohíbe el recargo porcentual simple

Una vez preparados los componentes de pérdidas y primas, el actuario debe clasificar los gastos según su comportamiento financiero. En el caso canónico de Meridiano:

1. **Gastos fijos (*Fixed Expenses, FE*):** 60 USD por exposición. Se comportan como una cantidad aditiva por unidad de exposición.
2. **Gastos variables (*Variable Expenses, v*):** 18 % de la prima final. Se comportan como una proporción de premium.
3. **Provisión de ganancia y contingencias (*q*):** 5 % de la prima final. Es una provisión seleccionada para el ejercicio, no una ganancia histórica observada.

La fracción de cada dólar de prima que queda disponible para financiar pérdidas y gastos fijos es:

$$1 - v - q = 1 - 0.18 - 0.05 = 0.77.$$

Es decir:

77 % de la prima final

queda disponible para pérdidas y gastos fijos bajo la estructura canónica.

La intuición que falla - El recargo porcentual simple subfinancia la operación

Supongamos que un analista suma el costo prospectivo de pérdidas y el gasto fijo:

$$894.02 + 60 = 954.02 \text{ USD por exposición.}$$

Luego aplica erróneamente un recargo directo del 23 %:

$$\text{Tarifa Errónea} = 954.02(1.23) = 1,173.4446 \approx 1,173.44 \text{ USD por exposición.}$$

El procedimiento falla porque el 18 % de gastos variables y el 5 % de provisión de ganancia y contingencias se calculan como proporciones de la **prima final**, no como proporciones del loss cost.

Si se cobrara la cantidad errónea sin redondeo intermedio, el importe disponible después de esas dos deducciones sería:

$$1,173.4446(0.77) = 903.552342 \approx 903.55 \text{ USD por exposición.}$$

Pero la necesidad de pérdidas más gasto fijo sigue siendo:

$$954.02 \text{ USD por exposición.}$$

El déficit resultante sería:

$$903.552342 - 954.02 = -50.467658 \approx -50.47 \text{ USD por exposición.}$$

La lección algebraica es que v y q reducen la fracción de la prima disponible para pérdidas y gastos fijos. No son un “23 % que se añade” al numerador. La forma exacta de convertir estas cantidades preparadas en una indicated rate pertenece a la siguiente sección.

Cierre y Puente Final

Al concluir la preparación de datos, Lucía dispone de los inputs canónicos que sí pueden llevarse hacia la decisión prospectiva sin mezclar silenciosamente bases incompatibles:

- costo de pérdida prospectivo gross:

$$LC_{\text{projected}} = 894.02 \text{ USD por exposición;}$$

- gasto fijo:

$$FE = 60 \text{ USD por exposición;}$$

- gastos variables:

$$v = 18 \%;$$

- provisión de ganancia y contingencias:

$$q = 5\%;$$

- fracción disponible para pérdidas y gastos fijos:

$$1 - v - q = 0.77;$$

- tarifa vigente al 31 de diciembre de 2025:

$$r_{\text{current}} = 1,124.76 \text{ USD por exposición.}$$

Las pérdidas históricas inmaduras han sido llevadas a una escala última estimada; el costo base seleccionado ha sido proyectado desde el 1 de julio de 2025 hasta el 1 de julio de 2027; y la prima 2025 ha sido reconstruida al current rate level. La incidencia de exposure/premium de AY 2024 permanece explícitamente fuera de cualquier cálculo que dependa de escoger una de sus dos bases.

La decisión de tarificación todavía no está resuelta: **¿qué rate convierte 894.02 USD de pérdidas esperadas por exposición, 60 USD de gasto fijo y las provisiones porcentuales de 18% y 5% en una tarifa suficiente, y qué cambio representa respecto de los 1,124.76 USD que Meridiano cobra actualmente?** Esa pregunta abre directamente la **Section 5.3 - Ratemaking: Loss Cost and Loss Ratio Methods**.

Ejercicios

Ejercicio 1 - Ajuste por desarrollo y tendencia compuesta de pérdidas

Un actuario de Meridiano Seguros prepara los datos históricos de Accident Year 2025 para una revisión de tarifas. A la fecha de valoración del **31 de diciembre de 2025**, registra

pérdidas acumuladas incurridas de 8.25 millones de USD a 12 meses. El factor acumulado de desarrollo de 12 a 60 meses es:

$$F_{12 \rightarrow 60} = 1.19053445.$$

La tendencia anual de severidad es 6.0 % y la tendencia anual de frecuencia es 1.0 %. La fecha media histórica de pérdidas es el **1 de julio de 2025** y la fecha media prospectiva es el **1 de julio de 2027**.

1. Calcule el ultimate estimado U_{2025} aplicando el ajuste de desarrollo.
2. Calcule la tendencia anual combinada del costo de pérdida y explique por qué no es exactamente 7 %.
3. Calcule el periodo de tendencia entre las dos fechas medias y el factor acumulado correspondiente.
4. Proyecte U_{2025} al nivel económico del 1 de julio de 2027.
5. Explique por qué development y trend no son intercambiables y etiquete cada cantidad por fecha, madurez y units.

Criterio de éxito para la solución:

$$U_{2025} = 8.25(1.19053445) = 9.821909 \text{ millones de USD},$$

$$1.06(1.01) - 1 = 0.0706 = 7.06 \% \text{ anual},$$

$$n = 2 \text{ años},$$

$$(1.0706)^2 = 1.14618436,$$

$$8.25(1.19053445)(1.14618436) = 11.2577187247 \text{ millones de USD} \approx 11.257719 \text{ millones de USD.}$$

La primera transformación cambia la **madurez** de la pérdida; la segunda cambia su **nivel económico** entre fechas declaradas.

Ejercicio 2 - Reconstrucción de primas e ingresos homogeneizados al nivel actual

Para Accident Year 2025, Meridiano registra 12, 500 **exposures** y una prima ganada contable de 13.789125 **millones de USD**. La tarifa base era 1, 000 USD por exposición y se aplicaron los siguientes cambios: +3 % el 1 de enero de 2023, +5 % el 1 de julio de 2024 y +4 % el 1 de julio de 2025. Se asume ganancia uniforme dentro de cada año.

1. Calcule el current rate level al 31 de diciembre de 2025.
2. Calcule la tarifa promedio ganada de 2025.
3. Calcule OLF_{2025} .
4. Calcule Π_{2025}^{OL} .
5. Reconcilie Π_{2025}^{OL} con exposure multiplicada por current rate.
6. Explique por qué un cambio de +4 % efectivo a mitad de 2025 no implica un $OLF_{2025} = 1.04$ para todo el año.

Criterio de éxito para la solución:

$$r_{\text{current}} = 1,000(1.03)(1.05)(1.04) = 1,124.76 \text{ USD por exposición,}$$

$$\bar{r}_{2025} = \frac{1,081.50 + 1,124.76}{2} = 1,103.13 \text{ USD por exposición,}$$

$$OLF_{2025} = \frac{1,124.76}{1,103.13} = 1.01960784,$$

$$\Pi_{2025}^{OL} = 13.789125(1.01960784) = 14.059500 \text{ millones de USD},$$

$$12,500(1,124.76) = 14,059,500 \text{ USD}.$$

El factor no es 1.04 porque la historical earned premium de 2025 ya incorpora parcialmente el cambio efectivo el 1 de julio.

Ejercicio 3 - Clasificación de gastos y base final

El departamento de Pricing dispone de los siguientes inputs preparados para el periodo prospectivo:

$$LC_{\text{projected}} = 894.02 \text{ USD por exposición},$$

$$FE = 60 \text{ USD por exposición},$$

$$v = 18 \%,$$

$$q = 5 \%.$$

1. Clasifique las units y el comportamiento algebraico de cada input.
2. Calcule la fracción de la prima disponible para pérdidas y gastos fijos.
3. Identifique qué cantidades deberán entrar como dollars por exposición y cuáles como proporciones de la prima en la siguiente sección.

4. Explique por qué aplicar directamente un recargo de 23 % sobre $LC_{\text{projected}} + FE$ no financia correctamente una estructura donde v y q son porcentajes de la prima final.

Criterio de éxito para la solución:

$$1 - v - q = 1 - 0.18 - 0.05 = 0.77.$$

El costo de pérdidas y el gasto fijo conservan units de USD por exposición; v y q son proporciones adimensionales de la prima final. El lector debe terminar el ejercicio sabiendo qué inputs están preparados para Section 5.3 sin calcular todavía la indicated rate final.

Section 5.3 - Ratemaking: Loss Cost and Loss Ratio Methods

Dos caminos algebraicos hacia el mismo equilibrio financiero

5.3.1 El método de Costo de Siniestralidad calcula el financiamiento directo por exposición

Al cerrar la preparación de datos de la sección anterior, la actuario de Pricing, **Lucía**, recibe un input ya preparado para el periodo prospectivo: un **Costo de Siniestralidad Proyectado** (*Projected Loss Cost, LC*) de 894.0238008 USD por exposición, expresado sobre la **base gross** seleccionada para el caso canónico y al nivel prospectivo cuya fecha media de pérdida es el **1 de julio de 2027**.

La primera pregunta parece sencilla: **si Meridiano Seguros espera 894.02 USD de pérdidas por exposición, ¿basta con cobrar exactamente 894.02 USD por exposición?**

Irene introduce el elemento que falta: **¿y quién financia los gastos?** La tarifa indicada debe sostener, además de las pérdidas prospectivas, los siguientes componentes ya preparados

en la Section 5.2:

- **Gastos Fijos por Exposición (*Fixed Expenses, FE*): 60.00 USD por exposición.**
- **Gastos Variables de Suscripción (*Variable Expenses, v*): 18 % de la prima final ($v = 0.18$).**
- **Provisión de Ganancia y Contingencias (*Profit and Contingencies, q*): 5 % de la prima final ($q = 0.05$).**

A la fecha de valoración del **31 de diciembre de 2025**, la tarifa comercial vigente (R_{current}) es de **1,124.76 USD por exposición**. La pregunta central de esta sección queda entonces definida: **¿qué tarifa promedio indicada financia la estructura prospectiva de pérdidas, gastos y provisión, y qué cambio porcentual representa respecto de la tarifa vigente?**

Para determinar la tarifa técnica indicada (R_{ind}), Lucía recurre en primer lugar al **Método de Costo de Siniestralidad (*Loss Cost Method*)**. Este enfoque adopta una perspectiva absoluta y aditiva por unidad de exposición: construye la tarifa sumando los costos directos esperados en el numerador y reduciendo el denominador por la fracción de prima que consumirán los gastos porcentuales variables y la provisión de ganancia y contingencias.

Formalmente, el balance económico del modelo exige que la tarifa indicada (R) sea suficiente para financiar las pérdidas esperadas, los gastos fijos por exposición, los gastos variables proporcionales a la propia tarifa y la provisión de ganancia y contingencias:

$$R = LC + FE + vR + qR$$

Para aislar la variable de tarifa requerida (R), Lucía desplaza todos los términos dependientes del precio final al miembro izquierdo de la ecuación de balance:

$$R - vR - qR = LC + FE$$

$$R(1 - v - q) = LC + FE$$

La diferencia residual $(1 - v - q)$ representa la **fracción admisible para pérdidas y gastos fijos** (*permissible fraction*), la cual se establece bajo la estructura de Meridiano Seguros en un **77 %** de cada dólar de prima recaudado ($1 - 0.18 - 0.05 = 0.77$). Al despejar la tarifa indicada, se obtiene la formulación clásica del método *Loss Cost*:

$$R_{\text{ind}} = \frac{LC + FE}{1 - v - q}$$

Al sustituir los parámetros canónicos auditados y congelados del portafolio en la ecuación, Lucía calcula de forma exacta la tarifa requerida:

$$R_{\text{ind}} = \frac{894.0238008 \text{ USD} + 60.00 \text{ USD}}{0.77} = \frac{954.0238008 \text{ USD}}{0.77} = \mathbf{1,238.991949 \text{ USD}}$$

Este resultado se redondea de forma operacional a **1,238.99 USD por exposición** para la presentación de la indicación tarifaria.

Para de manera analítica deducir la variación de precios requerida, se calcula el **factor de cambio de tarifa** (I) dividiendo la tarifa indicada entre la tarifa vigente actual ($R_{\text{current}} = 1,124.76 \text{ USD}$):

$$I = \frac{R_{\text{ind}}}{R_{\text{current}}} = \frac{1,238.991949 \text{ USD}}{1,124.76 \text{ USD}} = \mathbf{1.1015611767} \approx \mathbf{1.10156118}$$

Restando la unidad, obtenemos el **cambio porcentual de tarifa indicado** ($\Delta r = I - 1$):

$$\Delta r = 1.1015611767 - 1 = \mathbf{+10.1561177 \%} \approx \mathbf{+10.16 \%}$$

Este resultado significa que, bajo los supuestos prospectivos seleccionados de pérdidas, gastos y provisión, la **indicación promedio** se sitúa **10.16 %** por encima del nivel tarifario vigente.

La indicación no implica que la tarifa final implementada deba coincidir necesariamente con ese porcentaje.

5.3.2 El método de Razón de Siniestralidad traduce la necesidad en ratios de prima actual

Aunque el método *Loss Cost* resulta de enorme claridad intuitiva al trabajar con dólares absolutos por exposición, las compañías de seguros organizan frecuentemente sus revisiones de tarifas utilizando la perspectiva del **Método de Razón de Siniestralidad** (*Loss Ratio Method*). Este enfoque no busca fijar directamente el precio en dólares; en su lugar, evalúa qué porción de la estructura de tarifas actual está siendo consumida por los siniestros proyectados y los gastos fijos, para determinar la suficiencia o insuficiencia porcentual del nivel de precios vigente.

Para aplicar este método, Lucía traduce en primer lugar los costos aditivos del numerador en ratios relativos a la tarifa actual ($R_{\text{current}} = 1,124.76 \text{ USD}$):

1. **Razón de Siniestralidad Proyectada** (*Projected Loss Ratio, LR_{proj}*): Mide el costo esperado de pérdida futura como fracción de la prima técnica que cobramos hoy.

$$LR_{\text{proj}} = \frac{LC}{R_{\text{current}}} = \frac{894.0238008 \text{ USD}}{1,124.76 \text{ USD}} = 79.48573925 \% \approx 79.49 \%$$

2. **Razón de Gastos Fijos** (*Fixed Expense Ratio, FER*): Expresa el costo administrativo por exposición como fracción de la prima que cobramos hoy.

$$FER = \frac{FE}{R_{\text{current}}} = \frac{60.00 \text{ USD}}{1,124.76 \text{ USD}} = 5.33447135 \% \approx 5.33 \%$$

Al sumar ambos ratios, Lucía obtiene el **ratio de costos totales requeridos a tarifa actual** ($79.485739 \% + 5.334471 \% = 84.820211 \%$). Este porcentaje indica que, si mantuviéramos la tarifa actual de 1,124.76 USD sin modificaciones durante el periodo prospectivo,

el 84.82 % de cada dólar recaudado se consumiría exclusivamente en pagar siniestros proyectados y gastos fijos.

Dado que el marco canónico destina el 23 % de la prima a gastos variables (18 %) y a la provisión de ganancia y contingencias (5 %), la fracción de prima disponible para pérdidas y gastos fijos es del 77 %. El factor de indicación tarifaria (I) se calcula de forma directa dividiendo la necesidad de costo agregada entre la fracción admisible permitida:

$$I = \frac{LR_{\text{proj}} + FER}{1 - v - q} = \frac{0.7948573925 + 0.0533447135}{0.77} = \frac{0.8482021060}{0.77} = \mathbf{1.1015611767} \approx \mathbf{1.10156118}$$

Restando la unidad, obtenemos el cambio porcentual indicado:

$$\Delta r = 1.1015611767 - 1 = +\mathbf{10.1561177} \% \approx +\mathbf{10.16} \%$$

Para derivar la tarifa técnica requerida implícita, Lucía simplemente multiplica la tarifa comercial vigente por el factor de indicación obtenido:

$$R_{\text{ind}} = R_{\text{current}} \times I = 1,124.76 \text{ USD} \times 1.1015611767 = \mathbf{1,238.991949 \text{ USD}}$$

El resultado coincide con el obtenido mediante el método *Loss Cost*, como exige la equivalencia algebraica cuando ambos utilizan las mismas bases e inputs.

5.3.3 Dos métodos, un solo balance: la reconciliación algebraica perfecta

La perfecta coincidencia de los resultados anteriores no es una casualidad numérica ni el efecto de un redondeo afortunado de decimales; constituye una **identidad algebraica fundamental** de la ciencia actuarial. Para desvelar este comportamiento de manera transparente, la actuaria jefa, **Irene**, exige realizar una demostración formal de la equivalencia entre ambos métodos.

Partimos de la definición del factor de cambio de tarifa (I) derivado bajo el método de Costo de Siniestralidad:

$$I = \frac{R_{\text{ind}}}{R_{\text{current}}}$$

Sustituyendo la definición analítica de la tarifa indicada (R_{ind}) en el numerador:

$$I = \frac{\frac{LC+FE}{1-v-q}}{R_{\text{current}}}$$

Dado que la división entre la tarifa vigente actual (R_{current}) afecta a todo el numerador, podemos distribuir esa división sobre la suma $LC + FE$:

$$I = \frac{\frac{LC}{R_{\text{current}}} + \frac{FE}{R_{\text{current}}}}{1 - v - q}$$

Al sustituir las definiciones básicas del ratio de siniestralidad proyectada ($LR_{\text{proj}} = LC/R_{\text{current}}$) y del ratio de gastos fijos ($FER = FE/R_{\text{current}}$):

$$I = \frac{LR_{\text{proj}} + FER}{1 - v - q}$$

Esta última expresión es, precisamente, la fórmula del método de Razón de Siniestralidad. Queda demostrado de manera irrefutable que **ambas formulaciones son idénticas y representan exactamente la misma ecuación de balance financiero expresada en dos sistemas de coordenadas cuantitativas distintos**. El método *Loss Cost* trabaja con dólares absolutos por exposición, mientras que el método *Loss Ratio* opera con proporciones relativas respecto del nivel tarifario actual.

Esta equivalencia impone una estricta disciplina de auditoría interna actuarial: **si en la práctica de una aseguradora el método de Costo de Siniestralidad y el método de Razón de Siniestralidad produjeran indicaciones divergentes, esto constituiría una señal de error o desajuste de bases en los datos de entrada**. Las discrepancias suelen surgir cuando se mezclan pérdidas nominales históricas con primas on-level, cuando se

asumen periodos de tendencia asimétricos entre los métodos, cuando se omiten o reclasifican gastos, o cuando se utilizan bases gross y net incompatibles.

5.3.4 La asimetría de las indicaciones se revela ante shocks en el entorno de suscripción

Para consolidar la comprensión estructural de las tarifas, Irene y Lucía someten el modelo de tarificación de Meridiano Seguros a cuatro experimentos dinámicos de sensibilidad, modificando un supuesto técnico a la vez y manteniendo todos los demás elementos estrictamente constantes en sus valores base:

Experimento 1: Shock en la Inflación de Siniestros (Ruptura de Tendencia)

Supongamos que, debido a presiones macroeconómicas en el costo de reparaciones, la tendencia anual de severidad de Meridiano aumenta del 6.0 % al **7.0 % anual**, manteniendo la tendencia de frecuencia en el 1.0 %.

- La tasa combinada anual de costo de pérdida se eleva de 7.06 % a:

$$1.07 \times 1.01 - 1 = 0.0807 \Rightarrow \mathbf{8.07\% \text{ anual}}$$

- El costo de pérdida proyectado para el Accident Year 2027 a los 2 años de tendencia sube a:

$$780 \text{ USD} \times (1.0807)^2 = \mathbf{910.9717422 \text{ USD}}$$

- La nueva tarifa técnica indicada asciende a:

$$R_{\text{ind}} = \frac{910.9717422 + 60.00}{0.77} = \mathbf{1,261.002263 \text{ USD}}$$

- El cambio porcentual requerido pasa de +10.16 % a:

$$\Delta r = \frac{1,261.002263}{1,124.76} - 1 = +\mathbf{12.113007\%} \approx +\mathbf{12.11\%}$$

Lección: Un incremento de solo 100 puntos básicos en la inflación anual de severidad se transmite de forma multiplicativa y compuesta durante el periodo de tendencia de 2 años, amplificando la indicación de cambio tarifario en casi 200 puntos básicos adicionales.

Experimento 2: Shock en Comisiones de Suscripción (Gastos Variables)

Supongamos ahora que, debido a una reestructuración de la red de intermediarios, los gastos variables de Meridiano Seguros se incrementan del 18 % al **20 % de la prima técnica final**.

- La fracción admisible para pérdidas y gastos fijos se contrae del 77 % al:

$$1 - 0.20 - 0.05 = \mathbf{0.75} \quad (\mathbf{75\%})$$

- La nueva tarifa técnica indicada asciende a:

$$R_{\text{ind}} = \frac{894.0238008 + 60.00}{0.75} = \mathbf{1,272.031734 \text{ USD}}$$

- El cambio porcentual requerido se eleva de forma drástica de +10.16 % a:

$$\Delta r = \frac{1,272.0317344}{1,124.76} - 1 = +\mathbf{13.093614\%} \approx +\mathbf{13.09\%}$$

Lección: El incremento de 2 puntos porcentuales en gastos variables eleva la tarifa indicada porque una fracción mayor de la prima queda destinada a gastos variables y una fracción menor permanece disponible para pérdidas y gastos fijos.

Experimento 3: Shock en Gastos Fijos de Operación

Supongamos que los gastos fijos administrativos por exposición sufren un incremento lineal debido a sistemas tecnológicos de la compañía, elevándose de 60.00 a **70.00 USD por exposición**.

- La nueva tarifa indicada asciende a:

$$R_{\text{ind}} = \frac{894.0238008 + 70.00}{0.77} = \mathbf{1,251.978962 \text{ USD}}$$

- El cambio porcentual indicado se desplaza de manera lineal de +10.16 % a:

$$\Delta r = \frac{1,251.978962}{1,124.76} - 1 = \mathbf{+11.310765 \% \approx +11.31 \%}$$

Lección: El aumento aditivo de 10 USD de gastos fijos en el numerador se traduce en un incremento en la tarifa indicada de aproximadamente 12.99 USD por exposición (10/0.77) debido a que cada dólar de costo aditivo incorporado debe sostener su porción correspondiente de gastos variables y provisión de ganancia y contingencias.

Experimento 4: Ajuste de la Tarifa Comercial de Cierre (Cambio en Denominador)

Supongamos que Meridiano Seguros hubiera implementado un incremento comercial preventivo antes del cierre de 2025, de manera que su tarifa vigente actual de cierre no fuera 1,124.76 USD, sino de **1,200.00 USD por exposición**. Asumimos que los supuestos de costos futuros y márgenes permanecen estrictamente sin cambios.

- La tarifa técnica indicada calculada bajo el método *Loss Cost* se mantiene estrictamente fija e inalterada en **1,238.99 USD por exposición**.
- El factor de indicación tarifaria requerido se contrae a:

$$I = \frac{1,238.991949}{1,200.00} = \mathbf{1.03249329}$$

- El cambio de tarifa indicado cae de forma sustancial de +10.16 % a:

$$\Delta r = 1.03249329 - 1 = +\mathbf{3.249329\%} \approx +\mathbf{3.25\%}$$

Lección: Este experimento distingue dos objetos diferentes: **la tarifa indicada absoluta** (R_{ind}) **depende de la estructura de costos prospectivos y no cambia cuando solo cambia la tarifa vigente actual.** En cambio, el cambio porcentual indicado (Δr) depende de la tarifa actual mediante $\Delta r = R_{\text{ind}}/R_{\text{current}} - 1$; por tanto, su relación con R_{current} es inversa, no lineal.

5.3.5 La estructura técnica de la tarifa requiere transparencia en la composición de cada dólar

Para cerrar el análisis de la tarifa del Accident Year 2027, Lucía e Irene desglosan de forma analítica la composición de la tarifa técnica indicada de **1,238.99 USD por exposición**:

- **Pérdidas Esperadas Projectadas (LC): 894.02 USD por exposición**, equivalentes al **72.16 %** de la tarifa técnica indicada, corresponden al costo esperado de los siniestros de la cartera.
- **Gastos Fijos por Exposición (FE): 60.00 USD por exposición**, equivalentes al **4.84 %** de la tarifa técnica indicada, corresponden a los costos administrativos fijos por exposición de la aseguradora.
- **Gastos Variables de Suscripción (vR_{ind}): 223.02 USD por exposición** ($0.18 \times 1,238.9919$) corresponden a la provisión de gastos variables.
- **Provisión de Ganancia y Contingencias (qR_{ind}): 61.95 USD por exposición** ($0.05 \times 1,238.9919$) corresponden a la provisión de ganancia y contingencias del marco de pricing.

La reconciliación de la tarifa técnica indicada es perfecta:

$$894.023801 \text{ USD} + 60.00 \text{ USD} + 223.018551 \text{ USD} + 61.949597 \text{ USD} = \mathbf{1,238.991949 \text{ USD}}$$

$$72.157354 \% + 4.842646 \% + 18.00 \% + 5.00 \% = \mathbf{100.00 \%}$$

Al finalizar este cálculo, Lucía e Irene contemplan la composición técnica final de la tarifa. El **ratio de pérdidas esperado bajo la nueva tarifa indicada es de 72.16 %**, una cifra que se ubica por debajo de la razón proyectada original a tarifa actual de **79.49 %**. Esta disminución porcentual no representa una mejora en el riesgo de la cartera ni una disminución en el costo absoluto de los siniestros, que siguen fijos en 894.02 USD; es la consecuencia de haber aumentado el denominador tarifario desde la base actual de 1,124.76 USD hasta la tarifa indicada de 1,238.99 USD.

Este contraste numérico final cierra el bloque asegurador de la serie con un recordatorio del rigor metodológico: **una cifra técnica actuarial jamás es una verdad absoluta por sí sola; es el resultado de un balance de flujos que debe ser interpretado respetando la base matemática que lo hace posible.**

Cierre y Puente de Paradigm Shift (Tránsito a Part 6)

Part 5 comenzó mirando hacia el pasado. En reserving, la exposición ya había ocurrido y la pregunta era cuánto costo último todavía no había emergido. Después, la preparación de datos para ratemaking llevó la experiencia histórica a una base económica comparable con el periodo futuro. Finalmente, esta sección convirtió esa estructura prospectiva en una tarifa indicada.

La progresión completa de Part 5 queda así:

observación histórica → estimación última → costo prospectivo comparable → tarifa indicada.

Reserving y ratemaking utilizan información histórica, pero apuntan en direcciones temporales distintas. **Reserving** estima lo que falta por reconocer de eventos que ya ocurrieron. **Ratemaking** estima qué tarifa puede financiar el costo esperado de una exposición futura. En ambos casos, la cifra solo es interpretable si su base temporal, contractual y económica está explícita.

Sin embargo, Part 6 introduce un marco de valoración diferente para otro tipo de pago contingente. *Si un pago futuro incierto puede reproducirse mediante un portafolio de activos negociados, ¿qué cambia cuando su valor puede restringirse por replicación y ausencia de arbitraje en lugar de construirse principalmente desde su costo físico esperado?* Esa pregunta abre **Part 6 - Option Pricing Fundamentals, Section 6.1 - Introduction to Options**.

Ejercicios

Ejercicio 1 - Determinación de la Tarifa Técnica mediante el Loss Cost Method

El departamento de Pricing de Meridiano Seguros analiza la indicación prospectiva para el Accident Year 2027. Tras la fase de preparación de datos, cuenta con un costo de pérdidas esperado (LC) de exactamente **894.0238008 USD por exposición**, un gasto administrativo fijo por exposición (FE) de **60.00 USD por exposición**, un ratio de gastos variables de suscripción (v) del **18 % sobre la prima** y una provisión para ganancia y contingencias (q) del **5 % sobre la prima**. La tarifa comercial de cierre vigente es de **1,124.76 USD por exposición**. El caso permanece sobre la misma **base gross** utilizada en la sección.

1. Derive la ecuación de equilibrio de flujos de caja y justifique algebraicamente por qué los gastos variables y la provisión de ganancia y contingencias se incorporan mediante

la fracción admisible del denominador.

2. Calcule de manera exacta la tarifa técnica indicada (R_{ind}) por exposición aplicando el método *Loss Cost*.
3. Calcule el factor de indicación tarifaria requerido (I) y deduzca el cambio porcentual indicado (Δr) respecto de la tarifa actual.
4. Desglose la composición de cada unidad de la tarifa indicada calculando la porción en dólares destinada a siniestros, gastos fijos, gastos variables y provisión de ganancia y contingencias. Verifique que la suma de los componentes reconcilia con la tarifa indicada.
5. Explique la consecuencia financiera de cometer el error de recargar directamente un 23 % sobre la suma de pérdidas esperadas y gastos fijos, es decir, multiplicar esa suma por 1.23.

Criterio de éxito para la solución:

- Tarifa técnica indicada exacta: $R_{\text{ind}} = (894.0238008 + 60) / 0.77 = \mathbf{1,238.991949}$ USD.
- Factor de indicación de tarifa: $I = 1,238.991949 / 1,124.76 = \mathbf{1.1015611767} \approx \mathbf{1.10156118}$.
- Cambio porcentual indicado exacto: $\Delta r = 1.1015611767 - 1 = \mathbf{+10.1561177\%} \approx \mathbf{+10.16\%}$.
- Composición en dólares por exposición: siniestros = **894.02** USD; gastos fijos = **60.00** USD; gastos variables = $0.18 \times 1,238.9919 = \mathbf{223.02}$ USD; provisión de ganancia y contingencias = $0.05 \times 1,238.9919 = \mathbf{61.95}$ USD. La suma exacta de los componentes utilizados en el cálculo es $894.023801 + 60.00 + 223.018551 + 61.949597 = \mathbf{1,238.991949}$ USD.
- La tarifa errónea sería aproximadamente **1,173.45 USD por exposición**. Después de aplicar la fracción admisible de 0.77, quedarían aproximadamente **903.56 USD por exposición** para pérdidas y gastos fijos, frente a una necesidad de **954.02 USD por exposición**; el déficit sería aproximadamente **50.47 USD por exposición**.

Ejercicio 2 - Reconstrucción de Tarifas mediante el Loss Ratio Method

Para el mismo portafolio de Meridiano Seguros analizado en el Ejercicio 1, suponga que la compañía audita la indicación utilizando la perspectiva relativa del método *Loss Ratio*.

1. Calcule de manera exacta la Razón de Siniestralidad Proyectada (LR_{proj}) relativa al nivel de tarifa comercial de cierre actual ($R_{\text{current}} = 1,124.76$ USD por exposición).
2. Calcule de manera exacta la Razón de Gastos Fijos (FER) relativa al nivel de tarifa actual.
3. Aplique la ecuación general del método *Loss Ratio* para calcular el factor de indicación de tarifa (I) requerido.
4. Deduzca el cambio porcentual indicado (Δr) y compruebe que coincide con el obtenido en el Ejercicio 1.
5. Derive la tarifa técnica indicada (R_{ind}) implícita multiplicando el factor de indicación obtenido por la tarifa comercial actual.
6. Proporcione la demostración algebraica formal que demuestra que el método de Razón de Siniestralidad es algebraicamente equivalente al de Costo de Siniestralidad, identificando cómo la división por R_{current} transforma los costos absolutos del numerador en ratios de prima actual.

Criterio de éxito para la solución:

- Razón de Siniestralidad Proyectada exacta: $LR_{\text{proj}} = 894.0238008/1,124.76 = 79.48573925\% \approx 79.49\%$.
- Razón de Gastos Fijos exacta: $FER = 60.00/1,124.76 = 5.33447135\% \approx 5.33\%$.
- Factor de indicación de tarifa: $I = (0.7948573925 + 0.0533447135)/0.77 = 1.1015611767 \approx 1.10156118$.

- Cambio porcentual de tarifa: $\Delta r = +10.16\%$.
- Tarifa técnica indicada implícita: $R_{\text{ind}} = 1,124.76 \times 1.1015611767 = 1,238.991949$ USD por exposición.
- La demostración matemática debe dividir la ecuación por R_{current} y distribuir esa división sobre $LC + FE$ para reconstruir exactamente $LR_{\text{proj}} + FER$.

Ejercicio 3 - Auditoría de una discrepancia entre métodos

Dos analistas revisan el mismo caso prospectivo de Meridiano Seguros y reportan resultados diferentes:

- **Analista A - Loss Cost Method:** cambio indicado de $+12\%$. Su hoja de trabajo muestra que el loss cost prospectivo fue sometido nuevamente a tendencia después de haber sido recibido como input preparado de la Section 5.2.
- **Analista B - Loss Ratio Method:** cambio indicado de $+8\%$. Su hoja de trabajo omite la razón de gastos fijos al construir el numerador del método.

Ambos deberían utilizar la misma base canónica: $LC = 894.0238008$ USD por exposición, $FE = 60.00$ USD por exposición, $v = 18\%$, $q = 5\%$ y $R_{\text{current}} = 1,124.76$ USD por exposición, todos sobre la misma base gross y temporal.

1. Identifique cada incompatibilidad de base o tratamiento en las dos hojas de trabajo.
2. Corrija ambos cálculos utilizando exclusivamente los inputs canónicos ya preparados.
3. Reconcilie las dos indicaciones y demuestre que ambas producen el mismo factor de indicación antes de redondear.
4. Explique por qué promediar $+12\%$ y $+8\%$ sería actuarialmente indefendible, aunque el promedio numérico parezca cercano a la indicación correcta.

Criterio de éxito para la solución:

- El Analista A debe eliminar la segunda aplicación de trend y utilizar directamente $LC = 894.0238008$ USD por exposición.
- El Analista B debe incluir $FER = FE/R_{\text{current}}$ junto con LR_{proj} .
- Ambos métodos deben reconciliar en $I = \mathbf{1.1015611767} \approx \mathbf{1.10156118}$ y $\Delta r = +\mathbf{10.1561177} \% \approx +\mathbf{10.16} \%$ antes del redondeo editorial.
- La discrepancia debe tratarse como un problema de calidad y compatibilidad de bases; no debe resolverse promediando dos indicaciones construidas de manera inconsistente.

6 - Option Pricing Fundamentals

Section 6.1 - Introduction to Options

Una opción no promete un pago: define un derecho cuyo valor depende del estado futuro

6.1.1 La opción de compra define un derecho asimétrico a adquirir sin obligación

Al completar el análisis de tarifas y reservas para seguros de daños de corto plazo, el equipo técnico de Meridiano Seguros ha trabajado principalmente con pérdidas, experiencia y costos esperados. Irene introduce aquí el cambio de dominio con una pregunta más elemental: «*Si un contrato financiero genera un flujo futuro incierto, antes de intentar valorarlo, ¿podemos describir exactamente qué paga en cada estado futuro?*» A partir de este punto abandonamos el caso asegurador y trabajamos con un activo financiero y contratos de opciones.

Consideremos un activo financiero subyacente que no paga dividendos durante el horizonte del caso. Su precio actual al tiempo $t = 0$ es $S_0 = 100$ USD por unidad del subyacente. El contrato vence dentro de $T = 1$ año y tiene precio de ejercicio $K = 100$ USD por unidad. Para estudiar los cash flows terminales evaluaremos tres estados pedagógicos del precio al vencimiento:

- $S_T = 80$ USD por unidad;
- $S_T = 100$ USD por unidad;

- $S_T = 120$ USD por unidad.

Estos tres valores no constituyen una distribución empírica ni una afirmación de que sean los únicos precios posibles del activo. Son estados terminales seleccionados para mapear el payoff del contrato. En esta sección no necesitamos asignar probabilidades a esos estados.

Trabajaremos con opciones europeas: el ejercicio se evalúa únicamente en la fecha de vencimiento $t = T$. Para aislar la estructura contractual suponemos además un activo sin dividendos y ausencia de costos de transacción u otras fricciones relevantes en este mapeo básico. Existen también opciones de estilo americano, que bajo sus términos pueden permitir ejercicio anticipado, pero su tratamiento queda fuera del alcance de esta sección.

El primer contrato fundamental es la **opción de compra** (*call option*). Una call europea otorga a su tenedor (*holder*) el derecho, pero no la obligación, de adquirir una unidad del activo subyacente al precio contractual K en T . El holder compra el derecho; no queda obligado a comprar el activo.

Desafío al lector 1. Antes de escribir una fórmula, con $K = 100$ USD, ¿qué debería pagar una long call si S_T termina en 80, 100 o 120 USD?

La asimetría contractual aparece al evaluar la decisión del tenedor al vencimiento:

- Si $S_T = 80$ USD, comprar a $K = 100$ USD carece de sentido económico bajo el setup simplificado. El tenedor deja expirar el contrato y el payoff es 0 USD por opción sobre una unidad.
- Si $S_T = 100$ USD, ejercer o no ejercer es económicamente indiferente respecto del precio spot terminal. El payoff es 0 USD.
- Si $S_T = 120$ USD, el tenedor puede adquirir por 100 USD un activo que vale 120 USD. El valor bruto del ejercicio es $120 - 100 = 20$ USD.

Matemáticamente, esta regla se expresa mediante el operador de parte positiva:

$$(x)_+ = \max(x, 0).$$

El payoff terminal de una posición larga en una call es:

$$C_T = (S_T - K)_+ = \max(S_T - K, 0).$$

Equivalentemente,

$$C_T = \begin{cases} 0, & S_T \leq K, \\ S_T - K, & S_T > K. \end{cases}$$

Aplicado a los tres estados terminales evaluados:

$$C_T = \max(S_T - 100, 0) \implies C_T \in \{0, 0, 20\} \text{ USD}.$$

El punto importante es que el payoff puede mapearse estado por estado antes de introducir cualquier probabilidad sobre cuál estado ocurrirá. Conocer el payoff, sin embargo, todavía no nos dice cuánto vale hoy la opción.

6.1.2 La opción de venta define un derecho asimétrico a vender para proteger la caída

La **opción de venta** (*put option*) otorga a su tenedor el derecho, pero no la obligación, de vender una unidad del activo subyacente al precio contractual K en la fecha de vencimiento T .

Desafío al lector 2. Con el mismo strike $K = 100$ USD, ¿qué debería pagar una long put si S_T termina en 80, 100 o 120 USD?

La decisión del holder es la inversa de la observada en la call:

- Si $S_T = 80$ USD, el tenedor puede vender por $K = 100$ USD un activo que en el mercado vale 80 USD. El payoff es $100 - 80 = 20$ USD.

- Si $S_T = 100$ USD, el ejercicio es indiferente y el payoff es 0 USD.
- Si $S_T = 120$ USD, no tiene sentido económico vender a 100 USD algo que puede venderse en el mercado por 120 USD. La put expira sin ejercicio y su payoff es 0 USD.

Algebraicamente, el payoff terminal de una posición larga en una put es:

$$P_T = (K - S_T)_+ = \max(K - S_T, 0).$$

Equivalentemente,

$$P_T = \begin{cases} K - S_T, & S_T < K, \\ 0, & S_T \geq K. \end{cases}$$

En los tres estados terminales evaluados:

$$P_T = \max(100 - S_T, 0) \implies P_T \in \{20, 0, 0\} \text{ USD.}$$

La primera comparación conjunta queda así:

S_T	Long Call, $K = 100$	Long Put, $K = 100$
80 USD	0 USD	20 USD
100 USD	0 USD	0 USD
120 USD	20 USD	0 USD

La asimetría también produce límites distintos. El payoff de una long call no tiene un límite superior contractual cuando S_T aumenta. En cambio, para una acción cuyo precio no puede caer por debajo de cero, el payoff máximo de una long put con strike $K = 100$ USD ocurre en $S_T = 0$ y es:

$$P_T = 100 - 0 = 100 \text{ USD.}$$

Por tanto,

$$0 \leq P_T \leq K.$$

6.1.3 El tiempo separa la prima pagada hoy del pago contingente recibido mañana

Un contrato de opción genera cash flows en fechas distintas. En $t = 0$, el comprador paga el precio o **prima** del derecho: C_0 para la call y P_0 para la put. En $t = T$, recibe un payoff contingente determinado por S_T . Todas estas cantidades se expresan en USD por opción sobre una unidad del subyacente.

En esta sección las primas permanecen estrictamente simbólicas. No intentaremos calcular C_0 ni P_0 , porque primero necesitamos comprender la estructura de los flujos que esos precios compran.

Contrato y posición	Cash flow en $t = 0$	Cash flow contingente en $t = T$
Long Call	$-C_0$	$+(S_T - K)_+$
Long Put	$-P_0$	$+(K - S_T)_+$

Esta separación temporal impide confundir **payoff**, **premium** y **profit**. Si una call expira con $C_T = 0$, sabemos que el holder tuvo un flujo de $-C_0$ en $t = 0$ y un flujo de 0 en T . No debemos convertir esos dos importes en una única cifra de beneficio neto sin llevarlos primero a una fecha común y declarar cómo tratamos el valor temporal del dinero.

Desafío al lector 3. Si una call termina con un payoff de 20 USD, ¿puede afirmarse que el holder obtuvo exactamente 20 USD de profit? No. El payoff terminal es solo uno de los cash flows; la inversión también tuvo una prima inicial y ambos flujos pertenecen a fechas distintas.

La disciplina temporal puede resumirse así:

Concepto	Fecha o base	Qué mide
Premium / price	$t = 0$	Precio actual del derecho
Payoff	$t = T$	Cash flow contractual terminal
Profit	Base temporal común	Resultado económico neto después de comparar coherentemente los cash flows

6.1.4 Tenedor frente a emisor: la transferencia simétrica de suma cero

Cada contrato de opción tiene dos lados. El **holder**, comprador o posición **long**, adquiere el derecho. El **writer**, vendedor o posición **short**, recibe la prima inicial y asume la obligación contractual correspondiente si el holder ejerce.

Para el contrato derivado considerado aisladamente, los payoffs terminales de long y short tienen signos opuestos estado por estado.

Para una call:

$$\text{Long Call} = C_T = (S_T - K)_+,$$

$$\text{Short Call} = -C_T = -(S_T - K)_+.$$

Para una put:

$$\text{Long Put} = P_T = (K - S_T)_+,$$

$$\text{Short Put} = -P_T = -(K - S_T)_+.$$

Desafío al lector 4. Si los payoffs de la long call en los tres estados son $\{0, 0, 20\}$ USD, ¿cuáles deben ser los payoffs del writer? La respuesta debe invertir los signos estado por estado.

El mapa completo es:

Estado terminal					
S_T	Long Call C_T	Short Call $-C_T$	Long Put P_T	Short Put $-P_T$	
80 USD	0 USD	0 USD	+20 USD	-20 USD	
100 USD	0 USD	0 USD	0 USD	0 USD	
120 USD	+20 USD	-20 USD	0 USD	0 USD	

Por tanto, en cada estado:

$$C_T + (-C_T) = 0,$$

$$P_T + (-P_T) = 0.$$

La suma cero se refiere aquí a los cash flows del **contrato de opción** entre sus dos lados. La posición short no es simplemente una opinión contraria sobre el mercado: es la obligación contractual que corresponde al derecho del long.

En una short call, el payoff terminal nunca es positivo y puede hacerse arbitrariamente negativo cuando S_T aumenta. Separadamente, el writer recibió $+C_0$ en $t = 0$. No debemos sumar esos flujos de fechas distintas para declarar una ganancia total sin una base temporal común. En una short put ocurre la misma inversión de signos: el writer recibe $+P_0$ al inicio y asume un payoff terminal de $-(K - S_T)_+$.

6.1.5 Estar *in-the-money* define viabilidad de ejercicio, no rentabilidad final

La **moneyness** clasifica la relación entre el precio terminal del subyacente S_T y el strike K desde la perspectiva del ejercicio al vencimiento.

Para una call:

- **In-the-money (ITM):** $S_T > K$.
- **At-the-money (ATM):** $S_T = K$.
- **Out-of-the-money (OTM):** $S_T < K$.

Para una put:

- **In-the-money (ITM):** $S_T < K$.
- **At-the-money (ATM):** $S_T = K$.
- **Out-of-the-money (OTM):** $S_T > K$.

Desafío al lector 5. Con $K = 100$ USD, clasifique call y put cuando S_T vale 80, 100 y 120 USD. La call pasa de OTM a ATM y después a ITM; la put hace el recorrido opuesto.

Estar ITM no demuestra que la inversión completa haya sido rentable. Si una call con $K = 100$ USD termina en $S_T = 110$ USD, su payoff es:

$$C_T = \max(110 - 100, 0) = 10 \text{ USD.}$$

La opción está ITM porque el ejercicio genera valor bruto positivo. Pero para evaluar el resultado económico total todavía habría que incorporar la prima simbólica C_0 pagada en $t = 0$ y llevar los cash flows a una fecha común. Por eso **moneyness describe valor de ejercicio, no rentabilidad total de la inversión.**

La forma del payoff hace visible la misma asimetría. Para la long call, cuando $S_T \leq K$ el payoff permanece plano en cero; cuando $S_T > K$, cada dólar adicional de S_T añade un dólar al payoff. Su pendiente terminal cambia de 0 a +1 en K . Para la long put, cuando $S_T < K$ la pendiente terminal es -1 , porque un aumento de un dólar en S_T reduce el payoff en un dólar; cuando $S_T \geq K$, la pendiente es 0. El punto $S_T = K$ es el *kink* de ambas funciones.

Estas pendientes son propiedades de la **función de payoff al vencimiento**. No son el delta del precio de la opción hoy; esa sensibilidad pertenece a un problema de valoración posterior.

Las características esenciales pueden resumirse así:

Característica	Call europea	Put europea
Derecho del holder	Comprar el underlying a K	Vender el underlying a K
Long payoff en T	$(S_T - K)_+$	$(K - S_T)_+$
Short payoff en T	$-(S_T - K)_+$	$-(K - S_T)_+$
Región favorable para ejercicio	$S_T > K$	$S_T < K$
Cash flow inicial del long	$-C_0$	$-P_0$
Estilo utilizado	Europeo: ejercicio en T	Europeo: ejercicio en T

6.1.6 La opción de venta como cobertura: el portafolio protector

La asimetría de la put permite construir una analogía útil con seguros: pagar un importe inicial para obtener protección frente a un estado adverso. La analogía no convierte a una put en una póliza de seguros; describe únicamente una función económica de protección contingente.

Considere un **portafolio protector** (*protective put*) formado por:

1. una unidad del activo subyacente, cuyo valor terminal es S_T ;
2. una long put con strike $K = 100$ USD, adquirida mediante el pago inicial de la prima simbólica P_0 .

Desafío al lector 6. Antes de escribir la identidad algebraica, ¿cuál es el valor terminal combinado del stock y la put si S_T vale 80, 100 o 120 USD?

El mapeo es:

- Si $S_T = 80$ USD, el stock vale 80 USD y la put paga $100 - 80 = 20$ USD. El valor terminal combinado es $80 + 20 = 100$ USD.
- Si $S_T = 100$ USD, el stock vale 100 USD y la put paga 0 USD. El valor terminal combinado es 100 USD.
- Si $S_T = 120$ USD, el stock vale 120 USD y la put paga 0 USD. El valor terminal combinado es 120 USD.

Por tanto,

$$S_T + P_T = S_T + (K - S_T)_+ = \max(S_T, K).$$

En los tres estados terminales evaluados:

$$V_T^{\text{protective}} \in \{100, 100, 120\} \text{ USD.}$$

La identidad muestra que, **antes de considerar la prima inicial de la put, su financiación y los demás cash flows de la inversión**, el valor terminal stock + put tiene un piso de $K = 100$ USD. La put compensa la caída del stock por debajo del strike y conserva la participación en el alza del subyacente por encima de K .

La semejanza con insurance es limitada. En ambos casos existe un costo inicial asociado a protección frente a un estado adverso. Pero una put es un contrato financiero sobre el precio de un underlying, mientras que un seguro de daños responde a una pérdida física y a sus términos contractuales. Una put puede producir payoff sin que exista una pérdida física asegurada, y su marco de valoración pertenece al mercado financiero. Por tanto, la relación es una analogía de protección contingente, no una identidad de productos.

Desafío al lector 7. Si ya conocemos los payoffs de la call como $\{0, 0, 20\}$ USD y de la put como $\{20, 0, 0\}$ USD en los tres estados evaluados, ¿podemos simplemente promediarlos o convertirlos directamente en C_0 y P_0 ? No. El mapa de payoffs describe qué paga el contrato; todavía falta un principio de valoración que conecte esos cash flows futuros con precios actuales.

Cierre y puente hacia Section 6.2

El caso canónico queda reconciliado estado por estado. Con $S_0 = 100$ USD, $K = 100$ USD y $T = 1$ año, los estados terminales evaluados $S_T \in \{80, 100, 120\}$ USD producen:

Long Call : $\{0, 0, 20\}$ USD,

Long Put : $\{20, 0, 0\}$ USD,

Short Call : $\{0, 0, -20\}$ USD,

Short Put : $\{-20, 0, 0\}$ USD.

Sabemos también que el premium ocurre en $t = 0$ y el payoff en $t = T$, por lo que esos cash flows no deben confundirse con profit. Y sabemos que una protective put genera, antes de considerar su prima inicial, el valor terminal:

$$S_T + (K - S_T)_+ = \max(S_T, K).$$

Nada de lo anterior determina todavía cuánto deben valer hoy C_0 y P_0 .

La siguiente pregunta surge precisamente de esa limitación: **si podemos construir dos portafolios diferentes cuyos cash flows terminales sean exactamente iguales para**

cada posible S_T , ¿podrían esos portfolios tener precios distintos hoy sin crear una oportunidad de obtener algo a cambio de nada?

Esa pregunta abre la Section 6.2 - Put-Call Parity.

Ejercicios

Ejercicio 1 - Calls y puts estado por estado

Un inversionista analiza un activo financiero subyacente que no paga dividendos durante el año. El precio spot actual es $S_0 = 100$ USD por unidad, el strike es $K = 100$ USD por unidad y el vencimiento es $T = 1$ año. Considere los estados terminales evaluados $S_T \in \{80, 100, 120\}$ USD.

1. Antes de recurrir a las fórmulas, explique en qué estados el holder de la call decidiría ejercer y calcule el payoff terminal de la long call.
2. Explique en qué estados el holder de la put decidiría ejercer y calcule el payoff terminal de la long put.
3. Clasifique la call como ITM, ATM u OTM en cada estado.
4. Clasifique la put como ITM, ATM u OTM en cada estado.
5. Explique cómo la decisión de ejercicio se conecta con el derecho contractual del holder.

Criterio de éxito para la solución:

- Long Call: $C_T \in \{0, 0, 20\}$ USD.
- Long Put: $P_T \in \{20, 0, 0\}$ USD.
- Call: 80 USD OTM, 100 USD ATM, 120 USD ITM.
- Put: 80 USD ITM, 100 USD ATM, 120 USD OTM.
- La decisión de ejercicio se explica por el valor económico del derecho, no por una obligación del holder.

Ejercicio 2 - Long, short y timing

Considere una call y una put europeas con strike $K = 100$ USD y vencimiento $T = 1$ año. Mantenga las primas simbólicas C_0 y P_0 .

1. Construya una tabla que muestre, para Long Call, Short Call, Long Put y Short Put, el cash flow en $t = 0$ y el payoff en $t = T$.
2. Utilizando los estados terminales $S_T \in \{80, 100, 120\}$ USD, construya los payoffs de las posiciones short y verifique que son el negativo exacto de las posiciones long estado por estado.
3. Explique por qué un payoff terminal de 20 USD no puede llamarse por sí solo un profit de 20 USD.

Criterio de éxito para la solución:

- Long Call: $-C_0$ en $t = 0$ y $+(S_T - K)_+$ en $t = T$.
- Short Call: $+C_0$ en $t = 0$ y $-(S_T - K)_+$ en $t = T$.
- Long Put: $-P_0$ en $t = 0$ y $+(K - S_T)_+$ en $t = T$.
- Short Put: $+P_0$ en $t = 0$ y $-(K - S_T)_+$ en $t = T$.
- Short Call: $\{0, 0, -20\}$ USD; Short Put: $\{-20, 0, 0\}$ USD.
- La explicación de profit debe reconocer la prima inicial y la necesidad de una base temporal común.

Ejercicio 3 - Put como protección

Un inversionista posee una unidad del activo subyacente y compra una put europea con strike $K = 100$ USD y vencimiento $T = 1$ año, pagando la prima simbólica P_0 en $t = 0$. Considere $S_T \in \{80, 100, 120\}$ USD.

1. Mapee el valor terminal del stock en cada estado.
2. Calcule el payoff terminal de la put en cada estado.
3. Calcule el valor terminal combinado stock + put.
4. Determine el valor terminal mínimo del portafolio antes de considerar la prima inicial.
5. Demuestre que:

$$S_T + (K - S_T)_+ = \max(S_T, K).$$

6. Explique la analogía con insurance.
7. Explique una manera en que la analogía no es exacta.

Criterio de éxito para la solución:

- Stock: $\{80, 100, 120\}$ USD.
- Put: $\{20, 0, 0\}$ USD.
- Portafolio protector: $\{100, 100, 120\}$ USD.
- El piso terminal antes de considerar la prima inicial es $K = 100$ USD.
- La analogía correcta es protección contingente mediante un costo inicial; no debe afirmarse que una put sea literalmente una póliza de seguros.